Wasserstein 稳健检验中的变量选择：研究方向

工作笔记，非正式

怎么读。这是一份想法笔记，不是论文。每个结论都标了状态：【已证】表示证明完整（这里只写思路），【草证】表示是标准论证、细节未写全，【猜想】表示还没证。所有数字都来自开发检查：小规模的 `note/directions/dev_checks.py` 和 20 维检查 `results/study20-v1`（代码 `scripts/run_study20.py`）。它们用来验证想法，不是正式实验结论。符号沿用正式笔记 `robust_coordinate_selection.pdf`，式 (1)–(9) 指正式笔记的公式。损失 ℓ 只需满足正式笔记的假设（非负、不减、凸、$\ell(0)=1$、$t\to-\infty$ 时趋于 0）；用到 hinge 损失 $\ell(t)=(1+t)_+$ 的地方会单独说明，数值例子都用 hinge。

主线。第 1 节回答读正式笔记时的几个疑问。第 2 节给出 hinge 下的匹配形式，它让计算和直觉都变简单。第 3 节是计算：外逼近为什么几乎要枚举所有子集，以及把选择问题改写成“稀疏的坐标价格”之后得到的精确搜索。第 4 节和第 5 节是两个研究方向：让半径随选中维数变化，以及随机化选择。

1　读正式笔记时的几个疑问

1.1　理论对一般损失成立

损失只通过一个二元函数进入正式笔记：

$$\psi(a,b)=\inf_{t\in\mathbb{R}}\{a\ell(-t)+b\ell(t)\},$$

即一个位置上有类 0 质量 a、类 1 质量 b 时，最好的分数能达到的最小损失。引理 2.1、式 (3)–(5)、命题 2.2 和附录 A 只用到 ψ 凹、不减、一次齐次，所以对每个满足假设的 ℓ 都成立。hinge 只出现在代码里：此时 ψ 分段线性，式 (3)(4) 都是线性规划。

损失	$\ell(t)$	$\psi(a,b)$	$2-\sum\psi$
hinge	$(1+t)_+$	$2\min(a,b)$	$2\,\mathrm{TV}$
指数	e^t	$2\sqrt{ab}$	$\sum(\sqrt{a}-\sqrt{b})^2$（Hellinger 距离平方的两倍）
logistic	$\log_2(1+e^t)$	$a\log_2\frac{a+b}{a}+b\log_2\frac{a+b}{b}$	两倍的 Jensen–Shannon 散度

表 1: 三种常见损失。最后一列把 ψ 用在两个概率分布上，得到一个散度。

最后一列给出 $V(S)$ 的一个统一读法。记 $D_\ell(Q_0,Q_1)=2-\int\psi(dQ_0,dQ_1)$，$\mathcal{P}_k[S]=\{Q:\mathcal{W}_1(\widehat{\mathbb{P}}_k[S],Q)\le\rho_k\}$，其中 $Q[S]$ 表示分布在坐标 S 上的投影。

命题 1 (散度形式)**.** 【已证】对任意 S，$V(S)=2-\min_{Q_k\in\mathcal{P}_k[S]}D_\ell(Q_0,Q_1)$。

为什么：固定 (Q_0,Q_1)，在 $\mathcal{F}_S$ 上逐点最小化风险，得到的就是 $\int\psi$；对手再挑最难分的一对。所以 $V(S)$ 是“对手在坐标 S 上能把两类拉到多近”。损失与散度的对应见 [16, 20]，最不利分布对的思想来自 Huber [11, 12]。

1.2 式 (3) 怎样推出式 (4)

两步。第一步，式 (3) 的目标里每个 ψ 都是对分数取下确界，所以目标等于

$$\inf_{g} \sum_{k,i,y} \gamma_{i,y}^{(k)}\, \ell\big((-1)^{k+1} g_y\big),$$

它对 g 凸、对 γ 线性，而可行运输构成紧凸集。Sion 极小极大定理 [21] 允许把 $\inf_g$ 提到外面，于是对手在检测器固定之后才选运输。第二步，检测器固定时，对手的问题按类分开，每类是一个线性规划：在预算 ρ_k 内搬运 $\widehat{\mathbb{P}}_k$，使损失 $y \mapsto \ell((-1)^{k+1} g_y)$ 的期望最大。它的对偶就是常见的 Wasserstein 对偶

$$\min_{\lambda_k \ge 0}\ \rho_k \lambda_k + \frac{1}{n_k} \sum_{i=1}^{n_k} \max_{y \in \mathcal{X}} \big\{ \ell((-1)^{k+1} g_y) - \lambda_k \| x_i^{(k)}[S] - y[S] \|_1 \big\}.$$

把内层的 max 记作 $a_i^{(k)}$，再对 g 取最小，就是式 (4)。

读法。 λ_k 是类 k 每单位运输距离的价格；$a_i^{(k)}$ 是源点 i 在这个价格下的最坏净损失（搬到 y 的损失减去运费）。稳健风险等于平均最坏净损失加上预算乘价格。反过来，式 (4) 每条约束的乘子就是式 (3) 的运输量，所以代码只解一个线性规划，就同时拿到检测器、$V(S)$ 和最不利运输。

1.3 式 (5) 与 Xie 等的定理 1

式 (5) 就是 Xie 等 [26] 定理 1(ii) 的区间，换成了一般损失的写法。他们研究随机化检验 $\pi \in [0,1]$（π 是判为第一类，即我们的类 0 的概率），风险是两类错误概率之和：类 0 上 $1-\pi$，类 1 上 π。hinge 损失下把分数限制在 $[-1,1]$ 不损失什么，令 $\pi = (1+g)/2$，则

$$\ell(-g) = 1 - g = 2(1-\pi), \qquad \ell(g) = 1 + g = 2\pi.$$

所以 **hinge 下的稳健风险恰好是他们的风险的两倍**，两个问题是同一个问题。他们的定理 1(i) 是样本点上的有限问题，对应式 (3)(4)；定理 1(ii) 给出样本外的区间 $l(\omega) \le \pi(\omega) \le u(\omega)$。把他们的 $l(\omega)$ 展开，$\pi(\omega) \ge l(\omega)$ 恰好是 $1 - \pi(\omega) \le \min_i\{a_i + \lambda_1 c(\omega, \widehat{\omega}_1^i)\}$，即式 (5) 的第一个不等式（$u(\omega)$ 对应第二个）。看起来不一样只是因为记号：

	Xie 等 [26]	正式笔记
两类	H_1, H_2，样本 $\widehat{\omega}_1^i, \widehat{\omega}_2^j$	类 0、类 1，样本 $x_i^{(0)}, x_j^{(1)}$
半径、距离	θ_1, θ_2，$c(\omega, \omega')$	ρ_0, ρ_1，$\|x[S] - y[S]\|_1$
检验	$\pi \in [0,1]$，损失 $1-\pi$ 和 π	分数 g，损失 $\ell(-g)$ 和 $\ell(g)$
样本外	显式区间 $[l(\omega), u(\omega)]$	包络 E_k 与条件 (5)

表 2: 记号对照。hinge 下取 $\pi = (1+g)/2$，两边逐项相同。

一般损失的有限形式（引理 2.1）来自 Gao 等 [9]，所以正式笔记引用的是两篇：引理 2.1 用 [9]，区间 (5) 用 [26]。两点插值的构造是我们为了得到一个明确的可测检测器而写的。

1.4 命题 2.2 在做什么；旧版的平方根从哪里来

在二元点上，$V(\mathbf{1}_S)$ 已经由引理 2.1 给出。命题 2.2 要的是另一件事：一个对**分数** $z \in [0,1]^D$ 也有定义的函数，它在二元点上等于 V，并且由关于 z 的仿射函数拼成。有了它，每评估一个

子集就得到一条割，主问题 (9) 是一个混合整数线性规划。附录 A 证明“二元点上等于 V”，这一步本来就不该改变数值，它是检查这个函数确实是我们要的那个；收获在二元点之间。

这个函数天然是一个比值：

$$F(z) = \max_{(\gamma,\mu)\in\mathcal{D}} \frac{H(\gamma)}{M(\gamma) + \mu^\top z}.$$

分子是对手制造的重叠，分母是对手付出的“质量加豁免费”。比值对 z 不是仿射的，有两种办法处理：

- **旧版：平方根。**对 $b > 0$，$\max_{s\ge 0}\{2\sqrt{sH} - sb\} = H/b$（在 $s = H/b^2$ 取到，即算术–几何平均不等式）。把 (γ, μ) 整体乘以 s 不出 $\mathcal{D}$，而 H, M, μ 都随 s 线性变化，所以 $F(z) = \max_{\mathcal{D}}\{2\sqrt{H(\gamma)} - M(\gamma) - \mu^\top z\}$：每一项对 z 仿射，平方根就是这样来的。
- **新版：取倒数。**$1/F(z) = \min\{M(\gamma) + \mu^\top z : (\gamma, \mu) \in \mathcal{D},\ H(\gamma) \ge 1\}$，每一项对 z 仿射，所以 $1/F$ 是凹的。信息完全相同，但不需要平方根。

新版的割 $c_t(z) = M(\gamma^t) + (\mu^t)^\top z$ 给出 $F(z) \ge 1/c_t(z)$。因为 $t \mapsto 1/t$ 凸，这个下界处处不低于旧版的切线。在二元点上，它有一个闭式：若 $\gamma^\star$ 是 S 的最不利运输，令 $\pi_m = \max_k c_k(\gamma^\star)[m]/\rho_k$ $(m \notin S)$，则对任意 T，

$$V(T) \ \ge\ \frac{V(S)}{1 + \sum_{m\in T\setminus S} \pi_m}. \tag{1}$$

这就是比值割；旧版切线给出的是 $V(S)(1 - \sum_{m\in T\setminus S}\pi_m)$，当 $\sum_{m\in T\setminus S}\pi_m \ge 1$ 时它没有任何信息。π_m 是对手在坐标 m 上的运输量占预算的比例；S 内坐标上的运输已经计入预算，所以只对 $T \setminus S$ 收费。

2 hinge 例子：$V(S)$ 是一个带预算的匹配

本节用 hinge 损失。记 $C^m_{ij} = |x^{(0)}_i[m] - x^{(1)}_j[m]|$，$c_{ij}(S) = \sum_{m\in S} C^m_{ij}$，

$$m_S(\rho) = \max_{\pi\ge 0}\Big\{\sum_{i,j}\pi_{ij} :\ \sum_j \pi_{ij} \le \frac{1}{n_0},\ \sum_i \pi_{ij} \le \frac{1}{n_1},\ \sum_{i,j}\pi_{ij}c_{ij}(S) \le \rho\Big\}, \tag{2}$$

即在总运输预算 ρ 内最多能撮合多少跨类质量。

命题 2 (匹配形式)**.** 【已证】 hinge 损失下 $V(S) = 2\, m_S(\rho_0 + \rho_1)$。

为什么：hinge 下 $\psi = 2\min(a, b)$，所以 $V(S)/2$ 是两类在投影球里能达到的最大重叠质量。要制造重叠，必须把一个 0 类点的质量和一个 1 类点的质量搬到同一个位置，由三角不等式，两边合计至少花 $c_{ij}(S)$。反过来，沿两点连线按 $\rho_0 : \rho_1$ 的比例各走一段，就恰好花 $c_{ij}(S)$。所以**对手是一个媒人**：用预算 $\rho_0 + \rho_1$ 撮合尽可能多的跨类点对。

三个直接推论：(i) 半径只通过 $\rho_0 + \rho_1$ 起作用；(ii) S 好，当且仅当在 S 的坐标上便宜的跨类点对很少；(iii) 计算 $V(S)$ 只是一个多了一条预算约束的二分匹配，$n_0 n_1$ 个变量。20 维检查里，核心求解器算出的 $V(S)$ 与 $2m_S$ 的最大差是 3.3×10^{-11}。当 $n_0 = n_1 = n$ 时还可以更快：令 $C(k)$ 为 k 对不相交跨类点对的最小总代价除以 n（用匈牙利算法），$C(k)$ 关于 k 凸，$m_S(\rho)$ 就是 C 的反函数（断点之间线性插值）。实验代码里的 `Matching` 类这样算，比解线性规划快约 30 倍。这个形式对总体分布也成立：它是部分最优运输的预算形式 [6, 2]。

对偶：Lipschitz 见证函数。对 $\lambda \ge 0$，令 $\beta_\lambda(Q_0, Q_1) = \sup\{\mathbb{E}_{Q_0}h - \mathbb{E}_{Q_1}h :\ |h| \le \frac{1}{2},\ h$ 关于ℓ_1 是λ-Lipschitz$\}$，即用“有界、斜率不超过 λ”的函数能看出的两样本均值差 [5]。

命题 3 (Lipschitz 见证)．【已证】 hinge 损失下

$$V(S) = 2 - 2\max_{\lambda \geq 0}\{\beta_\lambda(\widehat{\mathbb{P}}_0[S], \widehat{\mathbb{P}}_1[S]) - \lambda(\rho_0 + \rho_1)\},$$

并且若 (λ, h) 取到最大，检测器 $f(x) = 2h(x[S])$ 是最优的：$R(f) = V(S)$。

为什么：只对式 (2)的预算约束取对偶，再对剩下的无预算匹配取线性规划对偶，把对偶变量读成两类点上的函数值，就得到 β_λ。$|2h| \leq 1$ 让 hinge 损失变成线性的，再用 Kantorovich–Rubinstein 对偶得到风险上界 $V(S)$。

读法。稳健 hinge 检验是一个两样本统计量：见证函数可以很陡地把两个样本分开，但斜率 λ 要付 $\lambda(\rho_0 + \rho_1)$。半径决定了见证函数必须多平滑。具体构造：解式 (2)的对偶得到 (u, v, λ)，令 $h'_j = \min(v_j - \frac{1}{2}, \frac{1}{2})$，$h(\xi) = \mathrm{clip}_{[-1/2,1/2]}(\min_j\{h'_j + \lambda\|x_j^{(1)}[S] - \xi\|_1\})$，它就是实验代码里的 `witness()`。$m_S$ 关于 ρ 凹、不减，斜率等于最优价格 λ；第 5 节会用这些切线。

3 计算：从割到稀疏的坐标价格

3.1 现象：外逼近几乎要枚举所有子集

表 3在小例子上比较了式 (1)的比值割和旧版切线。两种割都要评估**全部**子集才能证明最优；比值割虽然处处更强，评估次数却一样。20 维检查（表 4，旧版切线割）也一样：$d = 2$ 时评估了全部 190 个子集，$d = 3$ 时 600 秒内评估了 1140 个中的 920–1090 个，下界只有 0.17–0.28，而最优值是 0.88–1.02。

D	N	d	子集数	切线割评估	比值割评估
10	30	2	45	45	45
15	30	2	105	105	105
12	30	3	220	220	220
20	30	2	190	190	190

表 3: 外逼近（算法 1）用两种割时评估的子集数（`dev_checks.py --oa`）。hinge，$\rho_0 + \rho_1 = 0.6$。数据：两类都是标准正态，1 类在坐标 1–3 平移 0.8、在坐标 4 放大 1.8 倍；本节所有小例子都用这个设定。

n	d	枚举（匹配形式）	式 (4)（HiGHS）	承诺界	OA 上界/下界	OA 状态
25	2	1.2811（0.1 s）	1.2811（2.2 s，35 节点）	0.7142	1.2811 / 1.2811	最优，190 个子集，18 s
25	3	0.8762（0.3 s）	0.8762（9.5 s，1457 节点）	0.4881	0.8762 / 0.2842	600 s 超时，920 个子集
50	2	1.3210（0.2 s）	1.3210（7.0 s，33 节点）	0.7776	1.3210 / 1.3210	最优，190 个子集，63 s
50	3	1.0242（1.2 s）	1.0242（40.0 s，1559 节点）	0.5316	1.0242 / 0.1731	600 s 超时，1090 个子集

表 4: 20 维检查的实验 3（信号数据，第一个确认种子，hinge，$\rho_0 + \rho_1 = 0.6$），数值以 V 的尺度给出。OA 是旧版核心包（切线割）的算法 1；式 (4)与承诺界见第 3.2 节和第 3.3 节。$d = 2, 3$ 时分别共有 190 和 1140 个子集。

为什么。看式 (1)：从 S 得到的割要排除另一个子集 T，需要 $V(S)/(1 + \pi(T \setminus S)) \geq U$，即 $\pi(T \setminus S) \leq V(S)/U - 1$。$S$ 的最不利运输只为 S 上的坐标付钱，在别的坐标上常常搬得很远，π_m 通常大于 1；而好的 S 有 $V(S) \approx U$。所以**每条割基本只认得它自己那个子集**。根本原因是：割把对手在 S 上的计划原样缩小后搬到 T 上用，而真正的对手看到 T 之后会重新做计划。更

强的做法（把旧计划按比例缩到 T 的预算内，不足的质量留在原地）仍然只用旧计划，受同样的限制。下面换一个写法，把“对手能不能重新做计划”变成一个可以计算的量。

3.2 稀疏的坐标价格：一个精确的重写

式 (4) 里 $\lambda_k\|x[S]-y[S]\|_1=\sum_m w_{km}|x[m]-y[m]|$,其中 $w_k=\lambda_k\mathbf{1}_S$。把 $w=(w_0,w_1)\in\mathbb{R}_+^{2\times D}$ 当成自由变量：w_{km} 是防守方对“类 k 在坐标 m 上搬运”收的单价。记 $\operatorname{supp} w=\{m: w_{0m}+w_{1m}>0\}$，令 Γ 为行和满足 $\sum_y \gamma^{(k)}_{i,y}=1/n_k$ 的运输（**没有**预算约束），并定义

$$G(w)=\max_{\gamma\in\Gamma}\Big\{H(\gamma)-\sum_{k=0}^{1} w_k^\top c_k(\gamma)\Big\}.$$

$G(w)$ 是“对手不受预算限制、但每搬一单位要按价格 w 付钱”时能得到的最大净收益。

命题 4 (稀疏价格)**.** 【已证】对任意 S，$V(S)=\min\{\rho_0\|w_0\|_\infty+\rho_1\|w_1\|_\infty+G(w):\ w\ge 0,\ \operatorname{supp} w\subseteq S\}$。因此

$$\min_{|S|\le d} V(S)=\min_{w\ge 0,\ |\operatorname{supp} w|\le d}\ \rho_0\|w_0\|_\infty+\rho_1\|w_1\|_\infty+G(w). \tag{3}$$

G 凸、不增；若 γ 在 w 处取到 G 的最大值，则 $-c_k(\gamma)$ 是 G 关于 w_k 的次梯度。

为什么：和 (3) → (4) 一样用 Sion 定理交换 $\max_\gamma$ 与 $\inf_g$；交换后每一行的最大值取在一个目标上，于是 $G(w)$ 等于式 (4) 把 $\lambda_k\|x[S]-y[S]\|_1$ 换成 $\sum_m w_{km}|x[m]-y[m]|$、只对 (g,a) 取最小的值。取 $w_k=\lambda_k\mathbf{1}_S$ 再对 λ 取最小，就是式 (4)。反过来，任意 $\operatorname{supp} w\subseteq S$ 的 w 满足 $w_k\le\|w_k\|_\infty\mathbf{1}_S$，而 G 不增，所以把 w_k 抬到 $\|w_k\|_\infty\mathbf{1}_S$ 不会更差。G 是一族 w 的仿射函数的最大值，所以凸，次梯度由取到最大值的那一项给出。

读法。 式 (3)长得像稀疏回归：G 是损失，$\rho\|w\|_\infty$ 是罚项，$|\operatorname{supp} w|\le d$ 是稀疏约束。不同的是罚项用 ℓ_∞：一个价格 λ_k 管住所有选中的坐标，再加一个价格不超过 λ_k 的坐标，罚项不变。所以只有稀疏约束阻止“全选”。次梯度说的是：把坐标 m 的价格抬高一点，风险下降的速度就是对手在 m 上的运输量 $c_k(\gamma)[m]$。这正是比值割里 π_m 的来源，也是下面分支和局部搜索要用的“价格信号”。

hinge 的情形。由命题 2，hinge 下两类可以共用一个价格。令 $\rho=\rho_0+\rho_1$，$z\in\mathcal{Z}_d$，式 (3)变成一个紧凑的混合整数线性规划（值以 m 的尺度给出）：

$$\begin{aligned}\min_{z\in\mathcal{Z}_d,\,u,v,w,\lambda\ge 0}\quad & \rho\lambda+\bar u+\bar v\\ \text{s.t.}\quad & u_i+v_j+\sum_m w_m C^m_{ij}\ge 1,\qquad w_m\le\lambda,\qquad \rho w_m\le z_m,\qquad \sum_m w_m\le d\lambda,\end{aligned} \tag{4}$$

其中 $\bar u=\frac{1}{n_0}\sum_i u_i$，$\bar v=\frac{1}{n_1}\sum_j v_j$。第一条约束是式 (2)的对偶：每个跨类点对，要么由两个端点“付钱”（u_i+v_j），要么被定价后的距离隔开。$u=\mathbf{1}$、$v=0$、$\lambda=0$ 的值是 1，所以最优时 $\rho\lambda\le 1$，$\rho w_m\le z_m$ 只在 $z_m=0$ 时起作用；最后一条约束不改变整数解，但让松弛更紧（见下一节）。

3.3 连续松弛就是“对手先承诺”

式 (3)里唯一的组合部分是罚项加稀疏约束。对单个类，函数 $\lambda\|w\|_\infty$（限制在 $|\operatorname{supp} w|\le d$）的凸包络是 $\lambda\max\{\|w\|_\infty,\|w\|_1/d\}$：集合 $\{w\ge 0:\|w\|_\infty\le 1,\|w\|_1\le d\}$ 的顶点正好是 $\mathbf{1}_S$，$|S|\le d$。记 $\operatorname{top}_d(c)$ 为向量 c 最大的 d 个分量之和。

命题 5 (承诺界)**.** 【已证】把式 (3)中两类共用的稀疏约束换成每类各自的凸包络，

$$\begin{aligned}\min_{w\ge 0}\ &\sum_{k=0}^{1}\rho_k\max\Big\{\|w_k\|_\infty,\frac{\|w_k\|_1}{d}\Big\}+G(w)\\ &=\max\big\{H(\gamma):\ \gamma\in\Gamma,\ \mathrm{top}_d\big(c_k(\gamma)\big)\le\rho_k,\ k=0,1\big\},\end{aligned}\tag{5}$$

记这个值为 L_d，则 $L_d\le\min_{|S|\le d}V(S)$。hinge 下对式 (4)做同样的事，得到它的连续松弛，值为 $2\max\{\sum_{i,j}\pi_{ij}:\pi$ 满足式 (2)的行列约束, $\mathrm{top}_d(\kappa(\pi))\le\rho_0+\rho_1\}$，其中 $\kappa_m(\pi)=\sum_{i,j}\pi_{ij}C^m_{ij}$；它介于 L_d 和 $\min_{|S|\le d}V(S)$ 之间。

为什么：单位球 $\{w\ge 0:\max(\|w\|_\infty,\|w\|_1/d)\le 1\}$ 上 $w^\top c$ 的最大值是 $\mathrm{top}_d(c)$。把 G 写成最大值，交换 $\min_w$ 和 $\max_\gamma$（Sion，Γ 紧），对 w 取最小：若 $\mathrm{top}_d(c_k(\gamma))\le\rho_k$ 结果是 0，否则是 $-\infty$。不等式也可以直接看：若 $\mathrm{top}_d(c_k(\gamma))\le\rho_k$，则 γ 在每个 $|S|\le d$ 上都满足式 (3) 的预算，所以 $H(\gamma)\le V(S)$。hinge：最优时 $\rho\lambda\le 1$，松弛里取 $z=\rho w$ 总可行，剩下的约束 $0\le w\le\lambda$、$\sum w\le d\lambda$ 就是凸包络，同样的论证给出匹配形式。把 γ 在每个目标上的两类质量配成对，得到的 π 有 $\kappa\le c_0+c_1$，所以匹配形式不小于 L_d。

下文的表格都用 hinge 的匹配形式，称为**承诺界**。

读法。 L_d 里的对手必须**先**给出一个运输计划，它要在防守方挑的任意 d 个坐标上都不超预算；真正的对手是**后手**，看到 S 之后再做计划。所以

$$\min_{|S|\le d}V(S)-L_d\ =\ \text{后手对手比先手对手多拿到的重叠.}$$

同一个数还有一个读法：由极小极大定理，L_d 等于防守方用**加权** ℓ_1 度量 $\sum_m\zeta_m|x[m]-y[m]|$（$0\le\zeta\le 1$，$\sum\zeta_m\le d$，每个坐标“看一部分”）时的最好稳健值。加权把所有坐标平均起来，跨类点对的代价向均值集中，对手找不到在稀疏投影里总能找到的那几个便宜点对。**混合坐标帮防守方**，间隙就是这个好处的大小。

表 5给出数值：承诺界只有最优值的四成到三分之二。正式笔记的 F 的松弛更弱：$D=10$、$d=2$ 时 F 在均匀点 $(d/D)\mathbf{1}$ 处只有 0.58，而承诺界是 0.89。因为承诺界来自罚项的凸包络，稀疏回归里常用的强化松弛（利用二次项的那一类）在这里已经用上了，在根节点上不能再多得到什么。

D	N	d	$\min_S V(S)$	承诺界	式 (4)（HiGHS）	枚举
10	30	2	1.40	0.89	0.2 s，17 节点	0.2 s
15	30	2	1.12	0.75	0.4 s，25 节点	0.5 s
12	30	3	0.87	0.49	0.7 s，302 节点	1.1 s
30	40	3	0.75	0.43	26 s，4.1k 节点	22 s
50	40	3	0.80	0.40	235 s，26k 节点	–
100	40	3	≤ 0.88	0.37	600 s 时限	–

表 5: 承诺界与紧凑程序（`dev_checks.py --gap`），数值以 V 的尺度给出。hinge，$\rho_0+\rho_1=0.6$。

3.4 困难性：对每个损失都是 NP 难

命题 6 (NP 难)**.** 【已证】设数据取值于 $\{0,1\}$，$s=\psi(1/n_0,1/n_1)>0$。存在只依赖 ℓ,n_0,n_1 的 $\bar\rho>0$，使得 $\rho_0+\rho_1<\bar\rho$ 时：$\min_{|S|\le d}V(S)<s$，当且仅当存在 $|S|\le d$ 把每个跨类点对分开（$x_i^{(0)}[S]\ne x_j^{(1)}[S]$）。后者是 k-feature-set 问题，NP 完全 [4]；按 d 参数化也难 [3]，即不能指望运行时间形如“d 的函数乘以多项式”的算法。

为什么：没分开时，某一对跨类点在 S 上重合，零代价就能把它们放到同一个位置，那里同时有 $1/n_0$ 的类 0 质量和 $1/n_1$ 的类 1 质量，所以 $V(S) \geq s$。分开时，二值数据上不同投影的 ℓ_1 距离至少是 1，所以搬到对方位置的质量，类 k 合计不超过 ρ_k。在类 0 的位置用 $\psi(a,b) \leq a\ell(-T)+b\ell(T)$，在类 1 的位置把 T 换成 $-T$，得到 $V(S) \leq 2\ell(-T) + (\rho_0+\rho_1)\ell(T)$。先取 T 使 $2\ell(-T) < s/2$，再取 $\bar{\rho} = s/(2\ell(T))$。

边际递减也帮不了贪心：0 类在 $(0,0),(1,1)$，1 类在 $(0,1),(1,0)$（异或），单个坐标都不能把任何一对分开，两个一起才行。**结论：**精确算法在最坏情况下必然是搜索。能做的是让搜索的每个节点都用上最好的界、按价格信号分支，并在统计上没有意义的差距处停下。

3.5 一个精确的搜索：分支定界

搜索树的节点是 (A, C, r)：A 中的坐标已选，C 中的坐标待定，还能再选 $r = d - |A|$ 个。节点的界是式 (5)的局部版本

$$L(A,C,r) = \max\Big\{H(\gamma):\ \gamma\in\Gamma,\ \sum_{m\in A} c_k(\gamma)[m] + \operatorname{top}_r\big(c_k(\gamma)|_C\big) \leq \rho_k,\ k=0,1\Big\}.$$

它对节点下的每个补全 $S = A \cup T$（$T \subseteq C$，$|T| \leq r$）都是 $V(S)$ 的下界；根节点是 L_d；$r = 0$ 时就是 $V(A)$。$\operatorname{top}_r(c)$ 可以写成 $\min_t\{rt + \sum_m (c_m - t)_+\}$，所以 hinge 下用匹配形式，每个节点是一个线性规划，根节点是承诺界。三个部件：

- **分支**：选节点计划里价格 $\max_k c_k(\gamma)[m]/\rho_k$ 最高的待定坐标 m，分成“选 m”和“不选 m”两个子节点。先手对手最依赖这个坐标，先决定它，最可能让界动起来。
- **现有最好解**：从“全部坐标”的最不利计划里价格最高的 d 个坐标出发做交换：换入价格最高的未选坐标，换出价格最低的已选坐标，直到不再改进。
- **停止**：按最小界的顺序展开节点，当所有未展开节点的界都不低于 $U - \tau$ 时停止。$\tau = 0$ 是精确最优；第 4 节说明比夹逼宽度小的差别没有统计意义，τ 可以取那个宽度。

D	N	d	子集数	搜索的 LP 数	时间	承诺界	最优值	局部搜索（LP 数）
12	30	3	220	270	1 s	0.49	0.87	0.87（9）
20	30	3	1140	662	3 s	0.45	0.78	0.91（13）
30	30	4	27405	826	6 s	0.31	0.45	0.47（13）
30	40	3	4060	1473	12 s	0.43	0.75	0.76（14）
30	50	3	4060	6094	51 s	0.45	0.98	1.05（13）
50	40	3	19600	9575	85 s	0.40	0.80	0.83（12）
100	40	3	161700	164934	1936 s	0.37	0.86	0.96（15）

表 6: 分支定界（`dev_checks.py --search`），$\tau = 0$，hinge，$\rho_0 + \rho_1 = 0.6$，数值以 V 的尺度给出。LP 数包括局部搜索；每个节点的 LP 比单个子集的匹配 LP 多 $|C| + 1$ 个变量。

看到了什么（表 6）。

1. **总是精确，有时省很多。**$d = 4$ 时只解了 826 个线性规划，子集有 27405 个；$D = 50$ 时解了 9575 个、85 秒，同一个例子上 HiGHS 解紧凑程序式 (4)要 235 秒（表 5）；$D = 30$、$N = 40$ 时 12 秒，HiGHS 26 秒，枚举 22 秒。$D = 100$ 时 HiGHS 600 秒没解完（只知道 ≤ 0.88），分支定界 32 分钟给出了精确最优值 0.86。

2. $d = 3$ **时省不了多少。**线性规划的个数是子集数的 0.3–1.5 倍；$D = 12$、$N = 50$、$D = 100$ 三个例子里都超过了子集数（$D = 100$：164934 对 161700）。根节点的承诺界只有最优值的 43%–70%，树要很深才剪得动；每个节点的线性规划也比单个子集的大。所以这个搜索是“带证书的枚举”，在 d 大、半径大或允许容差时才明显快。

3. **局部搜索是好起点，不是答案。**它只用 9–15 个线性规划，离最优值差 0–0.10，只在最小的例子上命中。

4. $D = 100$ **的最优子集全是噪声坐标**（47、75、98，信号在坐标 1–4）：半径 0.6 对 $d = 3$ 不诚实，在 100 个坐标里总能挑出偶然“可分”的三个。这正是第 4 节的现象；精确求解一个不诚实的目标没有意义。

5. **容差很有用。**$D = 50$ 的例子上，$\tau = 0.05$ 和 0.1 把线性规划降到 4697 和 2113 个（46 秒、24 秒），都找到了最优子集。半径大时搜索小得多：$\rho_0 + \rho_1 = 2.0$ 时精确搜索只要 864 个线性规划（12 秒），$\tau = 0.1$ 时 256 个，找到的值 1.678 比最优 1.671 只差 0.007（`dev_checks.py --tolerance`）。

下一步。把分支定界放进核心包替代外逼近（一般损失下节点是凸规划）；节点上复用父节点的计划做热启动；以及一个计算版的恢复结果：

猜想 7 (有间隔时搜索很小)**.** 【猜想】在命题 14的间隔条件下，排除某个真坐标的节点，其界以高概率超过 $U - \tau$，因此分支定界展开的节点数关于 D 是多项式的。

3.6 试过但不够的路

(a) 外逼近配旧版切线割或比值割：小例子上都等于枚举（表 3）。(b) 用已评估的计划给其他子集定界：比比值割强，但它只用旧计划，并且要对每个子集逐一算界，没有树结构可以剪枝。(c) 把随机化选择的值当下界：在表 10的所有例子上都低于承诺界。

4 方向 A：选择让稳健检验变“诚实”（主线）

4.1 现象

两类同分布时，正确的稳健值是 2（不可分）。可是半径固定为 0.6 时，表 7里 $V([D])$ 在 $D = 50$ 时只有 0.03；20 维检查里全部 20 个坐标的 V 只有约 0.10（表 8）。也就是说，**稳健检验宣称两个相同的分布几乎完全可分。**原因：高维时经验点彼此孤立，每个跨类点对都很贵，对手撮合不起来。只选少数坐标能缓解，但“在很多子集里挑最好的”本身也是乐观的。**半径不随维数调整，证书就不诚实。**

D	1	2	3	5	10	20	50
$V([D])$	1.98	1.66	1.17	0.59	0.21	0.09	0.03
$\min_{\lvert S\rvert=2} V(S)$	–	1.66	1.65	1.53	1.39	1.40	–

表 7: hinge，两类都是 $N(0, I_D)$，$n_0 = n_1 = 15$，$\rho_0 + \rho_1 = 0.6$，五次抽样平均（`dev_checks.py --noise`）。正确值都是 2。

4.2 想法

半径应该是选中维数 d 的函数，按经验分布的 $\mathcal{W}_1$ 收敛速度取 $\rho(d) \asymp d\,n^{-1/d}$，而不是常数。这样有三个好处：

1. 证书在**选择之后**仍然有效，不需要多重比较修正，因为覆盖事件对所有子集同时成立；
2. 证书不会低于 Bayes 风险，虚假可分消失；
3. 用证书本身来选 d，半径就是复杂度惩罚，和按“经验风险加复杂度”选模型是同一个思路 [1]。

总体对象：真分布 $\mathbb{P}_0, \mathbb{P}_1$，真风险 $R_{\text{true}}(f) = \mathbb{E}_{\mathbb{P}_0}\ell(-f) + \mathbb{E}_{\mathbb{P}_1}\ell(f)$，总体稳健值 $V_{\text{pop}}(S; r) = 2 - \inf\{D_\ell(Q_0, Q_1) : \mathcal{W}_1(\mathbb{P}_k[S], Q_k) \le r_k\}$，以及 $B_S = V_{\text{pop}}(S; 0)$。$B_S$ 就是只看坐标 S 的 Bayes 风险；hinge 下 $B_S = 2(1 - \mathrm{TV}(\mathbb{P}_0[S], \mathbb{P}_1[S]))$，是最优检验两类错误率之和的两倍。$V(S; \rho)$ 表示半径为 ρ 的经验稳健值。除命题 10外，本节的结论对一般损失成立。

4.3 可能的定理

引理 8 (夹逼)**.** 【已证】若 $\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) \le \varepsilon_k \le \rho_k$，则 $B_S \le V_{\text{pop}}(S; \rho - \varepsilon) \le V(S; \rho) \le V_{\text{pop}}(S; \rho + \varepsilon)$。

为什么：三角不等式让三个球一个套一个，而稳健值随球增大而增大。

命题 9 (检测器的证书)**.** 【已证】设 (g, a, λ) 解式 (4)，f 是它按式 (5) 的延拓，$f < 0$ 时判 1 类。对任意有一阶矩的 $\mathbb{P}_0, \mathbb{P}_1$，

$$\mathbb{P}_0(f < 0) + \mathbb{P}_1(f \ge 0) \le R_{\text{true}}(f) \le V(S) + \sum_{k=0}^{1} \lambda_k \big(\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) - \rho_k\big).$$

为什么：第一个不等式是因为 $\ell \ge 1$ 在 $[0, \infty)$ 上。包络 E_k 控制 k 类的损失，是 λ_k-Lipschitz 的，在样本点上不超过 $a^{(k)}$；用 Kantorovich–Rubinstein 对偶即可。**含义：**只要半径盖住了真实的 $\mathcal{W}_1$ 误差，证书就有效；盖不住，就按价格 λ_k 线性变差。

命题 10 (半径下界，hinge)**.** 【已证】设 $\mathbb{P}_0 = \mathbb{P}_1$，在 $|S| = d$ 上的投影密度不超过 M。以至少 $1 - e^{-n_0/8}$ 的概率，对每个 $c \in (0, 1)$，

$$V(S) \ge 2 - c \implies \rho_0 + \rho_1 \ge (1 - c)\,\frac{d}{4e}\,(4M n_1)^{-1/d}.$$

为什么：看每个 0 类点到最近 1 类点的 ℓ_1 距离。n_1 个 ℓ_1 球的体积乘 M 很小，所以至少一半的 0 类点离 1 类很远（Hoeffding 不等式）。要让 $V \ge 2 - c$，大部分质量都得被撮合，远点的撮合代价就压出了下界。**含义：**想避免虚假可分，半径至少要是 $d\,n^{-1/d}$ 量级。

引理 11 (一致覆盖)**.** 【草证】设 $\mathbb{P}_0, \mathbb{P}_1$ 支撑在 $[0, 1]^D$，$3 \le d \le D$，$\delta \in (0, 1)$。以至少 $1 - \delta$ 的概率，对 $k = 0, 1$ 和所有 $|S| \le d$，

$$\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) \le \varepsilon_k := c\,d\,n_k^{-1/d} + d\sqrt{\frac{d\log(eD/d) + \log(2/\delta)}{2n_k}},$$

常数 $c \le 9$。$d = 1, 2$ 时第一项换成 $n^{-1/2}$ 和 $n^{-1/2}\log n$ 量级 [7]。

为什么：三步：把空间切成越来越细的小方块，得到期望的界 [25]；换掉一个样本只让 $\mathcal{W}_1$ 变化 d/n，所以集中在期望附近 [13]；再对两类和 $\binom{D}{d} \le (eD/d)^d$ 个子集取并。

定理 12 (诚实选择)**.** 【在引理 11 下已证】取 $\rho_k \ge \varepsilon_k$。以至少 $1-\delta$ 的概率，对所有 $|S| \le d$ 同时有：(a) $B_S \le V(S;\rho) \le V_{\mathrm{pop}}(S;2\rho)$；(b) 在 S 上拟合的检测器满足 $\mathbb{P}_0(f_S < 0) + \mathbb{P}_1(f_S \ge 0) \le R_{\mathrm{true}}(f_S) \le V(S;\rho)$。因此选出来的 $\widehat{S}$ 和它的检测器 $\widehat{f}$ 满足

$$\mathbb{P}_0(\widehat{f} < 0) + \mathbb{P}_1(\widehat{f} \ge 0) \le R_{\mathrm{true}}(\widehat{f}) \le V(\widehat{S};\rho) \le \min_{|S| \le d} V_{\mathrm{pop}}(S;2\rho).$$

只优化到误差 τ 时，右端加 τ。

为什么：在覆盖事件上，夹逼引理给 (a)（$\rho + \varepsilon \le 2\rho$），检测器证书给 (b)。

三层意思：证书在选择后无需修正就有效，而且对每个 S 都有效，所以优化误差只影响链条的右端；证书不会声称比 Bayes 风险更好，消除了虚假可分；把半径加倍后它是准确的。由命题 10，$d\,n^{-1/d}$ 的阶不能再降。第一层意思对计算很重要：第 3.5 节的容差 τ 不会让证书失效，只让右端松 τ。

推论 13 (用证书选 d)**.** 【在引理 11 下已证】对每个 $d \le d_{\max}$ 取水平 $\delta/d_{\max}$ 的半径 $\rho(d)$，在所有 $d \le d_{\max}$、$|S| \le d$ 上最小化 $V(S;\rho(d))$，得到 $(\widehat{d}, \widehat{S})$。以至少 $1-\delta$ 的概率，$R_{\mathrm{true}}(\widehat{f}) \le V(\widehat{S};\rho(\widehat{d})) \le \min_d \min_{|S| \le d} V_{\mathrm{pop}}(S;2\rho(d))$。

命题 14 (恢复真坐标)**.** 【在引理 11 下已证】设 $|S^\star| = s$，且对所有 $|S| = s$、$S \ne S^\star$ 有间隔 $V_{\mathrm{pop}}(S;\rho) \ge V_{\mathrm{pop}}(S^\star;\rho) + \gamma$。若 $\varepsilon_k \le \eta\rho_k$ 且 $4\eta/(1-\eta) < \gamma$，则以至少 $1-\delta$ 的概率，预算 s 下的选择恰好返回 $S^\star$。

为什么：$t \mapsto V_{\mathrm{pop}}(S;t\rho)$ 凹、不减、取值在 $[0,2]$，所以在 $[1-\eta, 1+\eta]$ 上斜率不超过 $2/(1-\eta)$；再用夹逼。样本量需求约为 $(Cs/\eta\rho)^s + s^3\log(eD/s)/(\eta\rho)^2$：**对选中维数是指数的，对环境维数只是对数的**，和投影检验的功效分析一致 [24, 23]。

速率的两个例子（hinge）：若 $\mathbb{P}_0[S], \mathbb{P}_1[S]$ 的支撑相距 Δ，则 $V_{\mathrm{pop}}(S;r) \le 2(r_0 + r_1)/\Delta$；若一维上 $\mathbb{P}_0 = U[0,1]$、$\mathbb{P}_1 = U[1,2]$，则 $V_{\mathrm{pop}}(S;r) = 2\sqrt{r_0 + r_1}$。取 $\rho \approx \varepsilon$，证书误差分别约为 $s\,n^{-1/s}/\Delta$ 和 $(s\,n^{-1/s})^{1/2}$；环境维数只通过 $\log(eD/s)$ 进入，而用全部坐标需要 $D\,n^{-1/D}$ 的半径。“选一个投影让两样本距离最大”的思路见 [15, 24, 17, 18, 23]；这里的距离是“被运输攻击之后的散度”，它的值就是检验风险的证书。

4.4 20 维验证（实验 1、2）

设计。 $D = 20$，每类 $n \in \{25, 50, 100\}$，hinge 损失。

- **实验 1（零假设）**：两类都是 $N(0, I_{20})$。对每个 $d \in \{1, 2, 3, 20\}$ 和每个子集 S，算“所需半径”：使 $V(S) \ge 1.92$（即至少撮合 96% 质量）的最小 $\rho_0 + \rho_1$。$\rho_h(d, n)$ 取为 40 个开发种子上“所有子集中最大所需半径”的 95% 分位数，冻结后在 40 个新种子上确认。
- **实验 2（信号）**：1 类在前两个坐标上平移 1.0（在开发种子上从 $\{1.0, 1.5\}$ 选出）。这对坐标的 Bayes hinge 风险 0.959，Bayes 总错误 0.480。半径取固定 0.6 或 $\{0.25, 0.5, 1, 2\} \times \rho_h(d, n)$。在每类 20000 个测试点上算检测器的真实 hinge 风险；“有效”指测试 hinge 不超过证书加两倍 Monte Carlo 标准误。

看到了什么。

d	ρ_h（$n = 25/50/100$）	对数斜率	虚假可分率 @ρ_h	虚假可分率 @0.6	最好的 V@0.6
1	0.66 / 0.47 / 0.27	-0.67	0.12 / 0.05 / 0.12	0.17 / 0.00 / 0.00	1.96 / 2.00 / 2.00
2	1.28 / 0.90 / 0.60	-0.53	0.07 / 0.07 / 0.07	1.00 / 1.00 / 0.07	1.57 / 1.83 / 1.97
3	1.97 / 1.46 / 1.08	-0.40	0.07 / 0.07 / 0.07	1.00 / 1.00 / 1.00	1.03 / 1.29 / 1.52
20	17.3 / 16.0 / 15.1	-0.07	0.03 / 0.12 / 0.12	1.00 / 1.00 / 1.00	0.10 / 0.10 / 0.11

表 8: 实验 1（两类同分布，40 个确认种子）。斜率是“最大所需半径”对 n 的双对数斜率，理论值为 $-1/2, -1/2\,(\log), -1/3, -1/20$。虚假可分率 = 确认种子中存在子集的所需半径超过给定半径的比例。

半径	恢复率	证书 $V(\widehat{S})$	测试 hinge	有效率	测试总错误	按证书选 d
固定 0.6	.53/.93/1.0	1.36/1.44/1.48	1.46/1.27/1.21	.33/.93/1.0	.62/.51/.49	全选 3
$0.25\rho_h$	.28/.68/.93	1.05/1.06/1.05	1.59/1.42/1.30	0/0/0	.72/.61/.55	全选 3
$0.5\rho_h$	.53/.90/.97	1.39/1.32/1.26	1.46/1.27/1.20	.40/.70/.82	.62/.52/.50	几乎全选 3
ρ_h	.68/.97/1.0	1.76/1.60/1.49	1.47/1.29/1.21	.97/1.0/1.0	.58/.49/.49	$n \geq 50$：90–95% 选 2
$2\rho_h$	1.0/1.0/1.0	2.00/1.93/1.77	1.97/1.58/1.34	1.0/1.0/1.0	.98/.61/.48	62–97% 选 1

表 9: 实验 2，$d = 2$（真实大小），每格三个数依次对应 $n = 25/50/100$。Bayes hinge 风险 0.959，Bayes 总错误 0.480。最后一列是推论 13在 $d \in \{1, 2, 3\}$ 中按证书选出的 d。

1. **维数效应很清楚。**$n = 100$ 时 $\rho_h = 0.27, 0.60, 1.08, 15.1$（$d = 1, 2, 3, 20$）。用全部 20 个坐标需要半径 15 才诚实，这时什么都检测不出来；选择把它降到 $O(1)$。斜率随 d 变平，方向与 $n^{-1/d}$ 一致；$d = 1$ 比 $-1/2$ 更陡，是因为只需撮合 96% 质量（可以丢掉尾部），加上样本量小。

2. **固定半径会虚假可分。**半径 0.6 下，$d = 3$ 和 $d = 20$ 在每个种子上都“证明”了两个相同的分布可分，$d = 20$ 时证书只有 0.10。在 ρ_h 下，确认集的虚假可分率是 3%–12%（目标 5%，40 次抽样的标准误约 3.4%）。

3. **命题 10的下界从未被违反，但很松**：比最坏子集的所需半径小约 5 倍（$d = 20$）到 230–370 倍（$d = 1$），常数没有优化。

4. **半径太小，证书无效，而且选得更差。**$0.25\rho_h$ 时证书约 1.05，测试 hinge 1.30–1.59，有效率为 0；恢复率也更低（$n = 25$ 时 0.28 对 0.68），测试总错误更高（$n = 100$ 时 0.55 对 0.49）。稳健半径同时也是正则化。

5. **ρ_h 下证书有效但偏松。**证书 1.76/1.60/1.49，测试 hinge 1.47/1.29/1.21，差 0.27–0.31；而 $n = 100$ 时检测器的测试总错误 0.485 已接近 Bayes 的 0.480。**松的是证书，不是检测器。**

6. **$2\rho_h$ 过度保守。**恢复率 100%，但 $n = 25$ 时证书 ≈ 2，检测器几乎是常数（总错误 0.98）。

7. **选 d。**半径不够大（固定 0.6、$0.25\rho_h$、$0.5\rho_h$）时，证书总是偏向最大的 $d = 3$，证书几乎全部无效：惩罚不够，加坐标总是“更好”。在 ρ_h 下，$n \geq 50$ 时 90%–95% 选对 $d = 2$，证书全部有效；$n = 25$ 时一半选 $d = 1$（信号相对半径太弱）。$2\rho_h$ 惩罚过度，偏向 $d = 1$。所以半径的**形状**（随 d 增长）和**水平**（倍数）都要对。

4.5 问题与下一步

- ρ_h **的标定用到了已知的零分布** $N(0,I)$，实际中不知道。下一步：数据驱动标定，例如把两类合并后随机重分标签，或在每类内部随机对半分，测所需半径的分位数；这正是同分布零假设下的量。
- **证书松约 0.3。**来源是定理右端的 $V_{\mathrm{pop}}(S;2\rho)$。可能的收紧：命题 9里 $\lambda_k(\mathcal{W}_1-\rho_k)$ 一项在半径有富余时为负，可以用估计的 $\mathcal{W}_1$ 扣回一部分；或者改用受限检测器类。
- **锐利半径**：半径在 $\frac{d}{4e}(4Mn)^{-1/d}$ 和 $c\,d\,n^{-1/d}+d^{3/2}\sqrt{\log(eD/d)/n}$ 之间。$\log(eD/d)$ 项是否必要?
- **受限检测器**：$n^{-1/d}$ 是任意可测检测器的代价（它能记住孤立点）。线性或核检测器按 [8] 的分析，半径可能只需 $\sqrt{d\log(eD/d)/n}$。

猜想 15 (诚实松弛)**.** 【猜想】给每个加权度量配上让它诚实的半径（权重 $\zeta_m=d/D$ 时，小尺度下它像 D 维立方体一样难以覆盖），承诺界相对最好的稀疏选择的改进就不会超过夹逼宽度。那么第 3.3 节的间隙只是一个统计假象。

5 方向 B：随机化选择（探索）

博弈。本节用 hinge，$\rho=\rho_0+\rho_1$，$V_S(r)=2m_S(r)$。防守方按分布 p 随机抽一个 $|S|\le d$ 和检测器 $f\in\mathcal{F}_S$；对手知道 p 但不知道抽签结果，选 $(Q_0,Q_1)\in\mathcal{P}_0\times\mathcal{P}_1$。记防守方最好的最坏期望风险为 $\mathrm{OPT}_{\mathrm{rand}}\le\mathrm{OPT}=\min_{|S|\le d}V(S)$。对抗分类里随机化防守的类似想法见 [19, 14, 10]。

引理 16 (代价可分)**.** 【已证】攻击在坐标 m 上的代价 $r_m=\sum_k\int|x[m]-y[m]|\,d\gamma_k$ 满足 $\sum_m r_m\le\rho$，且它在 S 上的投影代价不超过 $r(S)=\sum_{m\in S}r_m$。

由命题 3，每个价格 λ 和见证 h 给出 S 上的一个检测器，它在投影代价为 r 的攻击下风险至多 $A+\Lambda r$，$A=2(1-\beta_\lambda)$，$\Lambda=2\lambda$；$V_S(r)$ 是这些直线的下包络。

定理 17 (随机化可达值)**.** 【已证】对有限的直线族 $T=\{(S_t,A_t,\Lambda_t)\}$，最优混合的最坏期望风险至多

$$W_T=\min_{p}\max_{m\in[D]}\Big\{\sum_t p_tA_t+\rho\sum_{t:\,m\in S_t}p_t\Lambda_t\Big\}=\max_{r\ge0,\ \mathbf{1}^\top r\le\rho}\ \min_{t\in T}\big\{A_t+\Lambda_t r(S_t)\big\}. \tag{6}$$

T 取遍所有直线时 W_T 降到 $\overline{W}=\max_r\min_{|S|\le d}V_S(r(S))$，且 $\mathrm{OPT}_{\mathrm{rand}}\le\overline{W}\le\mathrm{OPT}$。

为什么：混合的期望风险关于攻击代价向量 r 是线性的、斜率非负，所以最坏攻击把全部预算砸在一个坐标上（$r=\rho e_m$），这给出左边；线性规划对偶给出等式。$\sum_{t:\,m\in S_t}p_t\Lambda_t$ 是坐标 m 的“价格暴露”：对手打最暴露的坐标，混合把暴露摊开，固定选择则把自己的 d 个坐标完全暴露。

定理 18 (不相交候选：预算均分到同一水平)**.** 【已证】若候选子集两两不交（特别是 $d=1$），则 $\mathrm{OPT}_{\mathrm{rand}}=\overline{W}=\max\{t:\sum_S V_S^{-1}(t)\le\rho\}$，其中 $V_S^{-1}(t)=\inf\{r:V_S(r)\ge t\}$。

为什么：上界来自定理 17；对手最优的预算分配让各候选的值相等，像往几个容器里注水到同一水位。下界：在每个候选块上取对应预算的最不利分布对，各块独立移动，代价按块相加，所以合起来仍在预算内，而每个投影都是它自己的最不利分布对。例子：每类一个点 $(0,0)$ 和 $(1,1)$，$\rho=1/2$，$d=1$：固定选择的值是 1，均分给 $r^\star=(1/4,1/4)$、值 $1/2$。

命题 19 (对抽样误差无增益)**.** 【已证】在定理 12的设定下，混合的证书是各固定证书的平均 $\sum_t p_t(A_t + \Lambda_t \sum_k \varepsilon_k)$，不小于其中最好的一个。

为什么：抽样误差不会“分摊预算”：覆盖事件允许每个投影同时偏离满半径。

数据	d	固定 $\min_S V(S)$	随机化 W_T	均分值	承诺界	测试 hinge：固定/混合
$D = 10$，$N = 30$	1	1.78	1.24	–	1.53	–
$D = 10$，$N = 30$	2	1.40	0.59	–	0.89	–
$D = 15$，$N = 30$	2	1.12	0.41	–	0.75	–
$D = 12$，$N = 30$	3	0.87	0.32	–	0.49	–
20 维，$n = 25$	1	1.765	1.200	1.189	1.371	1.475 / 1.915
20 维，$n = 25$	2	1.394	0.446	–	0.737	1.527 / 1.981

表 10: 前四行是表 5的例子（`dev_checks.py --random`）；后两行是 20 维实验 4（信号数据，5 个种子平均）。$\rho_0 + \rho_1 = 0.6$，W_T 用每个 V_S 在 23 个半径处的切线。最后一列：直接从真分布抽测试数据时，固定最优检测器与最优混合的 hinge 风险。

看到了什么。对抗意义下随机化的收益很大：20 维 $d = 2$ 时 $W_T = 0.45$，固定最优是 1.39，连承诺界 0.74 都比它差。$d = 1$ 时 $W_T = 1.200$ 略高于精确的均分值 1.189（有限条直线的误差），符合定理 18。但**面对抽样误差时混合更差**：测试 hinge 1.92/1.98 对固定的 1.48/1.53。原因是最优混合要把价格暴露摊到很多坐标上，它只把 11%–36%（$d = 1$）和 18%–26%（$d = 2$）的权重放在含信号坐标的子集上。这正是命题 19说的：随机化只对“先承诺、共用一笔预算的对手”有用，例如巡检、筛查、传感器调度，保证也只是对抛硬币取平均。

猜想 20 (紧性)**.** 【猜想】候选为所有大小 $d \geq 2$ 的子集时，某些例子上 $\mathrm{OPT}_{\mathrm{rand}} < \overline{W}$；若最优预算下各子集的最不利分布对能取成同一对高维分布的投影，则等号成立 [22]。

计算 $\overline{W}$ 可以逐个加入子集：给定预算向量 r，下一个子集是 $\min_{|S| \leq d} V_S(r(S))$ 的解，也就是把式 (4)中的 $\rho\lambda$ 换成 $r^\top w$。

6 优先级

1. **方向 A（诚实半径）**故事最强、成本最低：在高维里，正是选择让 Wasserstein 稳健检验变得有效。20 维检查支持了三点：随维数增长的半径消除虚假可分；它同时改善恢复；用证书选 d 在半径水平正确时选对。下一步：数据驱动的半径标定（置换），收紧证书，$d \leq 2$ 的显式常数，$D = 100$ 的恢复实验，与核变量选择 [23] 对比。
2. **计算**：用承诺界的分支定界替代外逼近，容差取夹逼宽度；验证猜想 7。$D = 20$ 时枚举就够。
3. **方向 B（随机化）**：探索性。两个定理已证；下一步是猜想 20，以及一个有战略对手的应用。

参考文献

[1] Peter L. Bartlett, Stéphane Boucheron, and Gábor Lugosi. Model selection and error estimation. *Machine Learning*, 48:85–113, 2002.

结果	状态
命题 1：散度形式（一般损失）	已证
命题 2、3：匹配、见证形式（hinge）	已证，数值核对过
命题 4、5：稀疏价格、承诺界（一般损失）	已证；承诺界在 hinge 上数值核对过
命题 6：NP 难（一般损失）	已证
引理 8，命题 9、10	已证；10 在 20 维上核对过
引理 11：一致覆盖	标准，草证
定理 12，推论 13，命题 14	在引理 11 下已证；20 维上验证了现象
定理 17、18，命题 19	已证；20 维上核对过
猜想 7、15、20	开放

表 11: 各结果的状态。

[2] Laetitia Chapel, Mokhtar Z. Alaya, and Gilles Gasso. Partial optimal transport with applications on positive-unlabeled learning. In *Advances in Neural Information Processing Systems*, volume 33, 2020.

[3] Carlos Cotta and Pablo Moscato. The k-feature set problem is W[2]-complete. *Journal of Computer and System Sciences*, 67(4):686–690, 2003.

[4] Scott Davies and Stuart Russell. NP-completeness of searches for smallest possible feature sets. In *AAAI Fall Symposium on Relevance*, 1994.

[5] Richard M. Dudley. *Real Analysis and Probability*. Cambridge University Press, 2nd edition, 2002.

[6] Alessio Figalli. The optimal partial transport problem. *Archive for Rational Mechanics and Analysis*, 195(2):533–560, 2010.

[7] Nicolas Fournier and Arnaud Guillin. On the rate of convergence in Wasserstein distance of the empirical measure. *Probability Theory and Related Fields*, 162:707–738, 2015.

[8] Rui Gao. Finite-sample guarantees for Wasserstein distributionally robust optimization: Breaking the curse of dimensionality. *Operations Research*, 71(6):2291–2306, 2023.

[9] Rui Gao, Liyan Xie, Yao Xie, and Huan Xu. Robust hypothesis testing using Wasserstein uncertainty sets. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[10] Amir Globerson and Sam Roweis. Nightmare at test time: Robust learning by feature deletion. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 353–360, 2006.

[11] Peter J. Huber. A robust version of the probability ratio test. *The Annals of Mathematical Statistics*, 36(6):1753–1758, 1965.

[12] Peter J. Huber and Volker Strassen. Minimax tests and the Neyman–Pearson lemma for capacities. *The Annals of Statistics*, 1(2):251–263, 1973.

[13] Colin McDiarmid. On the method of bounded differences. In *Surveys in Combinatorics*, volume 141 of *London Mathematical Society Lecture Note Series*, pages 148–188. Cambridge University Press, 1989.

[14] Laurent Meunier, Meyer Scetbon, Rafael Pinot, Jamal Atif, and Yann Chevaleyre. Mixed Nash equilibria in the adversarial examples game. In *Proceedings of the 38th International Conference on Machine Learning*, pages 7677–7687, 2021.

[15] Jonas Mueller and Tommi Jaakkola. Principal differences analysis: Interpretable characterization of differences between distributions. In *Advances in Neural Information Processing Systems*, volume 28, 2015.

[16] XuanLong Nguyen, Martin J. Wainwright, and Michael I. Jordan. On surrogate loss functions and f-divergences. *The Annals of Statistics*, 37(2):876–904, 2009.

[17] François-Pierre Paty and Marco Cuturi. Subspace robust Wasserstein distances. In *Proceedings of the 36th International Conference on Machine Learning*, pages 5072–5081, 2019.

[18] Mathis Petrovich, Chao Liang, Ryoma Sato, Yanbin Liu, Yao-Hung Hubert Tsai, Linchao Zhu, Yi Yang, Ruslan Salakhutdinov, and Makoto Yamada. Feature-robust optimal transport for high-dimensional data. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, volume 13717 of *Lecture Notes in Computer Science*, pages 291–307, 2022.

[19] Rafael Pinot, Raphael Ettedgui, Geovani Rizk, Yann Chevaleyre, and Jamal Atif. Randomization matters. How to defend against strong adversarial attacks. In *Proceedings of the 37th International Conference on Machine Learning*, 2020.

[20] Mark D. Reid and Robert C. Williamson. Information, divergence and risk for binary experiments. *Journal of Machine Learning Research*, 12:731–817, 2011.

[21] Maurice Sion. On general minimax theorems. *Pacific Journal of Mathematics*, 8(1):171–176, 1958.

[22] N. N. Vorob'ev. Consistent families of measures and their extensions. *Theory of Probability and its Applications*, 7(2):147–163, 1962.

[23] Jie Wang, Santanu S. Dey, and Yao Xie. Variable selection for kernel two-sample tests, 2023. arXiv:2302.07415.

[24] Jie Wang, Rui Gao, and Yao Xie. Two-sample test using projected Wasserstein distance. In *IEEE International Symposium on Information Theory*, 2021.

[25] Jonathan Weed and Francis Bach. Sharp asymptotic and finite-sample rates of convergence of empirical measures in Wasserstein distance. *Bernoulli*, 25(4A):2620–2648, 2019.

[26] Liyan Xie, Rui Gao, and Yao Xie. Robust hypothesis testing with Wasserstein uncertainty sets, 2021. arXiv:2105.14348.