Wasserstein 稳健检验中的变量选择：研究方向

工作笔记，非正式

怎么读。这是一份想法笔记，不是论文。每个结论都标了状态：【已证】表示证明完整（这里只写思路），【草证】表示是标准论证、细节未写全，【猜想】表示还没证。实验数字都来自 第 6 节的 20 维实验（`results/study20-v3`，代码 `scripts/run_study20.py`）：4 个真坐标藏在 16 个干扰坐标里，每类只有 10–50 个训练点，看检验能否分开两类、能否找到真坐标。协议沿用 Xie 等 [26]：小样本训练、新样本测试、交叉验证选半径、多次重复取平均。只做 $D = 20$。符号沿用正式笔记 `robust_coordinate_selection.pdf`，式 (1)–(9) 指正式笔记的公式。损失 ℓ 只需满足正式笔记的假设（非负、不减、凸、$\ell(0) = 1$、$t \to -\infty$ 时趋于 0）；用到 hinge 损失 $\ell(t) = (1+t)_+$ 的地方会单独说明，数值例子都用 hinge。

主线。 第 1 节回答读正式笔记时的几个疑问。第 2 节给出 hinge 下的匹配形式，它让计算和直觉都变简单。第 3 节是计算：外逼近为什么几乎要枚举所有子集，以及把选择问题改写成“稀疏的坐标价格”之后得到的精确搜索。第 4 节和第 5 节是两个研究方向：让半径随选中维数变化，以及随机化选择。第 6 节是 20 维实验。

1　读正式笔记时的几个疑问

1.1　理论对一般损失成立

损失只通过一个二元函数进入正式笔记：

$$\psi(a,b) = \inf_{t\in\mathbb{R}} \{a\ell(-t) + b\ell(t)\},$$

即一个位置上有类 0 质量 a、类 1 质量 b 时，最好的分数能达到的最小损失。引理 2.1、命题 2.2–2.4 和附录的证明只用到 ℓ 的凸性以及 ψ 凹、不减、一次齐次，所以对每个满足假设的 ℓ 都成立。hinge 只出现在代码里：此时 ψ 分段线性，式 (3)(4) 都是线性规划。

损失	$\ell(t)$	$\psi(a,b)$	$2 - \sum\psi$
hinge	$(1+t)_+$	$2\min(a,b)$	$2\,\mathrm{TV}$
指数	e^t	$2\sqrt{ab}$	$\sum(\sqrt{a}-\sqrt{b})^2$（Hellinger 距离平方的两倍）
logistic	$\log_2(1+e^t)$	$a\log_2\frac{a+b}{a} + b\log_2\frac{a+b}{b}$	两倍的 Jensen–Shannon 散度

表 1: 三种常见损失。最后一列把 ψ 用在两个概率分布上，得到一个散度。

最后一列给出 $V(S)$ 的一个统一读法。记 $D_\ell(Q_0,Q_1) = 2 - \int\psi(dQ_0, dQ_1)$，$\mathcal{P}_k[S] = \{Q : \mathcal{W}_1(\widehat{\mathbb{P}}_k[S], Q) \le \rho_k\}$，其中 $Q[S]$ 表示分布在坐标 S 上的投影。

命题 1 (散度形式)**.** 【已证】对任意 S，$V(S) = 2 - \min_{Q_k\in\mathcal{P}_k[S]} D_\ell(Q_0,Q_1)$。

为什么：固定 (Q_0,Q_1)，在 $\mathcal{F}_S$ 上逐点最小化风险，得到的就是 $\int\psi$；对手再挑最难分的一对。所以 $V(S)$ 是“对手在坐标 S 上能把两类拉到多近”。损失与散度的对应见 [16, 20]，最不利分布对的思想来自 Huber [11, 12]。

1.2 式 (3) 怎样推出式 (4)

两步。第一步，式 (3) 的目标里每个 ψ 都是对分数取下确界，所以目标等于

$$\inf_{g} \sum_{k,i,y} \gamma_{i,y}^{(k)}\, \ell\big((-1)^{k+1} g_y\big),$$

它对 g 凸、对 γ 线性，而可行运输构成紧凸集。Sion 极小极大定理 [21] 允许把 $\inf_g$ 提到外面，于是对手在检测器固定之后才选运输。第二步，检测器固定时，对手的问题按类分开，每类是一个线性规划：在预算 ρ_k 内搬运 $\widehat{\mathbb{P}}_k$，使损失 $y \mapsto \ell((-1)^{k+1} g_y)$ 的期望最大。它的对偶就是常见的 Wasserstein 对偶

$$\min_{\lambda_k \ge 0}\ \rho_k \lambda_k + \frac{1}{n_k} \sum_{i=1}^{n_k} \max_{y \in \mathcal{X}} \big\{ \ell((-1)^{k+1} g_y) - \lambda_k \| x_i^{(k)}[S] - y[S] \|_1 \big\}.$$

把内层的 max 记作 $a_i^{(k)}$，再对 g 取最小，就是式 (4)。

读法。 λ_k 是类 k 每单位运输距离的价格；$a_i^{(k)}$ 是源点 i 在这个价格下的最坏净损失（搬到 y 的损失减去运费）。稳健风险等于平均最坏净损失加上预算乘价格。反过来，式 (4) 每条约束的乘子就是式 (3) 的运输量，所以代码只解一个线性规划，就同时拿到检测器、$V(S)$ 和最不利运输。

1.3 式 (5) 与 Xie 等的定理 1

式 (5) 就是 Xie 等 [26] 定理 1(ii) 的区间，换成了一般损失的写法。他们研究随机化检验 $\pi \in [0,1]$（π 是判为第一类，即我们的类 0 的概率），风险是两类错误概率之和：类 0 上 $1-\pi$，类 1 上 π。hinge 损失下把分数限制在 $[-1,1]$ 不损失什么，令 $\pi = (1+g)/2$，则

$$\ell(-g) = 1 - g = 2(1-\pi), \qquad \ell(g) = 1 + g = 2\pi.$$

所以 **hinge 下的稳健风险恰好是他们的风险的两倍**，两个问题是同一个问题。他们的定理 1(i) 是样本点上的有限问题，对应式 (3)(4)；定理 1(ii) 给出样本外的区间 $l(\omega) \le \pi(\omega) \le u(\omega)$。把他们的 $l(\omega)$ 展开，$\pi(\omega) \ge l(\omega)$ 恰好是 $1 - \pi(\omega) \le \min_i\{a_i + \lambda_1 c(\omega, \widehat{\omega}_1^i)\}$，即式 (5) 的第一个不等式（$u(\omega)$ 对应第二个）。看起来不一样只是因为记号：

	Xie 等 [26]	正式笔记
两类	H_1, H_2，样本 $\widehat{\omega}_1^i, \widehat{\omega}_2^j$	类 0、类 1，样本 $x_i^{(0)}, x_j^{(1)}$
半径、距离	θ_1, θ_2，$c(\omega, \omega')$	ρ_0, ρ_1，$\|x[S] - y[S]\|_1$
检验	$\pi \in [0,1]$，损失 $1-\pi$ 和 π	分数 g，损失 $\ell(-g)$ 和 $\ell(g)$
样本外	显式区间 $[l(\omega), u(\omega)]$	包络 E_k 与条件 (5)

表 2: 记号对照。hinge 下取 $\pi = (1+g)/2$，两边逐项相同。

一般损失的有限形式（引理 2.1）来自 Gao 等 [9]，所以正式笔记引用的是两篇：引理 2.1 用 [9]，区间 (5) 用 [26]。两点插值的构造是我们为了得到一个明确的可测检测器而写的。

区间里取哪一点。区间里的每一点都达到同样的最坏风险 $V(S)$，但真实错误率可以差很多。旧版取 $\tau = \min\{1, r_0/b\}$，它偏向类 1：在类 0 锚点的另一侧（$r_0 \ge b$）直接取类 1 的分数。维数一高，新点到最近样本的距离和样本之间的距离差不多，几乎所有点都被判成类 1：20 维均值平移、每类 30 个点时，用全部坐标的测试错误率是 0.49。现在按到两个锚点的距离加权，$\tau = r_0/(r_0 + r_1)$，两类对称，同一例子降到 0.30。证明只用三角不等式 $b \le r_0 + r_1$。Xie 等在区间里用核平滑取点 [26]，那是另一种选择。

1.4 命题 2.4 在做什么；旧版的平方根从哪里来

在二元点上，$V(\mathbf{1}_S)$ 已经由引理 2.1 给出。命题 2.4 要的是另一件事：一个对**分数** $z \in [0,1]^D$ 也有定义的函数，它在二元点上等于 V，并且由关于 z 的仿射函数拼成。有了它，每评估一个子集就得到一条割，主问题 (9) 是一个混合整数线性规划。附录 C 证明“二元点上等于 V”，这一步本来就不该改变数值，它是检查这个函数确实是我们要的那个；收获在二元点之间。

这个函数天然是一个比值：

$$F(z) = \max_{(\gamma,\mu)\in\mathcal{D}} \frac{H(\gamma)}{M(\gamma) + \mu^\top z}.$$

分子是对手制造的重叠，分母是对手付出的“质量加豁免费”。比值对 z 不是仿射的，有两种办法处理：

- **旧版：平方根。**对 $b > 0$，$\max_{s\ge 0}\{2\sqrt{sH} - sb\} = H/b$（在 $s = H/b^2$ 取到，即算术–几何平均不等式）。把 (γ,μ) 整体乘以 s 不出 $\mathcal{D}$，而 H, M, μ 都随 s 线性变化，所以 $F(z) = \max_{\mathcal{D}}\{2\sqrt{H(\gamma)} - M(\gamma) - \mu^\top z\}$：每一项对 z 仿射，平方根就是这样来的。
- **新版：取倒数。**$1/F(z) = \min\{M(\gamma) + \mu^\top z : (\gamma,\mu) \in \mathcal{D},\ H(\gamma) \ge 1\}$，每一项对 z 仿射，所以 $1/F$ 是凹的。信息完全相同，但不需要平方根。

新版的割 $c_t(z) = M(\gamma^t) + (\mu^t)^\top z$ 给出 $F(z) \ge 1/c_t(z)$。因为 $t \mapsto 1/t$ 凸，这个下界处处不低于旧版的切线。在二元点上，它有一个闭式：若 $\gamma^\star$ 是 S 的最不利运输，令 $\pi_m = \max_k c_k(\gamma^\star)[m]/\rho_k$ $(m \notin S)$，则对任意 T，

$$V(T) \ \ge\ \frac{V(S)}{1 + \sum_{m\in T\setminus S} \pi_m}. \tag{1}$$

这就是比值割；旧版切线给出的是 $V(S)(1 - \sum_{m\in T\setminus S}\pi_m)$，当 $\sum_{m\in T\setminus S}\pi_m \ge 1$ 时它没有任何信息。π_m 是对手在坐标 m 上的运输量占预算的比例；S 内坐标上的运输已经计入预算，所以只对 $T \setminus S$ 收费。

2 hinge 例子：$V(S)$ 是一个带预算的匹配

本节用 hinge 损失。记 $C^m_{ij} = |x^{(0)}_i[m] - x^{(1)}_j[m]|$，$c_{ij}(S) = \sum_{m\in S} C^m_{ij}$，

$$m_S(\rho) = \max_{\pi\ge 0}\Big\{\sum_{i,j}\pi_{ij} :\ \sum_j \pi_{ij} \le \frac{1}{n_0},\ \sum_i \pi_{ij} \le \frac{1}{n_1},\ \sum_{i,j}\pi_{ij}c_{ij}(S) \le \rho\Big\}, \tag{2}$$

即在总运输预算 ρ 内最多能撮合多少跨类质量。

命题 2 (匹配形式)**.** 【已证】 hinge 损失下 $V(S) = 2\,m_S(\rho_0 + \rho_1)$。

为什么：hinge 下 $\psi = 2\min(a,b)$，所以 $V(S)/2$ 是两类在投影球里能达到的最大重叠质量。要制造重叠，必须把一个 0 类点的质量和一个 1 类点的质量搬到同一个位置，由三角不等式，两边合计至少花 $c_{ij}(S)$。反过来，沿两点连线按 $\rho_0 : \rho_1$ 的比例各走一段，就恰好花 $c_{ij}(S)$。所以**对手是一个媒人**：用预算 $\rho_0 + \rho_1$ 撮合尽可能多的跨类点对。

三个直接推论：(i) 半径只通过 $\rho_0 + \rho_1$ 起作用；(ii) S 好，当且仅当在 S 的坐标上便宜的跨类点对很少；(iii) 计算 $V(S)$ 只是一个多了一条预算约束的二分匹配，$n_0 n_1$ 个变量。核心求解器算出的 $V(S)$ 与 $2m_S$ 的最大差是 1.4×10^{-13}（`dev_checks.py --hinge`）。当 $n_0 = n_1 = n$ 时

还可以更快：令 $C(k)$ 为 k 对不相交跨类点对的最小总代价除以 n（用匈牙利算法），$C(k)$ 关于 k 凸，$m_S(\rho)$ 就是 C 的反函数（断点之间线性插值）。实验代码 `study20.py` 的 `robust_values` 这样算，一次得到所有半径上的值。这个形式对总体分布也成立：它是部分最优运输的预算形式 [6, 2]。

对偶：Lipschitz 见证函数。对 $\lambda \geq 0$，令 $\beta_\lambda(Q_0, Q_1) = \sup\{\mathbb{E}_{Q_0} h - \mathbb{E}_{Q_1} h : |h| \leq \frac{1}{2},\ h \text{ 关于} \ell_1 \text{ 是}\lambda\text{-Lipschitz}\}$，即用“有界、斜率不超过 λ”的函数能看出的两样本均值差 [5]。

命题 3 (Lipschitz 见证)**.** 【已证】 hinge 损失下

$$V(S) = 2 - 2 \max_{\lambda \geq 0} \big\{ \beta_\lambda(\widehat{\mathbb{P}}_0[S], \widehat{\mathbb{P}}_1[S]) - \lambda(\rho_0 + \rho_1) \big\},$$

并且若 (λ, h) 取到最大，检测器 $f(x) = 2h(x[S])$ 是最优的：$R(f) = V(S)$。

为什么：只对式 (2)的预算约束取对偶, 再对剩下的无预算匹配取线性规划对偶, 把对偶变量读成两类点上的函数值, 就得到 β_λ。$|2h| \leq 1$ 让 hinge 损失变成线性的, 再用 Kantorovich–Rubinstein 对偶得到风险上界 $V(S)$。

读法。稳健 hinge 检验是一个两样本统计量：见证函数可以很陡地把两个样本分开，但斜率 λ 要付 $\lambda(\rho_0 + \rho_1)$。半径决定了见证函数必须多平滑。具体构造：解式 (2)的对偶得到 (u, v, λ)，令 $h'_j = \min(v_j - \frac{1}{2}, \frac{1}{2})$，$h(\xi) = \mathrm{clip}_{[-1/2,1/2]}(\min_j\{h'_j + \lambda \|x_j^{(1)}[S] - \xi\|_1\})$，它就是实验代码里的 `witness()`。$m_S$ 关于 ρ 凹、不减，斜率等于最优价格 λ；第 5 节会用这些切线。

3 计算：从割到稀疏的坐标价格

3.1 现象：外逼近几乎要枚举所有子集

在交叉验证选出的半径上，用核心包的外逼近（比值割）解 $\min_{|S| \leq d} V(S)$，每次限时 600 秒（表 6）。$d = 2$ 时它在证明最优之前评估了 190 个子集中的 157–190 个。$d = 3, 4$ 时多数重复在限时内没有证明最优（80 次里只有 6 次，全在 $n = 10$），停下时评估了 234–405 个子集：每加一条割，主问题就是一个更大的混合整数规划，一轮比一轮慢。同样的问题，用匹配形式枚举全部子集只要 0.1–19 秒。

为什么。看式 (1)：从 S 得到的割要排除另一个子集 T，需要 $V(S)/(1 + \pi(T \setminus S)) \geq U$，即 $\pi(T \setminus S) \leq V(S)/U - 1$。$S$ 的最不利运输只为 S 上的坐标付钱，在别的坐标上常常搬得很远，π_m 通常大于 1；而好的 S 有 $V(S) \approx U$。所以**每条割基本只认得它自己那个子集。割到底假设了什么。**运输计划 γ 记的是“哪个样本的质量配到哪个目标点上”，它本身和坐标无关；和坐标有关的是它的代价 $\sum_{m \in S} c_k(\gamma)[m]$，因为检测器只看 S 上的坐标。$V(S)$ 里的对手在看到 S 之后才选计划，所以选的是在 S 的坐标上便宜的配对。比值割在 T 上的值，不超过“把这份旧计划按比例缩到 T 的预算内、其余质量留在原地”这个对手的值（附录 C.1 的构造）。真正的对手在 T 上会换一套在 T 的坐标上便宜的配对，所以 $V(T)$ 往往大得多。

例子：$D = 2$，类 0 两个点 $(0, 9)$、$(9, 0)$，类 1 一个点 $(0, 0)$，$\rho_0 = \rho_1 = 0.15$。只看坐标 1 时，$(0, 0)$ 和 $(0, 9)$ 已经重合，对手把它们配在一起，不花预算，$V(\{1\}) = 1.07$；只看坐标 2 时重合的是 $(0, 0)$ 和 $(9, 0)$，最优配对换了，$V(\{2\}) = 1.07$。旧配对 $(0, 0) \leftrightarrow (0, 9)$ 在坐标 2 上相距 9：要让一半质量重合，坐标 2 上的运输量至少是 4.5，而每类预算只有 0.15，所以 $\pi_2 \geq 15$（求解器给出的计划是 31），割只给出 $V(\{2\}) \geq 0.03$。在原空间里两个对手几乎都没有移动点；变的是“让哪两个点在检测器眼里重合”。下面换一个写法，把“对手能不能重新配对”变成一个可以计算的量。

3.2 稀疏的坐标价格：一个精确的重写

式 (4) 里 $\lambda_k\|x[S]-y[S]\|_1=\sum_m w_{km}|x[m]-y[m]|$,其中 $w_k=\lambda_k\mathbf{1}_S$。把 $w=(w_0,w_1)\in\mathbb{R}_+^{2\times D}$ 当成自由变量：w_{km} 是防守方对“类 k 在坐标 m 上搬运”收的单价。记 $\operatorname{supp} w=\{m: w_{0m}+w_{1m}>0\}$，令 Γ 为行和满足 $\sum_y \gamma^{(k)}_{i,y}=1/n_k$ 的运输（**没有**预算约束），并定义

$$G(w)=\max_{\gamma\in\Gamma}\Big\{H(\gamma)-\sum_{k=0}^{1} w_k^\top c_k(\gamma)\Big\}.$$

$G(w)$ 是“对手不受预算限制、但每搬一单位要按价格 w 付钱”时能得到的最大净收益。

命题 4 (稀疏价格)**.** 【已证】对任意 S，$V(S)=\min\{\rho_0\|w_0\|_\infty+\rho_1\|w_1\|_\infty+G(w):\ w\ge 0,\ \operatorname{supp} w\subseteq S\}$。因此

$$\min_{|S|\le d} V(S)=\min_{w\ge 0,\ |\operatorname{supp} w|\le d}\ \rho_0\|w_0\|_\infty+\rho_1\|w_1\|_\infty+G(w). \tag{3}$$

G 凸、不增；若 γ 在 w 处取到 G 的最大值，则 $-c_k(\gamma)$ 是 G 关于 w_k 的次梯度。

为什么：和 (3) → (4) 一样用 Sion 定理交换 $\max_\gamma$ 与 $\inf_g$；交换后每一行的最大值取在一个目标上，于是 $G(w)$ 等于式 (4) 把 $\lambda_k\|x[S]-y[S]\|_1$ 换成 $\sum_m w_{km}|x[m]-y[m]|$、只对 (g,a) 取最小的值。取 $w_k=\lambda_k\mathbf{1}_S$ 再对 λ 取最小，就是式 (4)。反过来，任意 $\operatorname{supp} w\subseteq S$ 的 w 满足 $w_k\le\|w_k\|_\infty\mathbf{1}_S$，而 G 不增，所以把 w_k 抬到 $\|w_k\|_\infty\mathbf{1}_S$ 不会更差。G 是一族 w 的仿射函数的最大值，所以凸，次梯度由取到最大值的那一项给出。

读法。 式 (3)长得像稀疏回归：G 是损失，$\rho\|w\|_\infty$ 是罚项，$|\operatorname{supp} w|\le d$ 是稀疏约束。不同的是罚项用 ℓ_∞：一个价格 λ_k 管住所有选中的坐标，再加一个价格不超过 λ_k 的坐标，罚项不变。所以只有稀疏约束阻止“全选”。次梯度说的是：把坐标 m 的价格抬高一点，风险下降的速度就是对手在 m 上的运输量 $c_k(\gamma)[m]$。这正是比值割里 π_m 的来源，也是下面分支和局部搜索要用的“价格信号”。

hinge 的情形。由命题 2，hinge 下两类可以共用一个价格。令 $\rho=\rho_0+\rho_1$，$z\in\mathcal{Z}_d$，式 (3)变成一个紧凑的混合整数线性规划（值以 m 的尺度给出）：

$$\begin{aligned}\min_{z\in\mathcal{Z}_d,\,u,v,w,\lambda\ge 0}\quad & \rho\lambda+\bar u+\bar v\\ \text{s.t.}\quad & u_i+v_j+\sum_m w_m C^m_{ij}\ge 1,\qquad w_m\le\lambda,\qquad \rho w_m\le z_m,\qquad \sum_m w_m\le d\lambda,\end{aligned} \tag{4}$$

其中 $\bar u=\frac{1}{n_0}\sum_i u_i$，$\bar v=\frac{1}{n_1}\sum_j v_j$。第一条约束是式 (2)的对偶：每个跨类点对，要么由两个端点“付钱”(u_i+v_j)，要么被定价后的距离隔开。$u=\mathbf{1}$、$v=0$、$\lambda=0$ 的值是 1，所以最优时 $\rho\lambda\le 1$，$\rho w_m\le z_m$ 只在 $z_m=0$ 时起作用；最后一条约束不改变整数解，但让松弛更紧（见下一节）。

3.3 连续松弛就是“对手先承诺”

式 (3)里唯一的组合部分是罚项加稀疏约束。对单个类，函数 $\lambda\|w\|_\infty$（限制在 $|\operatorname{supp} w|\le d$）的凸包络是 $\lambda\max\{\|w\|_\infty,\|w\|_1/d\}$：集合 $\{w\ge 0:\|w\|_\infty\le 1,\|w\|_1\le d\}$ 的顶点正好是 $\mathbf{1}_S$，$|S|\le d$。记 $\operatorname{top}_d(c)$ 为向量 c 最大的 d 个分量之和。

命题 5 (承诺界)**.** 【已证】把式 (3)中两类共用的稀疏约束换成每类各自的凸包络，

$$\begin{aligned}\min_{w\ge 0}\ &\sum_{k=0}^{1}\rho_k\max\Big\{\|w_k\|_\infty,\frac{\|w_k\|_1}{d}\Big\}+G(w)\\ &=\max\big\{H(\gamma):\ \gamma\in\Gamma,\ \mathrm{top}_d\big(c_k(\gamma)\big)\le\rho_k,\ k=0,1\big\},\end{aligned}\tag{5}$$

记这个值为 L_d，则 $L_d\le\min_{|S|\le d}V(S)$。hinge 下对式 (4)做同样的事，得到它的连续松弛，值为 $2\max\{\sum_{i,j}\pi_{ij}:\pi$ 满足式 (2)的行列约束, $\mathrm{top}_d(\kappa(\pi))\le\rho_0+\rho_1\}$，其中 $\kappa_m(\pi)=\sum_{i,j}\pi_{ij}C^m_{ij}$；它介于 L_d 和 $\min_{|S|\le d}V(S)$ 之间。

为什么：单位球 $\{w\ge 0:\max(\|w\|_\infty,\|w\|_1/d)\le 1\}$ 上 $w^\top c$ 的最大值是 $\mathrm{top}_d(c)$。把 G 写成最大值，交换 $\min_w$ 和 $\max_\gamma$（Sion，Γ 紧），对 w 取最小：若 $\mathrm{top}_d(c_k(\gamma))\le\rho_k$ 结果是 0，否则是 $-\infty$。不等式也可以直接看：若 $\mathrm{top}_d(c_k(\gamma))\le\rho_k$，则 γ 在每个 $|S|\le d$ 上都满足式 (3) 的预算，所以 $H(\gamma)\le V(S)$。hinge：最优时 $\rho\lambda\le 1$，松弛里取 $z=\rho w$ 总可行，剩下的约束 $0\le w\le\lambda$、$\sum w\le d\lambda$ 就是凸包络，同样的论证给出匹配形式。把 γ 在每个目标上的两类质量配成对，得到的 π 有 $\kappa\le c_0+c_1$，所以匹配形式不小于 L_d。

下文的表格都用 hinge 的匹配形式，称为**承诺界**。

读法。 L_d 里的对手必须**先**给出一个运输计划，它要在防守方挑的任意 d 个坐标上都不超预算；真正的对手是**后手**，看到 S 之后再做计划。所以

$$\min_{|S|\le d}V(S)-L_d\ =\ \text{后手对手比先手对手多拿到的重叠.}$$

同一个数还有一个读法：由极小极大定理，L_d 等于防守方用**加权** ℓ_1 度量 $\sum_m\zeta_m|x[m]-y[m]|$（$0\le\zeta\le 1$，$\sum\zeta_m\le d$，每个坐标“看一部分”）时的最好稳健值。加权把所有坐标平均起来，跨类点对的代价向均值集中，对手找不到在稀疏投影里总能找到的那几个便宜点对。**混合坐标帮防守方**，间隙就是这个好处的大小。

20 维实验里，承诺界平均是最优值的 0.54–0.77（表 6 最后一列）。因为承诺界来自罚项的凸包络，稀疏回归里常用的强化松弛（利用二次项的那一类）在这里已经用上了，在根节点上不能再多得到什么。

3.4 困难性：对每个损失都是 NP 难

命题 6 (NP 难)**.** 【已证】设数据取值于 $\{0,1\}$，$s=\psi(1/n_0,1/n_1)>0$。存在只依赖 ℓ,n_0,n_1 的 $\bar\rho>0$，使得 $\rho_0+\rho_1<\bar\rho$ 时：$\min_{|S|\le d}V(S)<s$，当且仅当存在 $|S|\le d$ 把每个跨类点对分开（$x_i^{(0)}[S]\ne x_j^{(1)}[S]$）。后者是 k-feature-set 问题，NP 完全 [4]；按 d 参数化也难 [3]，即不能指望运行时间形如“d 的函数乘以多项式”的算法。

为什么：没分开时，某一对跨类点在 S 上重合，零代价就能把它们放到同一个位置，那里同时有 $1/n_0$ 的类 0 质量和 $1/n_1$ 的类 1 质量，所以 $V(S)\ge s$。分开时，二值数据上不同投影的 ℓ_1 距离至少是 1，所以搬到对方位置的质量，类 k 合计不超过 ρ_k。在类 0 的位置用 $\psi(a,b)\le a\ell(-T)+b\ell(T)$，在类 1 的位置把 T 换成 $-T$，得到 $V(S)\le 2\ell(-T)+(\rho_0+\rho_1)\ell(T)$。先取 T 使 $2\ell(-T)<s/2$，再取 $\bar\rho=s/(2\ell(T))$。

边际递减也帮不了贪心：0 类在 $(0,0),(1,1)$，1 类在 $(0,1),(1,0)$（异或），单个坐标都不能把任何一对分开，两个一起才行。**结论：**精确算法在最坏情况下必然是搜索。能做的是让搜索的每个节点都用上最好的界、按价格信号分支，并在统计上没有意义的差距处停下。

3.5 一个精确的搜索：分支定界

搜索树的节点是 (A, C, r)：A 中的坐标已选，C 中的坐标待定，还能再选 $r = d - |A|$ 个。节点的界是式 (5)的局部版本

$$L(A, C, r) = \max\Big\{H(\gamma) :\ \gamma \in \Gamma,\ \sum_{m \in A} c_k(\gamma)[m] + \operatorname{top}_r\big(c_k(\gamma)|_C\big) \le \rho_k,\ k = 0, 1\Big\}.$$

它对节点下的每个补全 $S = A \cup T$（$T \subseteq C$，$|T| \le r$）都是 $V(S)$ 的下界；根节点是 L_d；$r = 0$ 时就是 $V(A)$。$\operatorname{top}_r(c)$ 可以写成 $\min_t\{rt + \sum_m (c_m - t)_+\}$，所以 hinge 下用匹配形式，每个节点是一个线性规划，根节点是承诺界。三个部件：

- **分支**：选节点计划里价格 $\max_k c_k(\gamma)[m]/\rho_k$ 最高的待定坐标 m，分成“选 m”和“不选 m”两个子节点。先手对手最依赖这个坐标，先决定它，最可能让界动起来。
- **现有最好解**：从“全部坐标”的最不利计划里价格最高的 d 个坐标出发做交换：换入价格最高的未选坐标，换出价格最低的已选坐标，直到不再改进。
- **停止**：按最小界的顺序展开节点，当所有未展开节点的界都不低于 $U - \tau$ 时停止。$\tau = 0$ 是精确最优；第 4 节说明比夹逼宽度小的差别没有统计意义，τ 可以取那个宽度。

20 维上的表现。分支定界和紧凑 MILP 在全部 120 次运行中都求到了最优（表 6）。$d = 3, 4$ 时分支定界解的线性规划个数（271–3124）少于子集数（1140 或 4845），$d = 2$ 时则和子集数相当（121–226 对 190）。但一个节点是一个线性规划，比枚举里的一次匹配贵，所以它比枚举慢（1.4–39 秒对 0.1–19 秒）；HiGHS 解紧凑 MILP 用 0.8–75 秒。$D = 20$ 时枚举最快，搜索要到子集数随 D 爆炸时才有用。

下一步。把分支定界放进核心包替代外逼近（一般损失下节点是凸规划）；节点上复用父节点的计划做热启动；以及一个计算版的恢复结果：

猜想 7 (有间隔时搜索很小)**.** 【猜想】在命题 14的间隔条件下，排除某个真坐标的节点，其界以高概率超过 $U - \tau$，因此分支定界展开的节点数关于 D 是多项式的。

3.6 试过但不够的路

(a) 外逼近（切线割或比值割）：评估的子集数接近枚举，$d \ge 3$ 时还常常在限时内停不下来（表 6）。(b) 用已评估的计划给其他子集定界：比比值割强，但它只用旧计划，并且要对每个子集逐一算界，没有树结构可以剪枝。

4 方向 A：选择让稳健检验变“诚实”（主线）

4.1 现象

`null` 情形里两类同分布，任何检验的错误率都是 0.5，实验里所有方法的测试错误率也都是 0.50。但在交叉验证选出的半径上，选择给出的证书 $V(\widehat{S})/4$ 平均只有 0.22–0.25，100 次里至多 2 次不低于实际错误率（表 5）：检验声称最坏情况下也只错四分之一，实际上在掷硬币。有信号的情形也一样，证书成立的比例只有 0.05–0.57。原因有两层。交叉验证为预测选半径，选出的半径（中位数 0.14–1.8）盖不住投影后经验分布的 $\mathcal{W}_1$ 误差，命题 9的证书因此不成立；选择又在 $\binom{20}{d}$ 个子集里挑经验上最可分的那个，误差偏向有利的一侧。

4.2 想法

半径应该是选中维数 d 的函数，按经验分布的 $\mathcal{W}_1$ 收敛速度取 $\rho(d) \asymp d\,n^{-1/d}$，而不是常数。这样有三个好处：

1. 证书在**选择之后**仍然有效，不需要多重比较修正，因为覆盖事件对所有子集同时成立；
2. 证书不会低于 Bayes 风险，虚假可分消失；
3. 用证书本身来选 d，半径就是复杂度惩罚，和按“经验风险加复杂度”选模型是同一个思路 [1]。

总体对象：真分布 $\mathbb{P}_0, \mathbb{P}_1$，真风险 $R_{\text{true}}(f) = \mathbb{E}_{\mathbb{P}_0}\ell(-f) + \mathbb{E}_{\mathbb{P}_1}\ell(f)$，总体稳健值 $V_{\text{pop}}(S;r) = 2 - \inf\{D_\ell(Q_0,Q_1) : \mathcal{W}_1(\mathbb{P}_k[S], Q_k) \le r_k\}$，以及 $B_S = V_{\text{pop}}(S;0)$。$B_S$ 就是只看坐标 S 的 Bayes 风险；hinge 下 $B_S = 2(1 - \mathrm{TV}(\mathbb{P}_0[S], \mathbb{P}_1[S]))$，是最优检验两类错误率之和的两倍。$V(S;\rho)$ 表示半径为 ρ 的经验稳健值。除命题 10外，本节的结论对一般损失成立。

4.3 可能的定理

引理 8 (夹逼)**.** 【已证】若 $\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) \le \varepsilon_k \le \rho_k$，则 $B_S \le V_{\text{pop}}(S;\rho-\varepsilon) \le V(S;\rho) \le V_{\text{pop}}(S;\rho+\varepsilon)$。

为什么：三角不等式让三个球一个套一个，而稳健值随球增大而增大。

命题 9 (检测器的证书)**.** 【已证】设 (g,a,λ) 解式 (4)，f 是它按式 (5) 的延拓，$f<0$ 时判 1 类。对任意有一阶矩的 $\mathbb{P}_0, \mathbb{P}_1$，

$$\mathbb{P}_0(f<0) + \mathbb{P}_1(f \ge 0) \le R_{\text{true}}(f) \le V(S) + \sum_{k=0}^{1} \lambda_k \big(\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) - \rho_k\big).$$

为什么：第一个不等式是因为 $\ell \ge 1$ 在 $[0,\infty)$ 上。包络 E_k 控制 k 类的损失，是 λ_k-Lipschitz 的，在样本点上不超过 $a^{(k)}$；用 Kantorovich–Rubinstein 对偶即可。**含义：**只要半径盖住了真实的 $\mathcal{W}_1$ 误差，证书就有效；盖不住，就按价格 λ_k 线性变差。

命题 10 (半径下界，hinge)**.** 【已证】设 $\mathbb{P}_0 = \mathbb{P}_1$，在 $|S| = d$ 上的投影密度不超过 M。以至少 $1 - e^{-n_0/8}$ 的概率，对每个 $c \in (0,1)$，

$$V(S) \ge 2 - c \implies \rho_0 + \rho_1 \ge (1-c)\,\frac{d}{4e}\,(4Mn_1)^{-1/d}.$$

为什么：看每个 0 类点到最近 1 类点的 ℓ_1 距离。n_1 个 ℓ_1 球的体积乘 M 很小，所以至少一半的 0 类点离 1 类很远（Hoeffding 不等式）。要让 $V \ge 2-c$，大部分质量都得被撮合，远点的撮合代价就压出了下界。**含义：**想避免虚假可分，半径至少要是 $d\,n^{-1/d}$ 量级。

引理 11 (一致覆盖)**.** 【草证】设 $\mathbb{P}_0, \mathbb{P}_1$ 支撑在 $[0,1]^D$，$3 \le d \le D$，$\delta \in (0,1)$。以至少 $1-\delta$ 的概率，对 $k=0,1$ 和所有 $|S| \le d$，

$$\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) \le \varepsilon_k := c\,d\,n_k^{-1/d} + d\sqrt{\frac{d\log(eD/d) + \log(2/\delta)}{2n_k}},$$

常数 $c \le 9$。$d=1,2$ 时第一项换成 $n^{-1/2}$ 和 $n^{-1/2}\log n$ 量级 [7]。

为什么：三步：把空间切成越来越细的小方块，得到期望的界 [25]；换掉一个样本只让 $\mathcal{W}_1$ 变化 d/n，所以集中在期望附近 [13]；再对两类和 $\binom{D}{d} \le (eD/d)^d$ 个子集取并。

定理 12 (诚实选择)**.** 【在引理 11 下已证】取 $\rho_k \ge \varepsilon_k$。以至少 $1-\delta$ 的概率，对所有 $|S| \le d$ 同时有：(a) $B_S \le V(S;\rho) \le V_{\mathrm{pop}}(S;2\rho)$；(b) 在 S 上拟合的检测器满足 $\mathbb{P}_0(f_S < 0) + \mathbb{P}_1(f_S \ge 0) \le R_{\mathrm{true}}(f_S) \le V(S;\rho)$。因此选出来的 $\widehat{S}$ 和它的检测器 $\widehat{f}$ 满足

$$\mathbb{P}_0(\widehat{f} < 0) + \mathbb{P}_1(\widehat{f} \ge 0) \le R_{\mathrm{true}}(\widehat{f}) \le V(\widehat{S};\rho) \le \min_{|S|\le d} V_{\mathrm{pop}}(S;2\rho).$$

只优化到误差 τ 时，右端加 τ。

为什么：在覆盖事件上，夹逼引理给 (a)（$\rho + \varepsilon \le 2\rho$），检测器证书给 (b)。

三层意思：证书在选择后无需修正就有效，而且对每个 S 都有效，所以优化误差只影响链条的右端；证书不会声称比 Bayes 风险更好，消除了虚假可分；把半径加倍后它是准确的。由命题 10，$d\,n^{-1/d}$ 的阶不能再降。第一层意思对计算很重要：第 3.5 节的容差 τ 不会让证书失效，只让右端松 τ。

推论 13 (用证书选 d)**.** 【在引理 11 下已证】对每个 $d \le d_{\max}$ 取水平 $\delta/d_{\max}$ 的半径 $\rho(d)$，在所有 $d \le d_{\max}$、$|S| \le d$ 上最小化 $V(S;\rho(d))$，得到 $(\widehat{d}, \widehat{S})$。以至少 $1-\delta$ 的概率，$R_{\mathrm{true}}(\widehat{f}) \le V(\widehat{S};\rho(\widehat{d})) \le \min_d \min_{|S|\le d} V_{\mathrm{pop}}(S;2\rho(d))$。

命题 14 (恢复真坐标)**.** 【在引理 11 下已证】设 $|S^\star| = s$，且对所有 $|S| = s$、$S \ne S^\star$ 有间隔 $V_{\mathrm{pop}}(S;\rho) \ge V_{\mathrm{pop}}(S^\star;\rho) + \gamma$。若 $\varepsilon_k \le \eta\rho_k$ 且 $4\eta/(1-\eta) < \gamma$，则以至少 $1-\delta$ 的概率，预算 s 下的选择恰好返回 $S^\star$。

为什么：$t \mapsto V_{\mathrm{pop}}(S;t\rho)$ 凹、不减、取值在 $[0,2]$，所以在 $[1-\eta, 1+\eta]$ 上斜率不超过 $2/(1-\eta)$；再用夹逼。样本量需求约为 $(Cs/\eta\rho)^s + s^3\log(eD/s)/(\eta\rho)^2$：**对选中维数是指数的，对环境维数只是对数的**，和投影检验的功效分析一致 [24, 23]。

速率的两个例子（hinge）：若 $\mathbb{P}_0[S], \mathbb{P}_1[S]$ 的支撑相距 Δ，则 $V_{\mathrm{pop}}(S;r) \le 2(r_0+r_1)/\Delta$；若一维上 $\mathbb{P}_0 = U[0,1]$、$\mathbb{P}_1 = U[1,2]$，则 $V_{\mathrm{pop}}(S;r) = 2\sqrt{r_0+r_1}$。取 $\rho \approx \varepsilon$，证书误差分别约为 $s\,n^{-1/s}/\Delta$ 和 $(s\,n^{-1/s})^{1/2}$；环境维数只通过 $\log(eD/s)$ 进入，而用全部坐标需要 $D\,n^{-1/D}$ 的半径。“选一个投影让两样本距离最大”的思路见 [15, 24, 17, 18, 23]；这里的距离是“被运输攻击之后的散度”，它的值就是检验风险的证书。

实验里的情况。 第 6 节只用交叉验证选半径，没有取 $\rho_k \ge \varepsilon_k$，所以证书多数不成立（表 5）。按本节取半径后证书成立的比例，以及测试错误率为此付出多少，还没有做。

4.4 问题与下一步

- **半径的标定。**定理要 $\rho_k \ge \varepsilon_k$，而引理 11的常数很保守。下一步：数据驱动标定，例如把每类样本随机对半分，测两半之间投影 $\mathcal{W}_1$ 在所有 $|S| \le d$ 上的最大值，取它的 $1-\delta$ 分位数；这估计的正是覆盖事件需要的量。
- **证书的松弛**来自定理右端的 $V_{\mathrm{pop}}(S;2\rho)$。可能的收紧：命题 9里 $\lambda_k(\mathcal{W}_1 - \rho_k)$ 一项在半径有富余时为负，可以用估计的 $\mathcal{W}_1$ 扣回一部分；或者改用受限检测器类。
- **锐利半径**：半径在 $\frac{d}{4e}(4Mn)^{-1/d}$ 和 $c\,d\,n^{-1/d} + d^{3/2}\sqrt{\log(eD/d)/n}$ 之间。$\log(eD/d)$ 项是否必要?

- **受限检测器**：$n^{-1/d}$ 是任意可测检测器的代价（它能记住孤立点）。线性或核检测器按 [8] 的分析，半径可能只需 $\sqrt{d\log(eD/d)/n}$。

猜想 15 (诚实松弛)**.** 【猜想】给每个加权度量配上让它诚实的半径（权重 $\zeta_m = d/D$ 时，小尺度下它像 D 维立方体一样难以覆盖），承诺界相对最好的稀疏选择的改进就不会超过夹逼宽度。那么第 3.3 节的间隙只是一个统计假象。

5 方向 B：随机化选择（探索）

博弈。本节用 hinge，$\rho = \rho_0 + \rho_1$，$V_S(r) = 2m_S(r)$。防守方按分布 p 随机抽一个 $|S| \le d$ 和检测器 $f \in \mathcal{F}_S$；对手知道 p 但不知道抽签结果，选 $(Q_0, Q_1) \in \mathcal{P}_0 \times \mathcal{P}_1$。记防守方最好的最坏期望风险为 $\mathrm{OPT}_{\mathrm{rand}} \le \mathrm{OPT} = \min_{|S|\le d} V(S)$。对抗分类里随机化防守的类似想法见 [19, 14, 10]。

引理 16 (代价可分)**.** 【已证】攻击在坐标 m 上的代价 $r_m = \sum_k \int |x[m] - y[m]|\, d\gamma_k$ 满足 $\sum_m r_m \le \rho$，且它在 S 上的投影代价不超过 $r(S) = \sum_{m\in S} r_m$。

由命题 3，每个价格 λ 和见证 h 给出 S 上的一个检测器，它在投影代价为 r 的攻击下风险至多 $A + \Lambda r$，$A = 2(1-\beta_\lambda)$，$\Lambda = 2\lambda$；$V_S(r)$ 是这些直线的下包络。

定理 17 (随机化可达值)**.** 【已证】对有限的直线族 $T = \{(S_t, A_t, \Lambda_t)\}$，最优混合的最坏期望风险至多

$$W_T = \min_{p} \max_{m\in[D]} \Big\{ \sum_t p_t A_t + \rho \sum_{t:\, m\in S_t} p_t \Lambda_t \Big\} = \max_{r\ge 0,\ \mathbf{1}^\top r \le \rho} \min_{t\in T} \big\{ A_t + \Lambda_t r(S_t) \big\}. \tag{6}$$

T 取遍所有直线时 W_T 降到 $\overline{W} = \max_r \min_{|S|\le d} V_S(r(S))$，且 $\mathrm{OPT}_{\mathrm{rand}} \le \overline{W} \le \mathrm{OPT}$。

为什么：混合的期望风险关于攻击代价向量 r 是线性的、斜率非负，所以最坏攻击把全部预算砸在一个坐标上（$r = \rho e_m$），这给出左边；线性规划对偶给出等式。$\sum_{t:\, m\in S_t} p_t\Lambda_t$ 是坐标 m 的“价格暴露”：对手打最暴露的坐标，混合把暴露摊开，固定选择则把自己的 d 个坐标完全暴露。

定理 18 (不相交候选：预算均分到同一水平)**.** 【已证】若候选子集两两不交（特别是 $d = 1$），则 $\mathrm{OPT}_{\mathrm{rand}} = \overline{W} = \max\{t : \sum_S V_S^{-1}(t) \le \rho\}$，其中 $V_S^{-1}(t) = \inf\{r : V_S(r) \ge t\}$。

为什么：上界来自定理 17；对手最优的预算分配让各候选的值相等，像往几个容器里注水到同一水位。下界：在每个候选块上取对应预算的最不利分布对，各块独立移动，代价按块相加，所以合起来仍在预算内，而每个投影都是它自己的最不利分布对。例子：每类一个点 $(0,0)$ 和 $(1,1)$，$\rho = 1/2$，$d = 1$：固定选择的值是 1，均分给 $r^\star = (1/4, 1/4)$、值 $1/2$。

命题 19 (对抽样误差无增益)**.** 【已证】在定理 12的设定下，混合的证书是各固定证书的平均 $\sum_t p_t(A_t + \Lambda_t \sum_k \varepsilon_k)$，不小于其中最好的一个。

为什么：抽样误差不会“分摊预算”：覆盖事件允许每个投影同时偏离满半径。

旧版笔记在这里有一张随机化选择的数值表，它的半径是人为固定的，已删去，没有按新协议重跑。

猜想 20 (紧性)**.** 【猜想】候选为所有大小 $d \ge 2$ 的子集时，某些例子上 $\mathrm{OPT}_{\mathrm{rand}} < \overline{W}$；若最优预算下各子集的最不利分布对能取成同一对高维分布的投影，则等号成立 [22]。

计算 $\overline{W}$ 可以逐个加入子集：给定预算向量 r，下一个子集是 $\min_{|S|\le d} V_S(r(S))$ 的解，也就是把式 (4)中的 $\rho\lambda$ 换成 $r^\top w$。

6　20 维实验

6.1　设定：4 个真坐标藏在 16 个干扰坐标里

问题。两类数据只在少数坐标上有差别。每类只有少量训练点时，检验还能不能分开两类？能不能找到那几个坐标？每个情形都是 $D = 20$：**4 个真坐标**，两类在这里分布不同；**16 个干扰坐标**，和其他一切独立，两类分布相同。于是似然比只依赖真坐标，Bayes 错误率（任何检验能达到的最低错误）和只看真坐标时相同。每次重复把 20 个坐标随机打乱，任何方法都不能靠下标找到真坐标。

数据。三种信号加一个零假设，参数取自文献。

- `null`：没有真坐标，两类都是 20 个独立的 $N(0,1)$。正确的错误率是 0.5，用来检查虚警。
- `mean_shift`：Wang 等 [23] 的情形 I。真坐标上 $N(0,\Sigma)$ 对 $N(\mu,\Sigma)$，$\Sigma_{ab} = 0.5^{|a-b|}$，$\mu_s = 2/s$；干扰坐标 $N(0,1)$。单个坐标就看得到差别，第一个坐标最强。
- `mixture`：[23] 的情形 IV。真坐标上 $N(0,I)$ 对 $\frac{1}{2}N(-\mu,I) + \frac{1}{2}N(\mu,I)$，$\mu$ 同上；干扰坐标 $N(0,1)$。两类均值相同，类 1 沿 μ 更分散，线性规则看不见。
- `interaction`：[26] 第 5.1 节的混合放在真坐标上，$\frac{1}{2}N(c,I) + \frac{1}{2}N(-c,I)$，类 0 取 $c = (1,1,1,1)$，类 1 取 $c = (1,1,-1,-1)$；干扰坐标是独立的 $\frac{1}{2}N(1,1) + \frac{1}{2}N(-1,1)$。20 个坐标在两类里的单坐标分布全都一样，差别只在真坐标之间“一起怎么动”。

4 个真坐标占 D 的五分之一，和 [23] 的 20/100 相同。三个信号情形的 Bayes 错误率相近（0.14–0.16）。

协议。照 Xie 等 [26] 第 5.1 节：每类 n 个训练点，$n \in \{10, 20, 30, 50\}$（$n = 10$ 是他们的设置）；每类 1000 个新测试点；所有调节参数用训练点上的 5 折交叉验证选，准则是验证错误率；用全部训练点重拟合后在测试点上评价；每个情形和 n 重复 100 次（他们重复 500 次）。

方法。稳健方法都用 hinge 损失和 ℓ_1 运输代价，$\rho_0 = \rho_1 = \rho/2$，ρ 在 0.01 到 100 的 17 个对数等距点上选。

- **选择**（本文）：在每个半径上精确求 $\arg\min_{|S|=d} V(S)$（匹配形式枚举，20 维足够快），在 S 上解式 (4)，新点按式 (5) 打分；(d,ρ) 交叉验证，$d \in \{1,2,3,4\}$。
- **边际筛选**：同一流程，只是 S 取单坐标值 $V(\{m\})$ 最小的 d 个。它和“选择”的差别就是**联合**选择的价值。
- **全部坐标**：20 个坐标上的稳健检验，即 [26] 的方法（样本外按式 (5) 而非核平滑）。它和“选择”的差别是干扰坐标的代价。
- **真坐标**：4 个真坐标上的稳健检验，作参照，实际中不可得。
- 逻辑回归、RBF 核 SVM（[26] 的基线）和 L1 逻辑回归（[23] 的稀疏基线）；正则参数在 $10^{-4}, \ldots, 10^{4}$（10 点）上交叉验证。

指标。分数非负判类 0。第一类错误是类 0 测试点被判成类 1 的比例，第二类错误是类 1 被判成类 0 的比例；测试错误率是两者的平均，掷硬币是 0.5，Bayes 错误率是下限。选出的坐标用 [23] 的 FDP（选中坐标里干扰坐标的比例）和 NDP（4 个真坐标里漏掉的比例）衡量；随机挑

d 个坐标时 FDP 是 0.8，NDP 是 $1 - d/20$。证书是 $V(S)/4$：随机化检验（以概率 $(1+g)/2$ 判类 0）在两个 Wasserstein 球上的最坏错误率；把它和随机化检验在测试集上的实际错误率比较，前者不低于后者就算成立。

前几次运行发现的问题。都已改掉：(1) 稳健方法按验证 hinge 风险调半径、基线按准确率调，准则不同；全部坐标的检验因此总选到几乎是常数的检测器。(2) `interaction` 的干扰坐标原来是 $N(0,1)$，方差比真坐标小，单坐标的稳健值能靠“分散程度”认出真坐标。(3) 很多子集的值并列时代码按下标取第一个，而真坐标原来就在前 4 个位置；现在每次重复随机打乱坐标。(4) 上一版 `mean_shift` 的协方差 $0.5^{|a-b|}$ 铺满 20 个坐标，紧挨真坐标的干扰坐标和它相关，也带信息；现在干扰坐标和真坐标独立。上一版还有一个信号均匀分在 20 个坐标上的情形，$d \le 4$ 的选择接近随机；它不属于“少数真坐标”这个设定，这一版去掉了。

6.2 结果

四张图和全部表格（含 $n = 20$、标准误和两类错误）在 `results/study20-v3/summary.md`。

	`mean_shift`			`mixture`			`interaction`		
方法	$n = 10$	30	50	10	30	50	10	30	50
Bayes	0.158	0.157	0.156	0.161	0.160	0.160	0.145	0.144	0.145
选择	0.228	0.185	0.172	0.347	0.247	0.227	0.480	0.377	0.273
边际筛选	0.222	0.182	0.174	0.354	0.257	0.237	0.498	0.481	0.473
全部坐标	0.338	0.297	0.294	0.419	0.381	0.370	0.453	0.427	0.406
真坐标	0.242	0.209	0.200	0.304	0.249	0.235	0.291	0.235	0.211
逻辑回归	0.248	0.201	0.193	0.493	0.497	0.495	0.498	0.498	0.500
L1 逻辑回归	0.291	0.192	0.178	0.501	0.500	0.499	0.499	0.499	0.500
RBF SVM	0.249	0.208	0.196	0.392	0.330	0.298	0.464	0.423	0.378

表 3: 测试错误率（两类错误的平均），100 次重复的平均，标准误不超过 0.010。`null` 省略：所有方法在所有 n 下都在 0.499–0.502。

		$n = 10$		$n = 30$		$n = 50$		
情形	方法	FDP	NDP	FDP	NDP	FDP	NDP	$\lvert S\rvert$
`mean_shift`	选择	0.21	0.73	0.17	0.71	0.13	0.72	1.4
	边际筛选	0.19	0.69	0.09	0.65	0.06	0.65	1.6
	L1 逻辑回归	0.59	0.50	0.66	0.47	0.74	0.50	8.2
`mixture`	选择	0.37	0.70	0.11	0.60	0.04	0.56	1.9
	边际筛选	0.43	0.72	0.15	0.67	0.07	0.64	1.7
	L1 逻辑回归	0.45	0.68	0.55	0.51	0.40	0.58	8.1
`interaction`	选择	0.76	0.84	0.36	0.57	0.07	0.26	3.2
	边际筛选	0.77	0.86	0.72	0.80	0.79	0.82	2.8
	L1 逻辑回归	0.59	0.60	0.54	0.50	0.49	0.52	9.9

表 4: 恢复的坐标。FDP 是选中坐标里干扰坐标的比例，NDP 是 4 个真坐标里漏掉的比例，$|S|$ 是平均选中个数。随机挑 $|S|$ 个坐标时，FDP 的期望是 0.8，NDP 是 $1 - |S|/20$。

看到了什么。

	选择				全部坐标		
情形	证书	实际	成立	半径	证书	实际	成立
`null`	0.247	0.500	0.02	0.14	0.241	0.500	0.18
`mean_shift`	0.232	0.257	0.52	0.32	0.280	0.474	0.27
`mixture`	0.265	0.325	0.42	0.32	0.188	0.488	0.07
`interaction`	0.257	0.442	0.14	0.56	0.230	0.493	0.07

表 5: 交叉验证半径下的证书，$n = 30$。证书是 $V(S)/4$，即随机化检验在两个 Wasserstein 球上的最坏错误率；实际是它在测试集上的错误率；成立是证书不低于实际值的重复比例；半径是 $\rho_0 + \rho_1$ 的中位数（全部坐标是 5.6–10）。其他 n 的情况相同。

				枚举	紧凑 MILP		外逼近			分支定界		
情形	n	d	子集	秒	秒	节点	最优	子集	秒	LP	秒	界/最优
`interaction`	10	2	190	0.11	0.8	23	1.0	173	154	143	1.5	0.70
	10	3	1140	0.58	3.0	498	0.1	296	547	275	2.3	0.74
	10	4	4845	2.02	3.8	1214	0.1	234	500	550	5.4	0.77
	30	2	190	0.68	4.0	34	1.0	190	143	226	5.4	0.60
	30	3	1140	4.16	28.8	1497	0.0	405	600	1181	14.4	0.57
	30	4	4845	17.9	75.3	5479	0.0	331	600	3124	39.1	0.60
`mean_shift`	10	2	190	0.13	1.3	23	1.0	157	124	121	1.4	0.70
	10	3	1140	0.82	3.5	518	0.2	258	496	271	3.2	0.72
	10	4	4845	3.32	4.0	1058	0.2	238	505	356	3.3	0.77
	30	2	190	1.66	4.7	31	1.0	190	179	224	5.5	0.54
	30	3	1140	6.19	15.4	1055	0.0	309	600	876	22.0	0.58
	30	4	4845	19.1	38.8	3101	0.0	238	543	1498	37.8	0.64

表 6: 在交叉验证给“选择”选出的半径上精确求 $\min_{|S|\le d} V(S)$，每格 10 次重复的平均。紧凑 MILP 是式 (4)，由 HiGHS 求解；外逼近是核心包的 `select(..., "oa")`，限时 600 秒，“最优”是在限时内证明最优的比例（另有 2 次主问题求解失败）；分支定界是第 3.5 节的算法。紧凑 MILP 和分支定界每次都求到最优。界/最优是承诺界除以最优值。

1. **信号只在真坐标的关系里时，只有联合选择找到了它，而且样本越多越准。**`interaction` 上选择的测试错误率从 0.480（$n = 10$）降到 0.377（$n = 30$）和 0.273（$n = 50$）；边际筛选一直在 0.47–0.50，逻辑回归和 L1 逻辑回归是 0.50，SVM 和全部坐标的稳健检验到 $n = 50$ 也只有 0.38 和 0.41。恢复也一样：$n = 50$ 时选择的 FDP/NDP 是 0.07/0.26，边际筛选是 0.79/0.82，和随机挑差不多。$n = 10$ 时选择也接近随机，但只用真坐标的检验已经是 0.291：小样本下的瓶颈是从干扰坐标里找出真坐标，而不是在真坐标上检验。

2. **单个坐标就看得到信号时，选择和边际筛选一样好，并且在每个 n 下都好过所有基线。**两者相差不超过 0.01。`mean_shift` 上选择从 0.228 降到 0.172（Bayes 0.156）；`mixture` 上从 0.347 降到 0.227，而两类均值相同，逻辑回归和 L1 逻辑回归一直是 0.50。`mean_shift` 上选择甚至好过真坐标（$n = 50$ 时 0.172 对 0.200）：$\mu_s = 2/s$ 让第一个坐标最强，交叉验证 52%–69% 的重复选 $d = 1$。这也是 NDP 高的原因：按预测选 d，不会把弱的真坐标都选进来。L1 逻辑回归 NDP 低一些，但要选 7–10 个坐标，FDP 是 0.40–0.74。

3. **干扰坐标的代价。**全部坐标的稳健检验在三个信号情形里是 0.29–0.42，比只用真坐标的 0.20–0.30 高 0.09–0.16，样本增加也补不回来。

4. **没有虚警。**`null` 上所有方法的测试错误率都在 0.499–0.502。L1 逻辑回归和全部坐标的两类错误不对称（约 0.35 对 0.65），但平均仍是 0.5。

5. **交叉验证半径下证书大多不成立**（表 5），见 第 4 节。另外，全部坐标的随机化检验在测试集上几乎是掷硬币（0.47–0.50），而它的符号判别是 0.29–0.45。20 维里新点离两类样本差不多远，式 (5) 的加权把分数拉向 0：一次重复里测试点上 $|g|$ 的平均，全部坐标时约 0.1，只用真坐标时是 0.3–0.5。

6. **计算**：$D = 20$ 时枚举最快；外逼近在 $d \geq 3$ 时多半在 600 秒内停不下来；紧凑 MILP 和分支定界总能求到最优；承诺界平均只有最优值的 0.54–0.77（第 3 节）。

7 优先级

1. **方向 A（诚实半径）**故事最强、成本最低：在高维里，正是选择让 Wasserstein 稳健检验变得有效。20 维实验给出了动机：交叉验证半径下证书大多不成立，零假设下证书声称最坏错误率约 0.25，而真实是 0.5（表 5）。下一步：数据驱动的半径标定，在同一协议下看证书成立的比例和测试错误率的代价，收紧证书，$d \leq 2$ 的显式常数，与核变量选择 [23] 对比。

2. **计算**：用承诺界的分支定界替代外逼近，容差取夹逼宽度；验证猜想 7。$D = 20$ 时枚举最快（表 6）。

3. **方向 B（随机化）**：探索性。两个定理已证；下一步是猜想 20，以及一个有战略对手的应用。

参考文献

[1] Peter L. Bartlett, Stéphane Boucheron, and Gábor Lugosi. Model selection and error estimation. *Machine Learning*, 48:85–113, 2002.

结果	状态
命题 1：散度形式（一般损失）	已证
命题 2、3：匹配、见证形式（hinge）	已证，数值核对过
命题 4、5：稀疏价格、承诺界（一般损失）	已证；承诺界在 hinge 上数值核对过
命题 6：NP 难（一般损失）	已证
引理 8，命题 9、10	已证
引理 11：一致覆盖	标准，草证
定理 12，推论 13，命题 14	在引理 11 下已证；还没有数值检验
定理 17、18，命题 19	已证
猜想 7、15、20	开放

表 7: 各结果的状态。

[2] Laetitia Chapel, Mokhtar Z. Alaya, and Gilles Gasso. Partial optimal transport with applications on positive-unlabeled learning. In *Advances in Neural Information Processing Systems*, volume 33, 2020.

[3] Carlos Cotta and Pablo Moscato. The k-feature set problem is W[2]-complete. *Journal of Computer and System Sciences*, 67(4):686–690, 2003.

[4] Scott Davies and Stuart Russell. NP-completeness of searches for smallest possible feature sets. In *AAAI Fall Symposium on Relevance*, 1994.

[5] Richard M. Dudley. *Real Analysis and Probability*. Cambridge University Press, 2nd edition, 2002.

[6] Alessio Figalli. The optimal partial transport problem. *Archive for Rational Mechanics and Analysis*, 195(2):533–560, 2010.

[7] Nicolas Fournier and Arnaud Guillin. On the rate of convergence in Wasserstein distance of the empirical measure. *Probability Theory and Related Fields*, 162:707–738, 2015.

[8] Rui Gao. Finite-sample guarantees for Wasserstein distributionally robust optimization: Breaking the curse of dimensionality. *Operations Research*, 71(6):2291–2306, 2023.

[9] Rui Gao, Liyan Xie, Yao Xie, and Huan Xu. Robust hypothesis testing using Wasserstein uncertainty sets. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[10] Amir Globerson and Sam Roweis. Nightmare at test time: Robust learning by feature deletion. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 353–360, 2006.

[11] Peter J. Huber. A robust version of the probability ratio test. *The Annals of Mathematical Statistics*, 36(6):1753–1758, 1965.

[12] Peter J. Huber and Volker Strassen. Minimax tests and the Neyman–Pearson lemma for capacities. *The Annals of Statistics*, 1(2):251–263, 1973.

[13] Colin McDiarmid. On the method of bounded differences. In *Surveys in Combinatorics*, volume 141 of *London Mathematical Society Lecture Note Series*, pages 148–188. Cambridge University Press, 1989.

[14] Laurent Meunier, Meyer Scetbon, Rafael Pinot, Jamal Atif, and Yann Chevaleyre. Mixed Nash equilibria in the adversarial examples game. In *Proceedings of the 38th International Conference on Machine Learning*, pages 7677–7687, 2021.

[15] Jonas Mueller and Tommi Jaakkola. Principal differences analysis: Interpretable characterization of differences between distributions. In *Advances in Neural Information Processing Systems*, volume 28, 2015.

[16] XuanLong Nguyen, Martin J. Wainwright, and Michael I. Jordan. On surrogate loss functions and f-divergences. *The Annals of Statistics*, 37(2):876–904, 2009.

[17] François-Pierre Paty and Marco Cuturi. Subspace robust Wasserstein distances. In *Proceedings of the 36th International Conference on Machine Learning*, pages 5072–5081, 2019.

[18] Mathis Petrovich, Chao Liang, Ryoma Sato, Yanbin Liu, Yao-Hung Hubert Tsai, Linchao Zhu, Yi Yang, Ruslan Salakhutdinov, and Makoto Yamada. Feature-robust optimal transport for high-dimensional data. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, volume 13717 of *Lecture Notes in Computer Science*, pages 291–307, 2022.

[19] Rafael Pinot, Raphael Ettedgui, Geovani Rizk, Yann Chevaleyre, and Jamal Atif. Randomization matters. How to defend against strong adversarial attacks. In *Proceedings of the 37th International Conference on Machine Learning*, 2020.

[20] Mark D. Reid and Robert C. Williamson. Information, divergence and risk for binary experiments. *Journal of Machine Learning Research*, 12:731–817, 2011.

[21] Maurice Sion. On general minimax theorems. *Pacific Journal of Mathematics*, 8(1):171–176, 1958.

[22] N. N. Vorob'ev. Consistent families of measures and their extensions. *Theory of Probability and its Applications*, 7(2):147–163, 1962.

[23] Jie Wang, Santanu S. Dey, and Yao Xie. Variable selection for kernel two-sample tests, 2023. arXiv:2302.07415.

[24] Jie Wang, Rui Gao, and Yao Xie. Two-sample test using projected Wasserstein distance. In *IEEE International Symposium on Information Theory*, 2021.

[25] Jonathan Weed and Francis Bach. Sharp asymptotic and finite-sample rates of convergence of empirical measures in Wasserstein distance. *Bernoulli*, 25(4A):2620–2648, 2019.

[26] Liyan Xie, Rui Gao, and Yao Xie. Robust hypothesis testing with Wasserstein uncertainty sets, 2021. arXiv:2105.14348.