Wasserstein 稳健检验中的变量选择：研究方向

工作笔记，非正式

怎么读。这是一份想法笔记，不是论文。每个结论都标了状态：【已证】表示证明完整（这里只写思路），【草证】表示是标准论证、细节未写全，【猜想】表示还没证。所有数字都来自开发检查：小规模的 `note/directions/dev_checks.py` 和 20 维检查 `results/study20-v1`（代码 `scripts/run_study20.py`）。它们是验证想法用的，不是正式实验结论。符号沿用正式笔记 `robust_coordinate_selection.pdf`；本笔记只讨论 hinge 损失 $\ell(t) = (1+t)_+$，除非另外说明。对分布 Q，$Q[S]$ 表示它在坐标 S 上的投影。

1　出发点：一个问题

正式笔记把 $\min_{|S|\le d} V(S)$ 写成凸函数 F 在 $\mathcal{Z}_d$ 上的最小化，用外逼近（OA）求解。实际跑下来有两个现象：

- OA 几乎要把所有子集都评估一遍才能闭合上下界。20 维检查里（表 5），$d = 2$ 时 OA 评估了全部 190 个子集才证明最优；$d = 3$ 时 600 秒内评估了 1140 个子集中的 920–1090 个，下界还停在 0.17–0.28，而最优值是 0.88–1.02。
- 连续松弛很弱：在 $D = 10$、$d = 2$ 的小例子上，F 在均匀点 $(d/D)\mathbf{1}$ 处只有 0.58，最优值是 1.40。

问题是：弱是公式的问题，还是问题本身的？本笔记的回答是：是问题本身的，而且有直观含义——**混合坐标对防守方有利**。能给所有坐标加权、或在坐标之间随机挑选的检测器，比任何固定的稀疏投影更能把两类分开。这个“好处”是真是假，取决于防守方面对的是谁，这正好给出三个方向：

- 面对**抽样误差**：好处是假的。高维时稳健检验会把两个相同的分布“证明”为可分。选择坐标、并让半径随选中的维数增长，可以消除这个假象（方向 A，第 4 节）。
- 在**优化**里：好处就是松弛间隙，也是问题难的原因（第 3 节；方向 B，第 5 节）。
- 面对**必须在坐标间分配同一笔运输预算的对手**：好处是真的，随机化的稀疏检验能拿到它（方向 C，第 6 节）。

2　核心改写：hinge 损失下 $V(S)$ 是一个带预算的匹配

2.1　$V(S)$ 是一个散度

对 $a, b \ge 0$ 令 $\psi(a,b) = \inf_t\{a\ell(-t) + b\ell(t)\}$，它是凹的、一次齐次的，且 $\psi(a,a) = 2a$。于是 $D_\ell(Q_0, Q_1) = 2 - \int \psi(dQ_0, dQ_1)$ 是一个 f-散度：hinge 对应 2 TV，指数损失对应 Hellinger

距离的平方，logistic 损失（以 2 为底）对应两倍的 Jensen–Shannon 散度。记 $\mathcal{P}_k[S] = \{Q : \mathcal{W}_1(\widehat{\mathbb{P}}_k[S], Q) \le \rho_k\}$。

命题 1 (散度形式)**.** 【已证】对任意 S，$V(S) = 2 - \min_{Q_k \in \mathcal{P}_k[S]} D_\ell(Q_0, Q_1)$。

为什么：固定 (Q_0, Q_1)，在 $\mathcal{F}_S$ 上逐点最小化风险，得到的就是 $\int \psi$。对手再挑最难分的一对。所以 $V(S)$ 的含义是“对手在坐标 S 上能把两类拉到多近”。投影把 Wasserstein 球映到同半径的球，正式笔记的引理 2.1 说明最不利分布可以取在投影样本上。

参考：损失与散度的对应来自 [19, 24]；最不利分布对的思想来自 Huber [14, 15]；Wasserstein 球来自 [11]。“选一个投影让两样本距离最大”的思路见 [18, 29, 20, 21, 28]；这里的距离是“被运输攻击之后的散度”，它的值就是极小极大检验的风险证书。

2.2 预算匹配

记 $C^m_{ij} = |x^{(0)}_i[m] - x^{(1)}_j[m]|$，$c_{ij}(S) = \sum_{m \in S} C^m_{ij}$，并定义

$$m_S(\rho) = \max_{\pi \ge 0} \Big\{ \sum_{i,j} \pi_{ij} : \ \sum_j \pi_{ij} \le \frac{1}{n_0},\ \sum_i \pi_{ij} \le \frac{1}{n_1},\ \sum_{i,j} \pi_{ij} c_{ij}(S) \le \rho \Big\}, \tag{1}$$

即在总运输预算 ρ 内最多能撮合多少跨类质量。

命题 2 (匹配形式)**.** 【已证】 hinge 损失下 $V(S) = 2\, m_S(\rho_0 + \rho_1)$。

为什么：hinge 下 $V(S)/2 = 1 - \min \mathrm{TV}$，就是两类在投影球里能达到的最大“重叠”质量 $\int \min(dQ_0, dQ_1)$。要制造重叠，必须把一个 0 类点的质量和一个 1 类点的质量搬到同一个位置，由三角不等式，两边合计至少花 $c_{ij}(S)$。反过来，沿两点连线按 $\rho_0 : \rho_1$ 的比例各走一段，就恰好花 $c_{ij}(S)$。所以**对手是一个媒人**：用预算 $\rho_0 + \rho_1$ 撮合尽可能多的跨类点对。

三个直接推论：(i) 半径只通过 $\rho_0 + \rho_1$ 起作用；(ii) 最不利分布就是“把一些跨类点对拉到一起”，所以 S 好，当且仅当在 S 的坐标上便宜的跨类点对很少；(iii) 计算 $V(S)$ 只是一个带一条边约束的二分匹配，$n_0 n_1$ 个变量。20 维检查里，核心求解器算出的 $V(S)$ 与 $2m_S$ 的最大差是 3.3×10^{-11}。

等样本量时更快。当 $n_0 = n_1 = n$，令 $C(k)$ 为 k 对不相交跨类点对的最小总代价除以 n （一个指派问题，用匈牙利算法），$C(k)$ 关于 k 是凸的，$m_S(\rho)$ 就是 C 的反函数（断点之间线性插值）。实验代码里的 `Matching` 类就是这么算的，比解 LP 快约 30 倍。

总体版本。证明没用到“经验分布”：对任意 P_0, P_1，在预算 r_0, r_1 内能达到的最大重叠，就是 $P_0[S]$ 与 $P_1[S]$ 之间运输代价不超过 $r_0 + r_1$ 的部分耦合的最大质量。这是部分最优运输的预算形式 [7, 2, 3]；它对 Wasserstein 球的作用，相当于 Strassen 定理 [26] 对 Prokhorov 邻域的作用。

2.3 对偶：有界 Lipschitz 见证函数

对 $\lambda \ge 0$，令 $\beta_\lambda(Q_0, Q_1) = \sup\{\mathbb{E}_{Q_0} h - \mathbb{E}_{Q_1} h : \ |h| \le \frac{1}{2},\ h \text{ 关于} \ell_1 \text{ 是}\lambda\text{-Lipschitz}\}$。它是 Dudley 有界 Lipschitz 距离 [6] 的一个变体：$\lambda = 0$ 时为 0，$\lambda \to \infty$ 时趋于 TV，关于 λ 是凹的。

命题 3 (Lipschitz 见证)**.** 【已证】 hinge 损失下

$$V(S) = 2 - 2 \max_{\lambda \ge 0} \big\{ \beta_\lambda(\widehat{\mathbb{P}}_0[S], \widehat{\mathbb{P}}_1[S]) - \lambda(\rho_0 + \rho_1) \big\},$$

并且若 (λ, h) 取到最大，检测器 $f(x) = 2h(x[S])$ 是最优的：$R(f) = V(S)$。

为什么：只对式 (1)里的预算约束取对偶，$m_S(\rho)=\min_\lambda\{\lambda\rho+M(\lambda)\}$，其中 $M(\lambda)$ 是“每对收益 $1-\lambda c_{ij}$”的无预算匹配；再对 $M(\lambda)$ 取 LP 对偶，把对偶变量改写成两类点上的函数值，就得到 $1-M(\lambda)=\beta_\lambda$。$|2h|\le 1$ 让 hinge 损失变成线性的，再用 Kantorovich–Rubinstein 对偶就得到风险上界 $=V(S)$。

读法。稳健 hinge 检验就是一个**有界 Lipschitz 两样本统计量**，Lipschitz 常数 λ 按总半径定价：λ 大，见证函数可以很陡地把两个样本分开，但要付 $\lambda\rho$。半径决定了一个“诚实的”见证函数必须有多平滑。变量选择就是挑 d 个坐标，让这个惩罚后的距离最大，类似核两样本检验里的坐标选择 [28]。$1-M(\lambda)$ 也是未匹配质量按固定价格计费的非平衡运输代价 [22, 13]。

具体构造。解式 (1)的 LP 对偶得到 (u,v,λ)，令 $h'_j=\min(v_j-\frac12,\frac12)$，

$$h(\xi)=\mathrm{clip}_{[-1/2,1/2]}\Big(\min_j\big\{h'_j+\lambda\|x_j^{(1)}[S]-\xi\|_1\big\}\Big).$$

它就是实验代码里的 `witness()`。由于 m_S 是切线 $\rho\mapsto\lambda\rho+M(\lambda)$ 的下包络，m_S 关于 ρ 凹、不减，斜率等于最优价格 λ；第 6 节 会用这些切线。

3　紧凑 MILP、松弛与困难性

式 (1)的 LP 对偶是 $m_S(\rho)=\min_{u,v,\lambda\ge0}\{\rho\lambda+\bar u+\bar v:\ u_i+v_j+\lambda c_{ij}(S)\ge1\}$，其中 $\bar u=\frac{1}{n_0}\sum_i u_i$，$\bar v=\frac{1}{n_1}\sum_j v_j$。读法：每个跨类点对，要么由两个端点“付钱”（$u_i+v_j$），要么被它的定价距离 $\lambda c_{ij}(S)$ 隔开。选 S 就是决定对手要为哪些坐标付钱。令 $w_m=\lambda z_m$、$\rho=\rho_0+\rho_1$，整个选择问题变成一个紧凑程序：

$$\begin{aligned}\min_{z\in\mathcal{Z}_d,\,u,v,w,\lambda\ge0}\quad & \rho\lambda+\bar u+\bar v\\ \text{s.t.}\quad & u_i+v_j+\sum_m w_m C_{ij}^m\ge1,\qquad w_m\le\lambda,\qquad \rho w_m\le z_m,\qquad \sum_m w_m\le d\lambda.\end{aligned}\tag{2}$$

命题 4 (紧凑程序)**.**【已证】式 (2)的最优值是 $\min_{|S|\le d}m_S(\rho)=\frac12\min_{|S|\le d}V(S)$。它的连续松弛（$z\in[0,1]^D$，$\mathbf{1}^\top z\le d$）的值，等于把坐标集换成加权 ℓ_1 度量 $\sum_m\zeta_m C_{ij}^m$ 之后的 $\min_\zeta m_\zeta(\rho)$。

为什么：$u=\mathbf{1},v=0,\lambda=0$ 可行且值为 1，所以最优解满足 $\rho\lambda\le1$。于是 $\rho w_m\le z_m$ 在 $z_m=1$ 时不起作用，在 $z_m=0$ 时迫使 $w_m=0$；这样 $z=\mathbf{1}_S$ 时就回到 m_S 的对偶。松弛时令 $\zeta=w/\lambda$ 即可。

为什么松弛弱。加权度量把坐标平均了。平均让跨类点对的代价向均值集中，对手就失去了在稀疏投影里总能找到的那几个便宜点对。这就是“混合坐标帮防守方”的机制，松弛间隙就是它的大小。表 1：松弛值只有最优值的一半到三分之二；20 维检查（表 5）里也是 0.49–0.78 对 0.88–1.32。它仍比正式笔记中 F 的松弛强。另外，“每对只取 d 个最大坐标差”的逐对界永远不比这个松弛强。

命题 5 (NP 难)**.**【已证】设数据是二值的，且 $\rho_0+\rho_1<\min\{1/n_0,1/n_1\}$。则 $\min_{|S|\le d}V(S)\le2(\rho_0+\rho_1)$，当且仅当存在 $|S|\le d$ 把每个跨类点对都分开（$x_i^{(0)}[S]\ne x_j^{(1)}[S]$）。这是 k-feature-set 问题，NP 完全 [5]，且关于 d 是 W[2] 完全的 [4]。

为什么：分开了，每对代价 ≥1，$m_S\le\rho$；没分开，某一对代价为 0，可以免费撮合，$m_S\ge\min\{1/n_0,1/n_1\}>\rho$。

边际递减也救不了贪心：0 类在 $(0,0),(1,1)$，1 类在 $(0,1),(1,0)$（XOR），单个坐标都给 $V=2$，两个一起给 $V=2(\rho_0+\rho_1)$。**结论：**不要指望一个强的凸松弛。进展必须用松弛看不到的信息：样本量（方向 A）、匹配结构（方向 B）、或者混合本身的价值（方向 C）。

D	N	d	$\min_S V(S)$	松弛	式 (2)（HiGHS）	枚举
10	30	2	1.40	0.89	0.2 s，17 节点	0.2 s
15	30	2	1.12	0.75	0.4 s，25 节点	0.5 s
12	30	3	0.87	0.49	0.7 s，302 节点	1.1 s
30	40	3	0.75	0.43	26 s，4.1k 节点	22 s
50	40	3	0.80	0.40	235 s，26k 节点	–
100	40	3	≤ 0.88	0.37	600 s 时限	–

表 1: 小规模开发检查（`dev_checks.py --gap`）。hinge 损失，$\rho_0 + \rho_1 = 0.6$，数值以 V 的尺度给出。两类都是标准正态，只是 1 类在坐标 1–3 平移 0.8、在坐标 4 放大 1.8 倍。

试过但走不通的路。 (a) perspective 加强：它在稀疏回归里有效，是因为有强凸的岭项；这里 z 只出现在线性代价里，perspective 就是它本身。(b) 逐对取前 d 大坐标差：每对各用各的坐标，不比松弛强。(c) 把随机化值当下界：在表 6的所有例子上都低于松弛。(d) 割工程（最不利割、Pareto 割、每次多条切线）：oracle 时间省 30–45%，但关不掉属于问题本身的间隙。(e) Sinkhorn 模糊集会把选择放进 $\exp(-c/\varepsilon)$ 里，丢掉匹配结构；神经网络生成最不利分布则丢掉证书。

4 方向 A：选择让稳健检验变“诚实”（主线）

4.1 现象

两类同分布时，正确的稳健值是 2（不可分）。可是半径固定为 0.6 时，表 2 里 $V([D])$ 在 $D = 50$ 时只有 0.03；20 维检查里全部 20 个坐标的 V 只有约 0.10（表 3）。也就是说，**稳健检验宣称两个相同的分布几乎完全可分**。原因：高维时经验点彼此孤立，每个跨类点对都很贵，对手撮合不起来。只选少数坐标能缓解，但“在很多子集里挑最好的”本身也是乐观的。**半径不随维数调整，证书就不诚实。**

D	1	2	3	5	10	20	50
$V([D])$	1.98	1.66	1.17	0.59	0.21	0.09	0.03
$\min_{\lvert S\rvert=2} V(S)$	–	1.66	1.65	1.53	1.39	1.40	–

表 2: 两类都是 $N(0, I_D), n_0 = n_1 = 15, \rho_0 + \rho_1 = 0.6$, 五次抽样平均（`dev_checks.py --noise`）。正确值都是 2。

4.2 想法

半径应该是选中维数 d 的函数，按经验分布的 $\mathcal{W}_1$ 收敛速度取 $\rho(d) \asymp d\, n^{-1/d}$，而不是常数。这样有三个好处：

1. 证书在**选择之后**仍然有效，不需要多重比较修正，因为覆盖事件对所有子集同时成立；
2. 证书不会低于 Bayes 风险，虚假可分消失；
3. 用证书本身来选 d，半径就扮演结构风险最小化 [1] 里的复杂度惩罚。

总体对象：真分布 $\mathbb{P}_0, \mathbb{P}_1$，真风险 $R_{\text{true}}(f) = \mathbb{E}_{\mathbb{P}_0}\ell(-f) + \mathbb{E}_{\mathbb{P}_1}\ell(f)$，总体稳健值 $V_{\text{pop}}(S;r) = 2 - \inf\{D_\ell(Q_0,Q_1) : \mathcal{W}_1(\mathbb{P}_k[S], Q_k) \le r_k\}$，以及 $B_S = V_{\text{pop}}(S;0)$。$B_S$ 就是只看坐标 S 的 Bayes 风险；hinge 下 $B_S = 2(1 - \text{TV}(\mathbb{P}_0[S], \mathbb{P}_1[S]))$，是最优检验两类错误率之和的两倍。$V(S;\rho)$ 表示半径为 ρ 的经验稳健值。

4.3 可能的定理

引理 6 (夹逼)**.** 【已证】若 $\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) \le \varepsilon_k \le \rho_k$，则 $B_S \le V_{\text{pop}}(S;\rho-\varepsilon) \le V(S;\rho) \le V_{\text{pop}}(S;\rho+\varepsilon)$。

为什么：三角不等式让三个球一个套一个，而稳健值随球增大而增大。

命题 7 (检测器的证书)**.** 【已证】设 (g, a, λ) 解正式笔记的 Eq. (4)，f 是它按正式笔记 Eq. (5) 的延拓，$f < 0$ 时判 1 类。对任意有一阶矩的 $\mathbb{P}_0, \mathbb{P}_1$，

$$\mathbb{P}_0(f < 0) + \mathbb{P}_1(f \ge 0) \le R_{\text{true}}(f) \le V(S) + \sum_{k=0}^{1} \lambda_k \big(\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) - \rho_k\big).$$

为什么：第一个不等式是因为 $\ell \ge 1$ 在 $[0,\infty)$ 上。包络 $E_k(\xi) = \min_r\{a_r^{(k)} + \lambda_k \|x_r^{(k)}[S] - \xi\|_1\}$ 控制 k 类的损失，是 λ_k-Lipschitz 的，在样本点上不超过 $a^{(k)}$；用 Kantorovich–Rubinstein 对偶即可。**含义：**只要半径盖住了真实的 $\mathcal{W}_1$ 误差，证书就有效；盖不住，就按价格 λ_k 线性变差。

命题 8 (半径下界)**.** 【已证】设 $\mathbb{P}_0 = \mathbb{P}_1$，在 $|S| = d$ 上的投影密度不超过 M。以至少 $1 - e^{-n_0/8}$ 的概率，对每个 $c \in (0,1)$，

$$V(S) \ge 2 - c \implies \rho_0 + \rho_1 \ge (1-c)\,\frac{d}{4e}\,(4Mn_1)^{-1/d}.$$

为什么：看每个 0 类点到最近 1 类点的 ℓ_1 距离。n_1 个 ℓ_1 球的体积乘 M 很小，所以至少一半的 0 类点离 1 类很远（Hoeffding）。要让 $V \ge 2 - c$，大部分质量都得被撮合，远点的撮合代价就压出了下界。**含义：**想避免虚假可分，半径至少要是 $d\,n^{-1/d}$ 量级。

引理 9 (一致覆盖)**.** 【草证】设 $\mathbb{P}_0, \mathbb{P}_1$ 支撑在 $[0,1]^D$，$3 \le d \le D$，$\delta \in (0,1)$。以至少 $1-\delta$ 的概率，对 $k = 0, 1$ 和所有 $|S| \le d$，

$$\mathcal{W}_1(\widehat{\mathbb{P}}_k[S], \mathbb{P}_k[S]) \le \varepsilon_k := c\,d\,n_k^{-1/d} + d\sqrt{\frac{d\log(eD/d) + \log(2/\delta)}{2n_k}},$$

常数 $c \le 9$。$d = 1, 2$ 时第一项换成 $n^{-1/2}$ 和 $n^{-1/2}\log n$ 量级 [9]。

为什么：三步：二进方块上的期望界 [30]；McDiarmid 有界差集中 [16]；对两类和 $\binom{D}{d} \le (eD/d)^d$ 个子集取并。

定理 10 (诚实选择)**.** 【在引理 9 下已证】取 $\rho_k \ge \varepsilon_k$。以至少 $1-\delta$ 的概率，对所有 $|S| \le d$ 同时有：(a) $B_S \le V(S;\rho) \le V_{\text{pop}}(S;2\rho)$；(b) 在 S 上拟合的检测器满足 $\mathbb{P}_0(f_S < 0) + \mathbb{P}_1(f_S \ge 0) \le R_{\text{true}}(f_S) \le V(S;\rho)$。因此选出来的 $\widehat{S}$ 和它的检测器 $\widehat{f}$ 满足

$$\mathbb{P}_0(\widehat{f} < 0) + \mathbb{P}_1(\widehat{f} \ge 0) \le R_{\text{true}}(\widehat{f}) \le V(\widehat{S};\rho) \le \min_{|S| \le d} V_{\text{pop}}(S;2\rho).$$

只优化到误差 τ 时，右端加 τ。

为什么：在覆盖事件上，夹逼引理给 (a)（$\rho+\varepsilon\le 2\rho$），检测器证书给 (b)。

三层意思：证书在选择后无需修正就有效，而且对每个 S 都有效，所以精确优化只影响链条的右端；证书不会声称比 Bayes 风险更好，消除了虚假可分；把半径加倍后它是准确的。由命题 8，$d\,n^{-1/d}$ 的阶不能再降。

推论 11 (用证书选 d)**.** 【在引理 9 下已证】对每个 $d\le d_{\max}$ 取水平 $\delta/d_{\max}$ 的半径 $\rho(d)$，在所有 $d\le d_{\max}$、$|S|\le d$ 上最小化 $V(S;\rho(d))$，得到 $(\widehat{d},\widehat{S})$。以至少 $1-\delta$ 的概率，$R_{\text{true}}(\widehat{f})\le V(\widehat{S};\rho(\widehat{d}))\le \min_d \min_{|S|\le d} V_{\text{pop}}(S;2\rho(d))$。

命题 12 (恢复真坐标)**.** 【在引理 9 下已证】设 $|S^\star|=s$，且对所有 $|S|=s$、$S\ne S^\star$ 有间隔 $V_{\text{pop}}(S;\rho)\ge V_{\text{pop}}(S^\star;\rho)+\gamma$。若 $\varepsilon_k\le\eta\rho_k$ 且 $4\eta/(1-\eta)<\gamma$，则以至少 $1-\delta$ 的概率，预算 s 下的选择恰好返回 $S^\star$。

为什么：$t\mapsto V_{\text{pop}}(S;t\rho)$ 凹、不减、取值在 $[0,2]$，所以在 $[1-\eta,1+\eta]$ 上斜率不超过 $2/(1-\eta)$；再用夹逼。样本量需求约为 $(Cs/\eta\rho)^s+s^3\log(eD/s)/(\eta\rho)^2$：**对选中维数是指数的，对环境维数只是对数的**，和投影检验的功效分析一致 [29, 28]。

速率的两个例子：若 $\mathbb{P}_0[S],\mathbb{P}_1[S]$ 的支撑相距 Δ，则 $V_{\text{pop}}(S;r)\le 2(r_0+r_1)/\Delta$；若一维上 $\mathbb{P}_0=U[0,1]$、$\mathbb{P}_1=U[1,2]$，则 $V_{\text{pop}}(S;r)=2\sqrt{r_0+r_1}$。取 $\rho\approx\varepsilon$，证书误差分别约为 $s\,n^{-1/s}/\Delta$ 和 $(s\,n^{-1/s})^{1/2}$；环境维数只通过 $\log(eD/s)$ 进入，而用全部坐标需要 $D\,n^{-1/D}$ 的半径。

4.4 20 维验证（实验 1、2）

设计。 $D=20$，每类 $n\in\{25,50,100\}$，hinge 损失。

- **实验 1（零假设）**：两类都是 $N(0,I_{20})$。对每个 $d\in\{1,2,3,20\}$ 和每个子集 S，算“所需半径”：使 $V(S)\ge 1.92$（即至少撮合 96% 质量）的最小 $\rho_0+\rho_1$。$\rho_h(d,n)$ 取为 40 个开发种子上“所有子集中最大所需半径”的 95% 分位数，冻结后在 40 个新种子上确认。
- **实验 2（信号）**：1 类在前两个坐标上平移 1.0（在开发种子上从 $\{1.0,1.5\}$ 选出）。这对坐标的 Bayes hinge 风险 0.959，Bayes 总错误 0.480。半径取固定 0.6 或 $\{0.25,0.5,1,2\}\times\rho_h(d,n)$。在每类 20000 个测试点上算检测器的真实 hinge 风险；“有效”指测试 hinge 不超过证书加两倍 Monte Carlo 标准误。

d	ρ_h（$n=25/50/100$）	对数斜率	虚假可分率 @ρ_h	虚假可分率 @0.6	最好的 V@0.6
1	0.66 / 0.47 / 0.27	−0.67	0.12 / 0.05 / 0.12	0.17 / 0.00 / 0.00	1.96 / 2.00 / 2.00
2	1.28 / 0.90 / 0.60	−0.53	0.07 / 0.07 / 0.07	1.00 / 1.00 / 0.07	1.57 / 1.83 / 1.97
3	1.97 / 1.46 / 1.08	−0.40	0.07 / 0.07 / 0.07	1.00 / 1.00 / 1.00	1.03 / 1.29 / 1.52
20	17.3 / 16.0 / 15.1	−0.07	0.03 / 0.12 / 0.12	1.00 / 1.00 / 1.00	0.10 / 0.10 / 0.11

表 3: 实验 1（两类同分布，40 个确认种子）。斜率是“最大所需半径”对 n 的双对数斜率，理论值为 $-1/2,-1/2\,(\log),-1/3,-1/20$。虚假可分率 = 确认种子中存在子集的所需半径超过给定半径的比例。

看到了什么。

1. **维数效应很清楚。**$n=100$ 时 $\rho_h=0.27,0.60,1.08,15.1$（$d=1,2,3,20$）。用全部 20 个坐标需要半径 15 才诚实，这时什么都检测不出来；选择把它降到 $O(1)$。斜率随 d 变平，方向与 $n^{-1/d}$ 一致；$d=1$ 比 $-1/2$ 更陡，是因为只需撮合 96% 质量（可以丢掉尾部），加上样本量小。

半径	恢复率	证书 $V(\widehat{S})$	测试 hinge	有效率	测试总错误	按证书选 d
固定 0.6	.53/.93/1.0	1.36/1.44/1.48	1.46/1.27/1.21	.33/.93/1.0	.62/.51/.49	全选 3
$0.25\rho_h$	.28/.68/.93	1.05/1.06/1.05	1.59/1.42/1.30	0/0/0	.72/.61/.55	全选 3
$0.5\rho_h$	.53/.90/.97	1.39/1.32/1.26	1.46/1.27/1.20	.40/.70/.82	.62/.52/.50	几乎全选 3
ρ_h	.68/.97/1.0	1.76/1.60/1.49	1.47/1.29/1.21	.97/1.0/1.0	.58/.49/.49	$n \geq 50$：90–95% 选 2
$2\rho_h$	1.0/1.0/1.0	2.00/1.93/1.77	1.97/1.58/1.34	1.0/1.0/1.0	.98/.61/.48	62–97% 选 1

表 4: 实验 2，$d = 2$（真实大小），每格三个数依次对应 $n = 25/50/100$。Bayes hinge 风险 0.959，Bayes 总错误 0.480。最后一列是推论 11在 $d \in \{1, 2, 3\}$ 中按证书选出的 d。

2. **固定半径会虚假可分。**半径 0.6 下，$d = 3$ 和 $d = 20$ 在每个种子上都“证明”了两个相同的分布可分，$d = 20$ 时证书只有 0.10。在 ρ_h 下，确认集的虚假可分率是 3%–12%（目标 5%，40 次抽样的标准误约 3.4%）。

3. 命题 8 **的下界从未被违反，但很松**：比最坏子集的所需半径小约 5 倍（$d = 20$）到 230–370 倍（$d = 1$），常数没有优化。

4. **半径太小，证书无效，而且选得更差。**$0.25\rho_h$ 时证书约 1.05，测试 hinge 1.30–1.59，有效率为 0；恢复率也更低（$n = 25$ 时 0.28 对 0.68），测试总错误更高（$n = 100$ 时 0.55 对 0.49）。稳健半径同时也是正则化。

5. ρ_h **下证书有效但偏松。**证书 1.76/1.60/1.49，测试 hinge 1.47/1.29/1.21，差 0.27–0.31；而 $n = 100$ 时检测器的测试总错误 0.485 已接近 Bayes 的 0.480。**松的是证书，不是检测器。**

6. $2\rho_h$ **过度保守。**恢复率 100%，但 $n = 25$ 时证书 ≈ 2，检测器几乎是常数（总错误 0.98）。

7. **选** d**。**半径不够大（固定 0.6、$0.25\rho_h$、$0.5\rho_h$）时，证书总是偏向最大的 $d = 3$，证书几乎全部无效：惩罚不够，加坐标总是“更好”。在 ρ_h 下，$n \geq 50$ 时 90%–95% 选对 $d = 2$，证书全部有效；$n = 25$ 时一半选 $d = 1$（信号相对半径太弱）。$2\rho_h$ 惩罚过度，偏向 $d = 1$。所以半径的**形状**（随 d 增长）和**水平**（倍数）都要对。

4.5 问题与下一步

- ρ_h **的标定用到了已知的零分布** $N(0, I)$，实际中不知道。下一步：数据驱动标定，例如把两类合并后随机重分标签，或在每类内部随机对半分，测所需半径的分位数；这正是同分布零假设下的量。

- **证书松约 0.3。**来源是定理右端的 $V_{\mathrm{pop}}(S; 2\rho)$。可能的收紧：命题 7里 $\lambda_k(\mathcal{W}_1 - \rho_k)$ 一项在半径有富余时为负，可以用估计的 $\mathcal{W}_1$ 扣回一部分；或者改用受限检测器类。

- **锐利半径**：半径在 $\frac{d}{4e}(4Mn)^{-1/d}$ 和 $c\,d\,n^{-1/d} + d^{3/2}\sqrt{\log(eD/d)/n}$ 之间。$\log(eD/d)$ 项是否必要?

- **受限检测器**：$n^{-1/d}$ 是非参数类 $\mathcal{F}_S$ 的代价（它能记住孤立点）。线性或核检测器按 [10] 的变差分析，半径可能只需 $\sqrt{d\log(eD/d)/n}$。

猜想 13 (诚实松弛)**.** 【猜想】给命题 4中每个加权度量配上让它诚实的半径（权重 $\zeta_m = d/D$ 时，小尺度下它有 D 维立方体的覆盖数），松弛相对最好的稀疏选择的改进就不会超过夹逼宽度。那么第 3 节的间隙只是一个统计假象。

n	d	枚举（匹配形式）	式 (2)（HiGHS）	松弛	OA 上界/下界	OA 状态
25	2	1.2811（0.1 s）	1.2811（2.2 s，35 节点）	0.7142	1.2811 / 1.2811	最优，190 个子集，18 s
25	3	0.8762（0.3 s）	0.8762（9.5 s，1457 节点）	0.4881	0.8762 / 0.2842	600 s 超时，920 个子集
50	2	1.3210（0.2 s）	1.3210（7.0 s，33 节点）	0.7776	1.3210 / 1.3210	最优，190 个子集，63 s
50	3	1.0242（1.2 s）	1.0242（40.0 s，1559 节点）	0.5316	1.0242 / 0.1731	600 s 超时，1090 个子集

表 5: 实验 3。数值以 V 的尺度给出；“松弛” 指式 (2)的连续松弛；OA 是核心包的算法 1。$d = 2, 3$ 时分别共有 190 和 1140 个子集。

5 方向 B：选择就是匹配阻断（计算）

想法。由第 3 节，$\min_{|S|\le d} m_S(\rho)$ 是一个双人博弈：防守方选坐标抬高点对代价，对手买得起多大的跨类匹配就买多大。把“给坐标定价”换成“删边”，就是匹配阻断 [31]；加坐标会缩小对手的可行集，是单调跟随者的设定 [8]；一般背景见 [25]。式 (2)是精确的，命题 5说搜索树绕不开。剩下的收益只能来自“跟随者是匹配”这个结构，以及“统计上可以提前停”的理由。

命题 14 (匹配下界)**.**【已证，未测试】设 $\pi \ge 0$ 满足式 (1)的行列约束，$\kappa_m = \sum_{i,j} \pi_{ij} C^m_{ij}$。对每个 S，$m_S(\rho) \ge \sum_{i,j} \pi_{ij} \cdot \min\{1, \rho / \sum_{m\in S} \kappa_m\}$。在搜索树上固定 I 在内、J 待定的节点，把 $\sum_{m\in S} \kappa_m$ 换成 $\sum_{m\in I} \kappa_m$ 加上 J 中最大的 $d - |I|$ 个 κ_m，界对所有补全成立。

为什么：把 π 等比例缩小，行列约束仍成立，代价降到 ρ 以内。

这个界对整个匹配按它在 S 下的真实代价收费，而正式笔记的割关于 z 是仿射的。每个匹配、每个节点只要 $O(D \log D)$。

推论 15 (诚实容差)**.**【在引理 9 下已证】若搜索在绝对间隙 τ 处停止，得到 $\widehat{S}_\tau$，则在定理 10的事件上 $R_{\text{true}}(\widehat{f}) \le V(\widehat{S}_\tau; \rho) \le \min_{|S|\le d} V_{\text{pop}}(S; 2\rho) + \tau$。

自然的 τ 是夹逼宽度 $4\eta/(1-\eta)$：比它小的差别没有统计意义。不过容差本身省不了多少：表 1中 $D = 50$ 的例子，相对容差 10%、5%、2% 分别在 209、211、220 秒停止，默认容差 235 秒，都找到了最优子集——求解器很早就找到最优解，时间都花在抬下界上。

命题 16 (一般损失)**.**【草证】对正式笔记中的任意损失，把 Eq. (4) 里的距离 $\lambda_k \|x_i^{(k)}[S] - y[S]\|_1$ 换成

$$\sum_m w_{km} |x_i^{(k)}[m] - y[m]|, \qquad 0 \le w_{km} \le \lambda_k, \quad \rho_k w_{km} \le 2 z_m, \quad z \in \mathcal{Z}_d,$$

得到的混合整数程序的值是 $\min_{|S|\le d} V(S)$。

为什么：$g = 0, a = \mathbf{1}, \lambda = 0$ 的值是 2，所以最优时 $\rho_k \lambda_k \le 2$，于是 $w_{km} = \lambda_k z_m$ 可行且最优。

分段线性损失下它是 N^2 行、两个价格的 MILP；hinge 下命题 2把它化成式 (2)：一个价格、$n_0 n_1$ 行。

20 维验证（实验 3）。 $\rho_0 + \rho_1 = 0.6$，取第一个确认种子的信号数据，结果见表 5。式 (2)每次都和枚举一致。但在 $D = 20$ 时，枚举（每个子集一次匈牙利算法）反而最快；OA 退化成很慢的枚举：它的割是正式笔记中 F 的切线，而 F 的连续松弛很弱，切线在没评估过的子集上给出的下界很低，$d = 3$ 时甚至低于式 (2)的松弛。所以 $D = 20$ 量级直接枚举即可，式 (2)的价值在 $D \ge 50$（表 1）。

下一步。匹配下界加上惰性生成点对行（从跨类最近邻开始）；最优性证书需要多少个匹配，在命题 12的间隔下是否多项式个就够（恢复的计算版本）；在 100 维研究上用式 (2)替代 OA。

6 方向 C：随机化选择（探索）

博弈。本节 $\rho = \rho_0 + \rho_1$，$V_S(r) = 2m_S(r)$。防守方按分布 p 随机抽一个 $|S| \le d$ 和检测器 $f \in \mathcal{F}_S$；对手知道 p 但不知道抽签结果，选 $(Q_0, Q_1) \in \mathcal{P}_0 \times \mathcal{P}_1$。记防守方最好的最坏期望风险为 $\mathrm{OPT}_{\mathrm{rand}} \le \mathrm{OPT} = \min_{|S|\le d} V(S)$。参考：有限博弈的 LP 对偶；对抗分类中的随机化防守 [23, 17]；删特征博弈 [12]；相容边际的延拓 [27]。

引理 17 (代价可分)**.** 【已证】攻击的坐标代价 $r_m = \sum_k \int |x[m] - y[m]|\, d\gamma_k$ 满足 $\sum_m r_m \le \rho$，且它在 S 上的投影代价不超过 $r(S) = \sum_{m\in S} r_m$。

由命题 3，每个价格 λ 和见证 h 给出 S 上的一个检测器，它在投影代价为 r 的攻击下风险至多 $A + \Lambda r$，$A = 2(1-\beta_\lambda)$，$\Lambda = 2\lambda$；$V_S(r)$ 是这些切线的下包络。

定理 18 (随机化可达值)**.** 【已证】对有限切线族 $T = \{(S_t, A_t, \Lambda_t)\}$，最优混合的最坏期望风险至多

$$W_T = \min_{p} \max_{m\in[D]} \Big\{ \sum_t p_t A_t + \rho \sum_{t:\, m\in S_t} p_t \Lambda_t \Big\} = \max_{r\ge 0,\ \mathbf{1}^\top r \le \rho} \ \min_{t\in T} \big\{ A_t + \Lambda_t r(S_t) \big\}. \tag{3}$$

T 取遍所有切线时 W_T 降到 $\overline{W} = \max_r \min_{|S|\le d} V_S(r(S))$，且 $\mathrm{OPT}_{\mathrm{rand}} \le \overline{W} \le \mathrm{OPT}$。

为什么：混合的期望风险关于攻击代价向量 r 是线性的、斜率非负，所以最坏攻击把全部预算砸在一个坐标上（$r = \rho e_m$），这给出左边；LP 对偶给出等式。$\sum_{t:\, m\in S_t} p_t\Lambda_t$ 是坐标 m 的“价格暴露”：对手打最暴露的坐标，混合把暴露摊开，固定选择则把自己的 d 个坐标完全暴露。

定理 19 (不相交候选：注水)**.** 【已证】若候选子集两两不交（特别是 $d = 1$），则 $\mathrm{OPT}_{\mathrm{rand}} = \overline{W} = \max\{t : \sum_S V_S^{-1}(t) \le \rho\}$，其中 $V_S^{-1}(t) = \inf\{r : V_S(r) \ge t\}$。

为什么：上界来自定理 18；最优预算让各候选的值相等，就是注水。下界：在每个候选块上取对应预算的最不利分布对，各块独立移动，代价按块相加，所以合起来仍在预算内，而每个投影都是它自己的最不利分布对。例子：每类一个点 $(0,0)$ 和 $(1,1)$，$\rho = 1/2$，$d = 1$：固定选择的值是 1，注水给 $r^\star = (1/4, 1/4)$、值 $1/2$。

命题 20 (对抽样误差无增益)**.** 【已证】在定理 10的设定下，混合的证书是各固定证书的平均 $\sum_t p_t(A_t + \Lambda_t \sum_k \varepsilon_k)$，不小于其中最好的一个。

为什么：抽样误差不会“分摊预算”：覆盖事件允许每个投影同时偏离满半径。

数据	d	固定 $\min_S V(S)$	随机化 W_T	注水	松弛	测试 hinge：固定/混合
$D = 10$，$N = 30$	1	1.78	1.24	–	1.53	–
$D = 10$，$N = 30$	2	1.40	0.59	–	0.89	–
$D = 15$，$N = 30$	2	1.12	0.41	–	0.75	–
$D = 12$，$N = 30$	3	0.87	0.32	–	0.49	–
20 维，$n = 25$	1	1.765	1.200	1.189	1.371	1.475 / 1.915
20 维，$n = 25$	2	1.394	0.446	–	0.737	1.527 / 1.981

表 6: 前四行是表 1的例子（`dev_checks.py --random`）；后两行是 20 维实验 4（信号数据，5 个种子平均）。$\rho_0 + \rho_1 = 0.6$，W_T 用每个 V_S 在 23 个半径处的切线。最后一列：直接从真分布抽测试数据时，固定最优检测器与最优混合的 hinge 风险。

看到了什么。对抗意义下随机化的收益很大：20 维 $d = 2$ 时 $W_T = 0.45$，固定最优是 1.39，连松弛 0.74 都比它差。$d = 1$ 时 $W_T = 1.200$ 略高于精确的注水值 1.189（有限切线的误差），符

合定理 19。但**面对抽样误差时混合更差**：测试 hinge 1.92/1.98 对固定的 1.48/1.53。原因是最优混合要把价格暴露摊到很多坐标上，它只把 11%–36%（$d = 1$）和 18%–26%（$d = 2$）的权重放在含信号坐标的子集上。这正是命题 20说的：随机化只对“先承诺、共用一笔预算的战略对手”有用，例如巡检、筛查、传感器调度，保证也只是对抛硬币取平均。

猜想 21 (紧性)**.** 【猜想】候选为所有大小 $d \geq 2$ 的子集时，某些例子上 $\mathrm{OPT}_{\mathrm{rand}} < \overline{W}$；若最优预算下的最不利分布对能在一个可分解族的交集上取成一致的，则等号成立 [27]。

计算 $\overline{W}$ 需要对式 (3)做列生成：给定预算向量 r，定价问题是 $\min_{|S|\leq d} V_S(r(S))$，即把式 (2)中的 $\rho\lambda$ 换成 $r^\top w$。

7 优先级

1. **方向 A（诚实半径）** 故事最强、成本最低：在高维里，正是选择让 Wasserstein 稳健检验变得有效。20 维检查支持了三点：随维数增长的半径消除虚假可分；它同时改善恢复；用证书选 d 在半径水平正确时选对。下一步：数据驱动的半径标定（置换），收紧证书，$d \leq 2$ 的显式常数，$D = 100$ 的恢复实验，与核变量选择 [28] 对比。

2. **方向 B（匹配阻断）**：$D \geq 50$ 时把式 (2)放进核心包替代 OA，然后加匹配下界。$D = 20$ 时枚举就够。

3. **方向 C（随机化）**：探索性。两个定理已证；下一步是猜想 21背后的边际问题、列生成原型，以及一个有战略对手的应用。

结果	状态
命题 1、2、3：散度、匹配、见证形式	已证；2、3 数值核对过
命题 4、5：紧凑程序、NP 难	已证
引理 6，命题 7、8	已证；8 在 20 维上核对过
引理 9：一致覆盖	标准，草证
定理 10，推论 11、15，命题 12	在引理 9 下已证；20 维上验证了现象
命题 14：匹配下界	已证，未测试
命题 16：一般损失	草证
定理 18、19，命题 20	已证；20 维上核对过
猜想 13、21	开放

表 7: 各结果的状态。

参考文献

[1] Peter L. Bartlett, Stéphane Boucheron, and Gábor Lugosi. Model selection and error estimation. *Machine Learning*, 48:85–113, 2002.

[2] Luis A. Caffarelli and Robert J. McCann. Free boundaries in optimal transport and Monge–Ampère obstacle problems. *Annals of Mathematics*, 171(2):673–730, 2010.

[3] Laetitia Chapel, Mokhtar Z. Alaya, and Gilles Gasso. Partial optimal transport with applications on positive-unlabeled learning. In *Advances in Neural Information Processing Systems*, volume 33, 2020.

[4] Carlos Cotta and Pablo Moscato. The k-feature set problem is W[2]-complete. *Journal of Computer and System Sciences*, 67(4):686–690, 2003.

[5] Scott Davies and Stuart Russell. NP-completeness of searches for smallest possible feature sets. In *AAAI Fall Symposium on Relevance*, 1994.

[6] Richard M. Dudley. *Real Analysis and Probability*. Cambridge University Press, 2nd edition, 2002.

[7] Alessio Figalli. The optimal partial transport problem. *Archive for Rational Mechanics and Analysis*, 195(2):533–560, 2010.

[8] Matteo Fischetti, Ivana Ljubić, Michele Monaci, and Markus Sinnl. Interdiction games and monotonicity, with application to knapsack problems. *INFORMS Journal on Computing*, 31(2):390–410, 2019.

[9] Nicolas Fournier and Arnaud Guillin. On the rate of convergence in Wasserstein distance of the empirical measure. *Probability Theory and Related Fields*, 162:707–738, 2015.

[10] Rui Gao. Finite-sample guarantees for Wasserstein distributionally robust optimization: Breaking the curse of dimensionality. *Operations Research*, 71(6):2291–2306, 2023.

[11] Rui Gao, Liyan Xie, Yao Xie, and Huan Xu. Robust hypothesis testing using Wasserstein uncertainty sets. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[12] Amir Globerson and Sam Roweis. Nightmare at test time: Robust learning by feature deletion. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 353–360, 2006.

[13] Leonid G. Hanin. Kantorovich–Rubinstein norm and its application in the theory of Lipschitz spaces. *Proceedings of the American Mathematical Society*, 115(2):345–352, 1992.

[14] Peter J. Huber. A robust version of the probability ratio test. *The Annals of Mathematical Statistics*, 36(6):1753–1758, 1965.

[15] Peter J. Huber and Volker Strassen. Minimax tests and the Neyman–Pearson lemma for capacities. *The Annals of Statistics*, 1(2):251–263, 1973.

[16] Colin McDiarmid. On the method of bounded differences. In *Surveys in Combinatorics*, volume 141 of *London Mathematical Society Lecture Note Series*, pages 148–188. Cambridge University Press, 1989.

[17] Laurent Meunier, Meyer Scetbon, Rafael Pinot, Jamal Atif, and Yann Chevaleyre. Mixed Nash equilibria in the adversarial examples game. In *Proceedings of the 38th International Conference on Machine Learning*, pages 7677–7687, 2021.

[18] Jonas Mueller and Tommi Jaakkola. Principal differences analysis: Interpretable characterization of differences between distributions. In *Advances in Neural Information Processing Systems*, volume 28, 2015.

[19] XuanLong Nguyen, Martin J. Wainwright, and Michael I. Jordan. On surrogate loss functions and f-divergences. *The Annals of Statistics*, 37(2):876–904, 2009.

[20] François-Pierre Paty and Marco Cuturi. Subspace robust Wasserstein distances. In *Proceedings of the 36th International Conference on Machine Learning*, pages 5072–5081, 2019.

[21] Mathis Petrovich, Chao Liang, Ryoma Sato, Yanbin Liu, Yao-Hung Hubert Tsai, Linchao Zhu, Yi Yang, Ruslan Salakhutdinov, and Makoto Yamada. Feature-robust optimal transport for high-dimensional data. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, volume 13717 of *Lecture Notes in Computer Science*, pages 291–307, 2022.

[22] Benedetto Piccoli and Francesco Rossi. Generalized Wasserstein distance and its application to transport equations with source. *Archive for Rational Mechanics and Analysis*, 211(1):335–358, 2014.

[23] Rafael Pinot, Raphael Ettedgui, Geovani Rizk, Yann Chevaleyre, and Jamal Atif. Randomization matters. How to defend against strong adversarial attacks. In *Proceedings of the 37th International Conference on Machine Learning*, 2020.

[24] Mark D. Reid and Robert C. Williamson. Information, divergence and risk for binary experiments. *Journal of Machine Learning Research*, 12:731–817, 2011.

[25] J. Cole Smith and Yongjia Song. A survey of network interdiction models and algorithms. *European Journal of Operational Research*, 283(3):797–811, 2020.

[26] Volker Strassen. The existence of probability measures with given marginals. *The Annals of Mathematical Statistics*, 36(2):423–439, 1965.

[27] N. N. Vorob'ev. Consistent families of measures and their extensions. *Theory of Probability and its Applications*, 7(2):147–163, 1962.

[28] Jie Wang, Santanu S. Dey, and Yao Xie. Variable selection for kernel two-sample tests, 2023. arXiv:2302.07415.

[29] Jie Wang, Rui Gao, and Yao Xie. Two-sample test using projected Wasserstein distance. In *IEEE International Symposium on Information Theory*, 2021.

[30] Jonathan Weed and Francis Bach. Sharp asymptotic and finite-sample rates of convergence of empirical measures in Wasserstein distance. *Bernoulli*, 25(4A):2620–2648, 2019.

[31] Rico Zenklusen. Matching interdiction. *Discrete Applied Mathematics*, 158(15):1676–1690, 2010.