Wasserstein 鲁棒假设检验中的变量选择

1 问题表述

本文研究鲁棒假设检验中的变量选择问题。令$[D]=\{1,\dots,D\}$，以正整数d 表示允许选择的变量数。给定检测函数$f:\mathbb{R}^D\to\mathbb{R}$，遵循文献[2] 的约定，将最坏情形风险定义为

$$R(f)=\sup_{\mathbb{P}_0\in\mathcal{P}_0,\mathbb{P}_1\in\mathcal{P}_1}\left\{\mathbb{E}_{\mathbb{P}_0}\ell(-f(X))+\mathbb{E}_{\mathbb{P}_1}\ell(f(X))\right\},\tag{1}$$

其中，$\mathcal{P}_k,k=0,1$ 为基于Wasserstein 距离构造的分布不确定集；生成函数$\ell(\cdot)$ 非负、非减且为凸函数，并满足$\ell(0)=1,\lim_{t\to-\infty}\ell(t)=0$。对于$k=0,1$，假设第$k$ 类中有n_k 个观测，记为$\{x_i^{(k)}\}_{i=1}^{n_k}$。将相应的经验分布记为$\widehat{\mathbb{P}}_k=\frac{1}{n_k}\sum_{i=1}^{n_k}\delta_{x_i^{(k)}}$，构造Wasserstein 不确定集

$$\mathcal{P}_k=\left\{\mathbb{P}_k:\ \mathcal{W}_1(\widehat{\mathbb{P}}_k,\mathbb{P}_k)\le\rho_k\right\}.$$

这里，$\mathcal{W}_1(\cdot,\cdot)$ 表示以ℓ_1 范数为运输成本的1-Wasserstein 距离。

对于$S\subseteq[D]$，定义仅依赖于S 中坐标的检测函数类：

$$\mathcal{F}_S=\left\{f:\ \mathbb{R}^D\to\mathbb{R},f(x)=g(x[S])，\text{其中}g:\ \mathbb{R}^{|S|}\to\mathbb{R}\text{ 为某个可测函数}\right\}.$$

对于向量$x\in\mathbb{R}^D$，以$x[i]$ 表示其第i 个坐标，以$x[S]$ 表示下标属于S 的坐标组成的向量。所研究的变量选择问题可写成如下组合优化问题：

$$\min_{S\subseteq[D],|S|\le d}\ \min_{f\in\mathcal{F}_S}\ R(f).\tag{2}$$

2 凸优化表示

假设$n_0,n_1\ge1$、$\rho_0,\rho_1>0$，且ℓ 在$\mathbb{R}$ 上有限。所有分布的一阶矩均有限。固定$S\subseteq[D]$，记

$$V(S)=\min_{f\in\mathcal{F}_S}R(f),\qquad\mathcal{X}=\{x_i^{(0)}:i\in[n_0]\}\cup\{x_j^{(1)}:j\in[n_1]\}.$$

以下引理将文献[3, 引理 2，式 (7)] 的有限支撑表示推广至第 1 节的生成损失。证明见附录 A，其中包括投影与检测函数延拓。

引理2.1 (有限维最不利分布重构)**.** 固定选集的风险为

$$\begin{aligned}
V(S)=\max_{p,\gamma\ge0}\quad&\sum_{y\in\mathcal{X}}\inf_{v\in\mathbb{R}}\{p_0(y)\ell(-v)+p_1(y)\ell(v)\}\\
\text{约束为}\quad&\sum_{y\in\mathcal{X}}\gamma_{i,y}^{(k)}=\frac{1}{n_k},&&i\in[n_k],\ k=0,1,\\
&p_k(y)=\sum_{i=1}^{n_k}\gamma_{i,y}^{(k)},&&y\in\mathcal{X},\ k=0,1,\\
&\sum_{i=1}^{n_k}\sum_{y\in\mathcal{X}}\gamma_{i,y}^{(k)}\|x_i^{(k)}[S]-y[S]\|_1\le\rho_k,&&k=0,1.
\end{aligned}\tag{3}$$

其中，$\gamma_{i,y}^{(k)}$ 是从$x_i^{(k)}[S]$ 运至$y[S]$ 的质量，$p_k(y)$ 为目标点质量。

以g_y 表示赋给$y[S]$ 的评分。代入目标点质量，得到

$$\sum_{y\in\mathcal{X}}\inf_{v\in\mathbb{R}}\{p_0(y)\ell(-v)+p_1(y)\ell(v)\}=\inf_g\left\{\sum_{i,y}\gamma_{i,y}^{(0)}\ell(-g_y)+\sum_{j,y}\gamma_{j,y}^{(1)}\ell(g_y)\right\}.$$

目标函数关于g 为凸函数、关于γ 为线性函数，运输可行集为紧凸集。由有限维极小极大定理，得到

$$V(S) = \inf_{g} \left\{ \max_{\gamma^{(0)}} \sum_{i,y} \gamma^{(0)}_{i,y} \ell(-g_y) + \max_{\gamma^{(1)}} \sum_{j,y} \gamma^{(1)}_{j,y} \ell(g_y) \right\},$$

其中，各最大化问题满足式 (3) 中相应的源质量与运输预算约束。

固定评分向量g，对式 (3) 中的质量约束与运输约束，分别引入乘子$a_i^{(0)} \in \mathbb{R}$ 和$\lambda_0 \geq 0$。关于$\gamma^{(0)}$ 的最大化问题具有拉格朗日函数

$$\begin{aligned} \mathcal{L}_0 = & \sum_{i,y} \gamma^{(0)}_{i,y} \ell(-g_y) + \sum_i a_i^{(0)} \left(\frac{1}{n_0} - \sum_y \gamma^{(0)}_{i,y} \right) \\ & + \lambda_0 \left(\rho_0 - \sum_{i,y} \gamma^{(0)}_{i,y} \| x_i^{(0)}[S] - y[S] \|_1 \right) \\ = & \frac{1}{n_0} \sum_i a_i^{(0)} + \rho_0 \lambda_0 \\ & + \sum_{i,y} \gamma^{(0)}_{i,y} \left[\ell(-g_y) - a_i^{(0)} - \lambda_0 \| x_i^{(0)}[S] - y[S] \|_1 \right]. \end{aligned} \tag{4}$$

因此，

$$\sup_{\gamma^{(0)} \geq 0} \mathcal{L}_0 < \infty \iff \ell(-g_y) \leq a_i^{(0)} + \lambda_0 \| x_i^{(0)}[S] - y[S] \|_1, \quad i \in [n_0],\ y \in \mathcal{X}.$$

对两类分别应用线性规划对偶，得到

$$\begin{aligned} V(S) = \min_{g,a,\lambda} \quad & \frac{1}{n_0} \sum_i a_i^{(0)} + \frac{1}{n_1} \sum_j a_j^{(1)} + \rho_0 \lambda_0 + \rho_1 \lambda_1 \\ \text{约束为} \quad & \ell(-g_y) \leq a_i^{(0)} + \lambda_0 \| x_i^{(0)}[S] - y[S] \|_1, && i \in [n_0],\ y \in \mathcal{X}, \\ & \ell(g_y) \leq a_j^{(1)} + \lambda_1 \| x_j^{(1)}[S] - y[S] \|_1, && j \in [n_1],\ y \in \mathcal{X}, \\ & g \in \mathbb{R}^{\mathcal{X}}, \quad a^{(k)} \in \mathbb{R}^{n_k}, \quad \lambda_k \geq 0, && k = 0, 1. \end{aligned} \tag{5}$$

将该目标函数记为$J(a, \lambda)$。附录 A 证明其与可测检测函数上的最优风险等价。

令$z = \mathbf{1}_S$，并记$\mathcal{Z}_d = \{ z \in \{0,1\}^D : \mathbf{1}^\top z \leq d \}$。运输成本可按坐标分解:

$$\| x_i^{(k)}[S] - y[S] \|_1 = \sum_{m=1}^{D} z_m | x_i^{(k)}[m] - y[m] |.$$

引入w_{km} 表示坐标是否被激活，并将选择指示变量扩展至$z \in [0,1]^D$。定义

$$\begin{aligned} F(z) = \min_{g,a,\lambda,w} \quad & J(a, \lambda) \\ \text{约束为} \quad & \ell(-g_y) \leq a_i^{(0)} + \sum_m w_{0m} | x_i^{(0)}[m] - y[m] |, && i \in [n_0],\ y \in \mathcal{X}, \\ & \ell(g_y) \leq a_j^{(1)} + \sum_m w_{1m} | x_j^{(1)}[m] - y[m] |, && j \in [n_1],\ y \in \mathcal{X}, \\ & 0 \leq w_{km} \leq \lambda_k, && k = 0, 1,\ m \in [D], \\ & \rho_0 w_{0m} + \rho_1 w_{1m} \leq 2 z_m, && m \in [D], \\ & g \in \mathbb{R}^{\mathcal{X}}, \quad a^{(k)} \in \mathbb{R}^{n_k}, \quad \lambda_k \geq 0, && k = 0, 1. \end{aligned} \tag{6}$$

约束关于(z, g, a, λ, w) 联合凸，故部分最小化定义了$[0,1]^D$ 上的凸函数F。当$z = \mathbf{1}_S$ 时，约束使$m \notin S$ 对应的$w_{km} = 0$，并允许在最优解处对$m \in S$ 取$w_{km} = \lambda_k$。因此，

$$F(\mathbf{1}_S) = V(S), \qquad \min_{|S| \leq d} V(S) = \min_{z \in \mathcal{Z}_d} F(z). \tag{7}$$

该连续扩展保持每个二元选集处的目标值；在连续预算集合上最小化则得到松弛。离散问题具有文献[1, 问题 (2.1)–(2.2)] 中逻辑约束模型的形式。附录 B 给出精确性与最优值可达性的证明。

对式 (6) 的损失约束引入乘子$\gamma_{i,y}^{(k)} \ge 0$，对坐标约束引入乘子$\mu_m \ge 0$。所得对偶如下。

命题2.2 (对偶表示)**.** 对于每个$z \in [0,1]^D$，

$$F(z) = \max_{(\gamma,\mu)\in\mathcal{D}} \{H(\gamma) - 2\mu^\top z\}, \tag{8}$$

其中

$$H(\gamma) = \sum_{y\in\mathcal{X}} \inf_{v\in\mathbb{R}} \left\{ \sum_{i=1}^{n_0} \gamma_{i,y}^{(0)} \ell(-v) + \sum_{j=1}^{n_1} \gamma_{j,y}^{(1)} \ell(v) \right\}, \tag{9}$$

且

$$\mathcal{D} = \left\{ (\gamma,\mu) \ge 0 : \begin{array}{ll} \displaystyle\sum_{y\in\mathcal{X}} \gamma_{i,y}^{(k)} = 1/n_k, & i \in [n_k],\ k = 0,1, \\ \displaystyle\sum_{m=1}^{D} \left(\sum_{i=1}^{n_k} \sum_{y\in\mathcal{X}} \gamma_{i,y}^{(k)} |x_i^{(k)}[m] - y[m]| - \rho_k \mu_m \right)_+ \le \rho_k, & k = 0,1 \end{array} \right\}, \tag{10}$$

这里，$(v)_+ = \max\{v, 0\}$，且最大值可以取得。对于z^t 处的最优解(γ^t, μ^t)，

$$\begin{aligned} F(z) &\ge c_t(z) := H(\gamma^t) - 2(\mu^t)^\top z \\ &= F(z^t) - 2(\mu^t)^\top (z - z^t), \qquad z \in [0,1]^D, \end{aligned} \tag{11}$$

并且$c_t(z^t) = F(z^t)$。

证明见附录 B。

3 外逼近方法

命题 2.2 给出具有文献[1, 定理 2.5 与算法 3.1] 所述形式的外逼近方法。令$\mathrm{OPT} = \min_{z\in\mathcal{Z}_d} F(z)$。评估$z^1, \dots, z^t$ 并取得相应的对偶最优解后，令$U_t = \min_{s\le t} F(z^s)$，求解

$$\begin{aligned} (z^{t+1}, L_t) \in \ & \operatorname*{arg\,min}_{z\in\mathcal{Z}_d,\ \eta\ge 0} \quad \eta \\ & \text{约束为} \quad \eta \ge F(z^s) - 2(\mu^s)^\top (z - z^s), \qquad s = 1, \dots, t. \end{aligned} \tag{12}$$

由式 (11)，

$$L_t \le \mathrm{OPT} \le U_t. \tag{13}$$

从任意$z^1 \in \mathcal{Z}_d$ 出发，交替求解凸子问题(6)–(8) 与二元线性主问题 (12)。当$U_t - L_t \le \varepsilon$ 时停止，返回最优的已评估选集。附录 A 恢复其检测函数，其风险为U_t，最优性间隙至多为ε。若内层求解非精确，则以实际可行对偶表达式$H(\gamma^t) - 2(\mu^t)^\top z$ 为割，以原始可行目标值为上界；主问题须提供全局下界。

A 引理 2.1 的证明

证明. 下文关于γ 的最大化与关于(g, a, λ) 的最小化分别受式 (3) 与式 (5) 的约束。令$S^c = [D] \setminus S$。对于每个源点–目标点对，定义提升后的目标点

$$\widetilde{y}_i^{(k)}[S] = y[S], \qquad \widetilde{y}_i^{(k)}[S^c] = x_i^{(k)}[S^c], \qquad \mathbb{P}_k^{\gamma} = \sum_{i,y} \gamma_{i,y}^{(k)} \delta_{\widetilde{y}_i^{(k)}}.$$

于是

$$\mathcal{W}_1(\widehat{\mathbb{P}}_k, \mathbb{P}_k^{\gamma}) \le \sum_{i,y} \gamma_{i,y}^{(k)} \|x_i^{(k)} - \widetilde{y}_i^{(k)}\|_1 = \sum_{i,y} \gamma_{i,y}^{(k)} \|x_i^{(k)}[S] - y[S]\|_1 \le \rho_k.$$

因此，对于每个$f(x)=g(x[S])$，

$$\begin{aligned} R(f) &\geq \sum_{y}\{p_0(y)\ell(-g(y[S]))+p_1(y)\ell(g(y[S]))\} \\ &\geq H(\gamma), \qquad \max_{\gamma} H(\gamma)\leq V(S), \end{aligned} \tag{14}$$

其中，H 为式 (9) 中的目标函数。由有限维极小极大定理与式 (4)–(5) 中的线性规划对偶，得到

$$\begin{aligned} \max_{\gamma} H(\gamma) &= \inf_{g\in\mathbb{R}^{\mathcal{X}}} \max_{\gamma} \sum_{y}\{p_0(y)\ell(-g_y)+p_1(y)\ell(g_y)\} \\ &= \inf_{(g,a,\lambda)} J(a,\lambda). \end{aligned} \tag{15}$$

固定任意可行解(g,a,λ)。重合的投影目标点具有相同的约束列，故可令其评分相等。取$g(y[S])=g_y$，并定义

$$E_k(\xi)=\min_{r\in[n_k]}\{a_r^{(k)}+\lambda_k\|x_r^{(k)}[S]-\xi\|_1\}, \qquad k=0,1.$$

在投影目标集合之外，分别选取达到$E_0(\xi),E_1(\xi)$ 的最小下标i,j，令

$$r_0=\|x_i^{(0)}[S]-\xi\|_1, \quad r_1=\|x_j^{(1)}[S]-\xi\|_1, \quad b=\|x_i^{(0)}[S]-x_j^{(1)}[S]\|_1,$$

$$\tau=\begin{cases}\min\{1,r_0/b\}, & b>0,\\ 0, & b=0,\end{cases} \qquad g(\xi)=(1-\tau)g_{x_i^{(0)}}+\tau g_{x_j^{(1)}}. \tag{16}$$

三角不等式给出

$$b\leq r_0+r_1, \qquad \tau b\leq r_0, \qquad (1-\tau)b\leq r_1.$$

由凸性、源点约束及交叉目标点约束，得到

$$\begin{aligned} \ell(-g(\xi)) &\leq (1-\tau)\ell(-g_{x_i^{(0)}})+\tau\ell(-g_{x_j^{(1)}}) \\ &\leq a_i^{(0)}+\lambda_0\tau b\leq a_i^{(0)}+\lambda_0 r_0=E_0(\xi), \\ \ell(g(\xi)) &\leq (1-\tau)\ell(g_{x_i^{(0)}})+\tau\ell(g_{x_j^{(1)}}) \\ &\leq a_j^{(1)}+\lambda_1(1-\tau)b\leq a_j^{(1)}+\lambda_1 r_1=E_1(\xi). \end{aligned} \tag{17}$$

在投影目标点处，相同的界直接由式 (5) 得到。最小化下标的选取规则为Borel 可测；赋予有限个观测值仍保持可测性，且$|g|\leq\max_y|g_y|$。对从经验分布到$\mathbb{P}_k$ 的最优耦合积分式 (17)，对于每个$\mathbb{P}_k\in\mathcal{P}_k$，得到

$$\begin{aligned} \mathbb{E}_{\mathbb{P}_0}\ell(-g(X[S])) &\leq \frac{1}{n_0}\sum_i a_i^{(0)}+\rho_0\lambda_0, \\ \mathbb{E}_{\mathbb{P}_1}\ell(g(X[S])) &\leq \frac{1}{n_1}\sum_j a_j^{(1)}+\rho_1\lambda_1. \end{aligned}$$

因此

$$\max_{\gamma} H(\gamma)\leq V(S)\leq \inf_{(g,a,\lambda)} J(a,\lambda)=\max_{\gamma} H(\gamma).$$

由于$g=0$ 时有$J(\mathbf{1},0)=2$，子水平集$J\leq 2$ 非空，其可行点满足

$$0\leq a_i^{(k)}\leq 2n_k, \qquad 0\leq\lambda_k\leq 2/\rho_k.$$

损失约束同时控制$\ell(g_y)$ 与$\ell(-g_y)$；由$t\to\infty$ 时$\ell(t)\to\infty$，每个g_y 均有界。该子水平集紧致，因此有限维最小值及其恢复的检测函数均达到$V(S)$，且每个最优解满足

$$\rho_0\lambda_0+\rho_1\lambda_1\leq J(a,\lambda)=V(S)\leq 2. \tag{18}$$

由于H 在紧运输可行集上为上半连续函数，有限维最不利分布的最大值亦可取得。 □

B 命题 2.2 的证明

证明. 由附录 A 中的界及$0 \le w_{km} \le \lambda_k$，非空子水平集$J \le 2$ 紧致，故$F(z)$ 取得最小值。当$z = \mathbf{1}_S$ 时，由式 (18)，固定选集的最优解可通过$w_{km} = \lambda_k z_m$ 提升。反之，

$$0 \le w_{km} \le \lambda_k z_m \quad \Longrightarrow \quad \sum_m w_{km} |x_i^{(k)}[m] - y[m]| \le \lambda_k \|x_i^{(k)}[S] - y[S]\|_1,$$

这就证明了式 (7)。

对损失约束、$w_{km} \le \lambda_k$ 及坐标容量约束，分别引入非负乘子γ, β, μ。保留g, a 为自由变量、$\lambda, w \ge 0$，整理拉格朗日函数，得到

$$\begin{aligned} \mathcal{L} = & -2\mu^\top z + \sum_{y \in \mathcal{X}} \left[\ell(-g_y) \sum_{i=1}^{n_0} \gamma_{i,y}^{(0)} + \ell(g_y) \sum_{j=1}^{n_1} \gamma_{j,y}^{(1)} \right] \\ & + \sum_{k=0}^{1} \sum_{i=1}^{n_k} a_i^{(k)} \left(\frac{1}{n_k} - \sum_{y \in \mathcal{X}} \gamma_{i,y}^{(k)} \right) + \sum_{k=0}^{1} \lambda_k \left(\rho_k - \sum_m \beta_{km} \right) \\ & + \sum_{k,m} w_{km} \left[\beta_{km} + \rho_k \mu_m - \sum_{i=1}^{n_k} \sum_{y \in \mathcal{X}} \gamma_{i,y}^{(k)} |x_i^{(k)}[m] - y[m]| \right]. \end{aligned} \tag{19}$$

关于a 的下确界有限，当且仅当$\sum_y \gamma_{i,y}^{(k)} = 1/n_k$；关于$g$ 取下确界得到$H(\gamma)$。关于$\lambda, w \ge 0$ 的下确界有限，当且仅当

$$\sum_m \beta_{km} \le \rho_k, \qquad \beta_{km} \ge \sum_{i=1}^{n_k} \sum_{y \in \mathcal{X}} \gamma_{i,y}^{(k)} |x_i^{(k)}[m] - y[m]| - \rho_k \mu_m.$$

存在满足上述不等式的非负β，当且仅当

$$\sum_{m=1}^{D} \left(\sum_{i=1}^{n_k} \sum_{y \in \mathcal{X}} \gamma_{i,y}^{(k)} |x_i^{(k)}[m] - y[m]| - \rho_k \mu_m \right)_+ \le \rho_k, \qquad k = 0, 1.$$

因此，对偶可行域与目标函数分别为$\mathcal{D}$ 和$H(\gamma) - 2\mu^\top z$。

对于每个$z \in [0,1]^D$，取

$$g = 0, \qquad \lambda = w = 0, \qquad a_i^{(k)} > \ell(0)$$

满足全部仿射约束，并严格满足全部损失约束。将非负性计入仿射约束，改进的Slater 对偶定理给出式 (8) 中的等式与对偶最优值的可达性，亦包括$z_m = 0$ 的情形。因此，z^t 处的最优解(γ^t, μ^t) 满足

$$\begin{aligned} c_t(z) &= H(\gamma^t) - 2(\mu^t)^\top z \le F(z), \\ c_t(z^t) &= H(\gamma^t) - 2(\mu^t)^\top z^t = F(z^t), \\ c_t(z) &= F(z^t) - 2(\mu^t)^\top (z - z^t), \end{aligned}$$

这就证明了式 (11)。 □

参考文献

[1] Dimitris Bertsimas, Ryan Cory-Wright, and Jean Pauphilet. A unified approach to mixed-integer optimization problems with logical constraints. *SIAM Journal on Optimization*, 31(3):2340–2367, 2021.

[2] Rui Gao, Liyan Xie, Yao Xie, and Huan Xu. Robust hypothesis testing using Wasserstein uncertainty sets. In *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.

[3] Liyan Xie, Rui Gao, and Yao Xie. Robust hypothesis testing with Wasserstein uncertainty sets, 2021. arXiv:2105.14348.