Wasserstein 鲁棒假设检验中的变量选择

2026年10月18日

摘要

Wasserstein 鲁棒检验中的变量选择问题具有精确的有限维表示，并可写成一族仿射函数的最大值。对偶运输计划据此生成全局有效的割。

1 问题表述

本文研究鲁棒假设检验中的变量选择问题。令$[D] = \{1, \dots, D\}$，以正整数d 表示允许选择的变量数。给定检测函数$f : \mathbb{R}^D \to \mathbb{R}$，遵循文献[2] 的约定，将最坏情形风险定义为

$$R(f) = \sup_{\mathbb{P}_0 \in \mathcal{P}_0, \mathbb{P}_1 \in \mathcal{P}_1} \left\{ \mathbb{E}_{P_0} \ell(-f(X)) + \mathbb{E}_{P_1} \ell(f(X)) \right\}, \tag{1}$$

其中，$\mathcal{P}_k, k = 0, 1$ 为基于Wasserstein 距离构造的分布不确定集；生成函数$\ell(\cdot)$ 非负、非减且为凸函数，并满足$\ell(0) = 1, \lim_{t \to -\infty} \ell(t) = 0$。对于$k = 0, 1$，假设第$k$ 类中有n 个观测，记为$\{x_i^{(k)}\}_{i=1}^n$。将相应的经验分布记为$\widehat{\mathbb{P}}_k$，构造Wasserstein 不确定集

$$\mathcal{P}_k = \left\{ \mathbb{P}_k : \mathcal{W}_1(\widehat{\mathbb{P}}_k, \mathbb{P}_k) \le \rho_k \right\}.$$

这里，$\mathcal{W}_1(\cdot, \cdot)$ 表示以ℓ_1 范数为运输成本的1-Wasserstein 距离。

对于$S \subseteq [D]$，定义仅依赖于S 中坐标的检测函数类：

$$\mathcal{F}_S = \left\{ f : \mathbb{R}^D \to \mathbb{R}, f(x) = g(x[S])，\text{其中} g : \mathbb{R}^{|S|} \to \mathbb{R} \text{ 为某个可测函数} \right\}.$$

对于向量$x \in \mathbb{R}^D$，以$x[i]$ 表示其第i 个坐标，以$x[S]$ 表示下标属于S 的坐标组成的向量。所研究的变量选择问题可写成如下组合优化问题：

$$\min_{S \subseteq [D], |S| \le d} \min_{f \in \mathcal{F}_S} R(f). \tag{2}$$

2 有限维重构与对偶

2.1 固定坐标集合的最优风险

固定选集S，先计算仅使用这些坐标能够达到的最优风险，再由外层最小化比较不同选集。下文假设$\rho_0, \rho_1 > 0$，且ℓ 在$\mathbb{R}$ 上取有限值。所有概率分布均具有有限的一阶矩。将两类观测合并编号：

$$N = 2n, \qquad I_0 = [n], \qquad I_1 = \{n+1, \dots, 2n\}, \qquad x_i = x_i^{(0)}, \quad x_{n+i} = x_i^{(1)} \quad (i \in [n]).$$

因此，每个源观测在所属类别中的概率质量均为$1/n$。记$\ell_0(s) = \ell(-s)$、$\ell_1(s) = \ell(s)$，并定义

$$V(S) = \min_{f \in \mathcal{F}_S} R(f), \qquad \mathrm{OPT} = \min_{|S| \le d} V(S),$$

$$y_i = x_i[S], \qquad \Delta_{ir,j} = |x_i[j] - x_r[j]|, \qquad c_{ir}^S = \|y_i - y_r\|_1 = \sum_{j \in S} \Delta_{ir,j}.$$

其中，$i, r \in [N]$ 为观测下标，$j \in [D]$ 为坐标下标。

将检测函数限制为仅使用S，等价于在投影观测y_i 上进行检验，相应的不确定集也得到精确保留。记投影后的经验分布为$\widehat{Q}_k^S = n^{-1} \sum_{i \in I_k} \delta_{y_i}$，其中$\delta_y$ 为集中在y 处的单位质量，并令

$$\mathcal{Q}_k^S = \{Q : \mathcal{W}_1(Q, \widehat{Q}_k^S) \le \rho_k\}.$$

当$\mathbb{P}_k$ 遍历$\mathcal{P}_k$ 时，$X[S]$ 的分布恰好遍历Q_k^S。投影不会增加运输成本；反之，选中坐标上的任意运输，都可通过保持各源点的其余坐标不变而提升到完整空间。因此，

$$V(S) = \inf_{g\ \text{可测}} \sum_{k=0}^{1} \sup_{Q\in Q_k^S} \mathbb{E}_Q \ell_k(g(Y)).$$

Gao 等人[2, 命题 1 与定理 3] 证明了这一凸损失检验问题的极小极大等式与精确有限支持表示。将其结果用于投影观测，最优风险即可通过合并样本位置之间的运输来计算。对于第k 类，以π_{ir} 表示从y_i 运到y_r 的质量，并定义

$$\mathcal{T}_k(S) = \left\{ \pi \ge 0 : \sum_{r=1}^{N} \pi_{ir} = \frac{1}{n}\ (i \in I_k), \quad \sum_{i\in I_k, r\in[N]} c_{ir}^S \pi_{ir} \le \rho_k \right\}.$$

若u_r 是赋予目标点y_r 的检测得分，则

$$V(S) = \inf_{u\in\mathbb{R}^N} \sum_{k=0}^{1} \max_{\pi\in\mathcal{T}_k(S)} \sum_{i\in I_k, r\in[N]} \pi_{ir}\ell_k(u_r). \tag{3}$$

最后的求和就是期望损失：目标点r 接收到第k 类的质量$p_{kr} = \sum_{i\in I_k}\pi_{ir}$，因而贡献损失$p_{kr}\ell_k(u_r)$。精确性针对检测函数优化后的最优值，并不意味着任意固定检测函数的最坏情形分布都以观测点为支持。

固定得分u 后，式 (3) 中的每个最大化问题都是运输线性规划。其对偶以变量$a_i \in \mathbb{R}$ 对应源质量等式，以价格$\lambda_k \ge 0$ 对应运输预算。定义

$$J(a,\lambda) = \frac{1}{n}\sum_{i=1}^{N} a_i + \rho_0\lambda_0 + \rho_1\lambda_1.$$

由线性规划对偶得到有限维凸问题

$$\begin{aligned} V(S) = \min_{a,u\in\mathbb{R}^N,\ \lambda\in\mathbb{R}_+^2} \quad & J(a,\lambda) \\ \text{约束为} \quad & \ell_k(u_r) \le a_i + \lambda_k c_{ir}^S, \quad i\in I_k,\ r\in[N],\ k=0,1. \end{aligned} \tag{4}$$

每个约束都将可能目标点处的损失控制在源项与运输成本之和以内。因此，式 (4) 计算的就是$\min_{f\in\mathcal{F}_S} R(f)$，再对满足$|S| \le d$ 的选集最小化其值，即可求解原问题。附录 A 给出投影论证、有限维极小极大与线性规划对偶的具体步骤，并构造在样本位置之外也有定义的最优检测函数。

Xie 等人的后续研究[3, 引理 2 与定理 1] 针对随机检验给出有限支持与延拓结果，其风险为两类错误概率之和，运输目标为$\sum_r \min\{p_{0r}, p_{1r}\}$。对于本文使用的一般生成损失，相应目标为$\sum_r \inf_s\{p_{0r}\ell(-s) + p_{1r}\ell(s)\}$，即Gao 等人[2, 定理 2–3] 的凸损失结果。式 (4) 的推导使用的是后者。

2.2 坐标选择的表示

选中坐标j 时令$z_j = 1$，否则令$z_j = 0$。按照Bertsimas 等人[1] 的逻辑变量建模思路，未选坐标将迫使与之关联的连续变量为零。本文中，这些变量为两个坐标价格w_{0j}, w_{1j}，用来替代损失约束中的乘积$\lambda_0 z_j, \lambda_1 z_j$。

对于$z\in[0,1]^D$，定义

$$\begin{aligned} F(z) = \min_{a,u,\lambda,w} \quad & J(a,\lambda) \\ \text{约束为} \quad & \ell_k(u_r) \le a_i + \sum_{j=1}^{D} \Delta_{ir,j} w_{kj}, \quad i\in I_k,\ r\in[N],\ k=0,1, \\ & 0 \le w_{kj} \le \lambda_k, \quad k=0,1,\ j\in[D], \\ & \rho_0 w_{0j} + \rho_1 w_{1j} \le z_j J(a,\lambda), \quad j\in[D], \\ & a,u\in\mathbb{R}^N, \qquad \lambda\in\mathbb{R}_+^2. \end{aligned} \tag{5}$$

固定z 时，这是一个凸规划。最后一组不等式表达坐标选择：若$z_j = 0$，由于半径为正，必有$w_{0j} = w_{1j} = 0$；若$z_j = 1$，该约束不增加限制，因为取$r = i$ 的约束给出$a_i \ge 0$，从而

$$\rho_0 w_{0j} + \rho_1 w_{1j} \le \rho_0 \lambda_0 + \rho_1 \lambda_1 \le J(a, \lambda).$$

当$z = \mathbf{1}_S$ 时，式 (4) 的任意可行解都可通过$w_{kj} = \lambda_k z_j$ 扩充为式 (5) 的可行解。反之，式 (5) 的任意可行解满足

$$\ell_k(u_r) \le a_i + \sum_{j \in S} \Delta_{ir,j} w_{kj} \le a_i + \lambda_k c^{S}_{ir}.$$

两个方向都保持目标不变，因此$F(\mathbf{1}_S) = V(S)$。这一具体重构针对本文的检验问题推导得到；所引逻辑约束论文提供的是建模与外逼近思路。

2.3 关于选择变量的仿射对偶

下一步对偶变换的目的是获得可在不同选集之间复用的下界。对式 (5) 的损失约束引入非负乘子Π_{ir}，对选择约束引入非负乘子μ_j。矩阵Π 是一个经缩放的运输计划。为描述其目标与可行域，记

$$m_{kr}(\Pi) = \sum_{i \in I_k} \Pi_{ir}, \qquad C_{kj}(\Pi) = \sum_{i \in I_k, r \in [N]} \Pi_{ir} \Delta_{ir,j},$$

$$H(\Pi) = \sum_{r=1}^{N} \inf_{s \in \mathbb{R}} \{ m_{0r}(\Pi) \ell(-s) + m_{1r}(\Pi) \ell(s) \}.$$

其中，m_{kr} 为目标点r 上第k 类的质量，C_{kj} 为坐标j 上的运输成本，H 的每一项是单个目标点处加权损失的下确界。与$\pi \in \mathcal{T}_k(S)$ 不同，Π 的每类总质量不必为一。

附录 B 中的拉格朗日推导给出

$$\begin{aligned} F(z) = \max_{\Pi, \alpha, \mu} \quad & H(\Pi) \\ \text{约束为} \quad & (\Pi, \alpha, \mu) \in \mathcal{D}, \qquad \alpha + \mu^{\top} z = 1, \end{aligned} \tag{6}$$

其中，α 为源质量的缩放系数；记正部为$(v)_+ = \max\{v, 0\}$，则

$$\mathcal{D} = \left\{ (\Pi, \alpha, \mu) \ge 0 : \begin{array}{ll} \displaystyle\sum_{r=1}^{N} \Pi_{ir} = \alpha / n, & i \in [N], \\ \displaystyle\sum_{j=1}^{D} (C_{kj}(\Pi) - \rho_k \mu_j)_+ \le \alpha \rho_k, & k = 0, 1 \end{array} \right\}. \tag{7}$$

行和等式来自对a 的最小化，正部不等式来自对λ 和w 的最小化。这些公式由式 (5) 推导得到，并非直接引用参考文献的结果。

式 (6) 的归一化条件仍依赖于z。由于$\mathcal{D}$ 为锥，将归一化三元组乘以$\tau \ge 0$ 后仍然可行，并有

$$H(\tau \Pi) = \tau H(\Pi), \qquad \max_{\tau \ge 0} \{ 2\sqrt{\tau H(\Pi)} - \tau \} = H(\Pi).$$

因此，沿每条射线优化缩放系数，得到

$$\boxed{F(z) = \max_{(\Pi, \alpha, \mu) \in \mathcal{D}} \{ 2\sqrt{H(\Pi)} - \alpha - \mu^{\top} z \}.} \tag{8}$$

此时，每个可行三元组都为所有选集定义一个仿射下界。在给定的z 处，将归一化最优解$(\bar{\Pi}, \bar{\alpha}, \bar{\mu})$ 乘以$F(z)$，即可得到式 (8) 的最优解。其仿射斜率为$-F(z)\bar{\mu}$，而非$-\bar{\mu}$。命题 B.1 证明两种表示等价、最优值可以取得，且所生成的仿射函数在求值点与F 相等。

3 切平面算法

仿射表示使我们能够采用Bertsimas 等人[1, 第 3.1 节] 的外逼近策略：对一个选集求解连续问题，保留其仿射下界，再用二元线性规划选择下一个选集。令$\mathcal{Z}_d = \{ z \in \{0, 1\}^D : \mathbf{1}^{\top} z \le d \}$。

在z^t 处取式 (8) 的一个最优解(Π^t, α^t, μ^t)，定义

$$\begin{aligned} c_t(z) &= 2\sqrt{H(\Pi^t)} - \alpha^t - (\mu^t)^\top z, \\ F(z) \geq c_t(z) &= F(z^t) - (\mu^t)^\top (z - z^t), \qquad c_t(z^t) = F(z^t). \end{aligned} \tag{9}$$

对偶可行性给出全局下界，对偶最优性给出在z^t 处的等式。因此，这是一个支撑仿射函数，而非任意下界；此处不要求F 可微。下一选集与主问题下界由以下问题给出：

$$\begin{aligned} (z^{t+1}, \eta^{t+1}) \in \underset{z \in \mathcal{Z}_d,\ \eta \geq 0}{\arg\min} \quad & \eta \\ \text{约束为} \quad & \eta \geq F(z^s) - (\mu^s)^\top (z - z^s), \qquad s = 1, \ldots, t. \end{aligned} \tag{10}$$

记$U_t = \min_{s \leq t} F(z^s)$。由于保留的全部割均位于$F$ 下方，有

$$\eta^{t+1} \leq \mathrm{OPT} \leq U_t.$$

当$U_t - \eta^{t+1} \leq \varepsilon$ 时停止，返回已求值选集中最优的一个。附录 A 说明如何由有限维凸问题的解恢复对应的检测函数。

算法 1 变量选择的精确切平面方法

输入： 问题数据、预算d、容差$\varepsilon > 0$ 及$z^1 \in \mathcal{Z}_d$。
输出： 选集S^*、对应的最优检测函数f^*，以及宽度至多为ε 的风险区间。

$t \leftarrow 1, U \leftarrow +\infty$.
当 真 **时**
  在z^t 处求解式 (8)，取最优解(Π^t, α^t, μ^t)。
  如果 $F(z^t) < U$ **则**
    $(U, z^*) \leftarrow (F(z^t), z^t)$.
  结束判断
  保留下标为t 的割 (9)。
  求解式 (10)，得到(z^{t+1}, η^{t+1})。
  如果 $U - \eta^{t+1} \leq \varepsilon$ **则**
    $S^* \leftarrow \{j : z^*_j = 1\}$.
    对S^* 求解式 (4)，并按式 (14) 构造g^*。
    令$f^*(x) = g^*(x[S^*])$，**返回** $(S^*, f^*, [\eta^{t+1}, U])$。
  结束判断
  $t \leftarrow t + 1$.
结束循环

A 与有限维检验问题的等价性

命题A.1 (有限表示)**.** 对于每个$S \subseteq [D]$，有限维凸问题 (4) 取得最优值$V(S) = \min_{f \in \mathcal{F}_S} R(f)$。其每个最优解都可构造为完整观测空间上的最优可测检测函数。

证明. 令$\mathrm{Proj}_S\, x = x[S]$，以$(\mathrm{Proj}_S)_\# \mathbb{P}$ 表示$\mathbb{P}$ 下$X[S]$ 的分布。由Proj_S 不增加距离，有

$$\mathcal{W}_1((\mathrm{Proj}_S)_\# \mathbb{P}, \widehat{Q}^S_k) \leq \mathcal{W}_1(\mathbb{P}, \widehat{\mathbb{P}}_k).$$

反之，将从$\widehat{Q}^S_k$ 到$Q \in \mathcal{Q}^S_k$ 的耦合按源下标分解为质量均为$1/n$ 的测度ν_i。对于$i \in I_k$，定义$L_i(y)[S] = y$ 以及$L_i(y)[S^c] = x_i[S^c]$。于是

$$\mathbb{P} = \sum_{i \in I_k} (L_i)_\# \nu_i, \qquad (\mathrm{Proj}_S)_\# \mathbb{P} = Q, \qquad \mathcal{W}_1(\mathbb{P}, \widehat{\mathbb{P}}_k) \leq \sum_{i \in I_k} \int \|y - y_i\|_1 \, \nu_i(dy) \leq \rho_k.$$

重复的投影源点可按原始下标拆分。因此，$(\mathrm{Proj}_S)_\# \mathcal{P}_k = \mathcal{Q}^S_k$，投影后的鲁棒检验问题具有最优值$V(S)$。

当$S \neq \varnothing$时，在投影后的欧氏空间上应用Gao 等人[2] 的命题 1 与定理 3。记$p_{kr} = \sum_{i \in I_k} \pi^k_{ir}$，其有限支持目标就是各点最优加权损失之和，因而有

$$\begin{aligned} V(S) &= \max_{\pi^0 \in \mathcal{T}_0(S),\, \pi^1 \in \mathcal{T}_1(S)} \sum_{r=1}^{N} \inf_{s \in \mathbb{R}} \{p_{0r}\ell(-s) + p_{1r}\ell(s)\} \\ &= \max_{\pi^0, \pi^1} \inf_{u \in \mathbb{R}^N} \sum_{k=0}^{1} \sum_{i \in I_k, r \in [N]} \pi^k_{ir} \ell_k(u_r) \\ &= \inf_{u \in \mathbb{R}^N} \sum_{k=0}^{1} \max_{\pi^k \in \mathcal{T}_k(S)} \sum_{i \in I_k, r \in [N]} \pi^k_{ir} \ell_k(u_r). \end{aligned} \tag{11}$$

第二行中的运输计划与第一行取遍相同的笛卡尔积集合。最后一个等式来自有限维极小极大对偶：运输可行域为紧凸集，目标连续，关于运输计划为仿射函数，关于u 为凸函数。重合的目标点可以合并；保留各自下标也得到相同的最优值。若$S = \varnothing$，投影空间只有一个点，两边均为$\min_s\{\ell(-s) + \ell(s)\} = 2$，因此式 (3) 仍成立。

固定u 与类别k，运输线性规划的拉格朗日函数为

$$\begin{aligned} L_k &= \sum_{i \in I_k, r} \pi_{ir}\ell_k(u_r) + \sum_{i \in I_k} a_i \left(\frac{1}{n} - \sum_r \pi_{ir}\right) + \lambda_k \left(\rho_k - \sum_{i \in I_k, r} c^S_{ir}\pi_{ir}\right) \\ &= \frac{1}{n}\sum_{i \in I_k} a_i + \rho_k\lambda_k + \sum_{i \in I_k, r} \pi_{ir}[\ell_k(u_r) - a_i - \lambda_k c^S_{ir}]. \end{aligned} \tag{12}$$

其关于$\pi \geq 0$ 的上确界有限，当且仅当所有方括号内的系数均非正。由线性规划强对偶，有

$$\begin{aligned} \max_{\pi \in \mathcal{T}_k(S)} \sum_{i \in I_k, r} \pi_{ir}\ell_k(u_r) = \min_{(a_i)_{i \in I_k},\, \lambda_k \geq 0} \quad & \frac{1}{n}\sum_{i \in I_k} a_i + \rho_k\lambda_k \\ \text{约束为} \quad & \ell_k(u_r) \leq a_i + \lambda_k c^S_{ir}, \quad i \in I_k,\ r \in [N]. \end{aligned} \tag{13}$$

对两类求和并关于u 最小化，即得式 (4)。在下水平集$J \leq 2$ 上，有$0 \leq a_i \leq 2n$ 以及$0 \leq \lambda_k \leq 2/\rho_k$。约束进而同时界住$\ell(u_r)$ 与$\ell(-u_r)$。由于$t \to \infty$ 时$\ell(t) \to \infty$，该下水平集有界且闭，故最小值可以取得。

为恢复检测函数，取式 (4) 的可行解(a, u, λ)。在$y \in \mathbb{R}^{|S|}$ 处，分别选取两类中使下式最小的最小下标:

$$E_k(y) = \min_{i \in I_k}\{a_i + \lambda_k\|y_i - y\|_1\}, \qquad i_k = \min \arg\min_{i \in I_k}\{a_i + \lambda_k\|y_i - y\|_1\},$$
$$r_k = \|y_{i_k} - y\|_1, \qquad b = \|y_{i_0} - y_{i_1}\|_1 \leq r_0 + r_1.$$

定义

$$g(y) = \begin{cases} (1-\gamma)u_{i_0} + \gamma u_{i_1}, & \gamma = \min\{1, r_0/b\}, \quad b > 0, \\ u_{i_0}, & b = 0. \end{cases} \tag{14}$$

若$b > 0$，则有$\gamma b \leq r_0$ 和$(1-\gamma)b \leq r_1$。由凸性与四个源点–目标点约束，有

$$\ell_0(g(y)) \leq (1-\gamma)\ell_0(u_{i_0}) + \gamma\ell_0(u_{i_1}) \leq a_{i_0} + \lambda_0\gamma b \leq E_0(y),$$
$$\ell_1(g(y)) \leq (1-\gamma)\ell_1(u_{i_0}) + \gamma\ell_1(u_{i_1}) \leq a_{i_1} + \lambda_1(1-\gamma)b \leq E_1(y).$$

当$b = 0$ 时，目标点i_0 处的约束给出同样的界。取最小下标的规则保证g 为Borel 可测，且$|g(y)| \leq \max_r |u_r|$。对从$\widehat{Q}^S_k$ 到任意$Q \in Q^S_k$ 的运输耦合积分，得到

$$\mathbb{E}_Q\ell_k(g(Y)) \leq \frac{1}{n}\sum_{i \in I_k} a_i + \rho_k\lambda_k, \qquad R(f) \leq J(a, \lambda), \quad f(x) = g(x[S]).$$

对于有限问题的最优解，右侧为$V(S)$；由$f \in \mathcal{F}_S$ 可得反向不等式。因此，恢复的检测函数最优。 □

B 对偶表示与支撑仿射函数

命题B.1 (对偶与次梯度)**.** (i) 对于每个$S \subseteq [D]$，有$F(\mathbf{1}_S) = V(S)$。对于每个$z \in [0,1]^D$，原问题最小值与归一化对偶最大值均可以取得，且

$$0 < F(z) = \max_{\substack{(\Pi,\alpha,\mu)\in\mathcal{D} \\ \alpha+\mu^\top z=1}} H(\Pi) \le 2. \tag{15}$$

(ii) 同一最优值还具有如下可以取得的表示：

$$F(z) = \max_{(\Pi,\alpha,\mu)\in\mathcal{D}} \{2\sqrt{H(\Pi)} - \alpha - \mu^\top z\}. \tag{16}$$

对于归一化最优解$(\bar\Pi, \bar\alpha, \bar\mu)$，上述仿射表示的一个最优解为

$$(\Pi, \alpha, \mu) = F(z)(\bar\Pi, \bar\alpha, \bar\mu), \qquad H(\Pi) = F(z)^2. \tag{17}$$

(iii) 函数F 在$[0,1]^D$ 上为凸函数。在z^t 处的仿射对偶最优解(Π^t, α^t, μ^t) 给出

$$\begin{aligned} c_t(z) &= 2\sqrt{H(\Pi^t)} - \alpha^t - (\mu^t)^\top z \le F(z), \\ c_t(z^t) &= F(z^t), \qquad F(z) \ge F(z^t) - (\mu^t)^\top (z - z^t). \end{aligned} \tag{18}$$

因此，$-\mu^t \in \partial F(z^t)$，其中次梯度不等式在$[0,1]^D$ 上成立。

证明. (i) 在两个原问题中，取$r = i$ 的约束均给出$a_i \ge \ell_k(u_i) \ge 0$。若$(a, u, \lambda)$ 是式 (4) 的可行解，令$z = \mathbf{1}_S$、$w_{kj} = \lambda_k z_j$，则

$$\ell_k(u_r) \le a_i + \sum_j \Delta_{ir,j} w_{kj}, \qquad \sum_k \rho_k w_{kj} = z_j \sum_k \rho_k \lambda_k \le z_j J.$$

反之，式 (5) 在$z = \mathbf{1}_S$ 时的可行解满足

$$w_{kj} = 0 \ (j \notin S), \qquad \ell_k(u_r) \le a_i + \sum_{j\in S} \Delta_{ir,j} w_{kj} \le a_i + \lambda_k c^S_{ir}.$$

两个方向均保持J 不变，故$F(\mathbf{1}_S) = V(S)$。

为推导对偶，分别对损失不等式、上界$w_{kj} \le \lambda_k$ 以及选择不等式引入乘子$\Pi_{ir}, \beta_{kj}, \mu_j \ge 0$。保留$a, u$ 为自由变量、$\lambda, w \ge 0$，并令$\alpha = 1 - \mu^\top z$。拉格朗日函数为

$$\begin{aligned} \mathcal{L} &= J + \sum_{k, i\in I_k, r} \Pi_{ir} \left[\ell_k(u_r) - a_i - \sum_j \Delta_{ir,j} w_{kj} \right] + \sum_{k,j} \beta_{kj}(w_{kj} - \lambda_k) \\ &\quad + \sum_j \mu_j \left[\sum_k \rho_k w_{kj} - z_j J \right] \\ &= \sum_i a_i \left(\frac{\alpha}{n} - \sum_r \Pi_{ir} \right) + \sum_{r=1}^{N} \{ m_{0r}(\Pi)\ell(-u_r) + m_{1r}(\Pi)\ell(u_r) \} \\ &\quad + \sum_k \lambda_k \left(\alpha\rho_k - \sum_j \beta_{kj} \right) + \sum_{k,j} w_{kj} [\beta_{kj} + \rho_k \mu_j - C_{kj}(\Pi)]. \end{aligned} \tag{19}$$

其关于a, λ, w 的下确界有限，当且仅当

$$\sum_r \Pi_{ir} = \alpha/n, \qquad \sum_j \beta_{kj} \le \alpha\rho_k, \qquad \beta_{kj} \ge (C_{kj}(\Pi) - \rho_k \mu_j)_+. \tag{20}$$

行和等式强制$\alpha \ge 0$。其余项关于u 的最小化可按目标点分离，结果为$H(\Pi)$。在式 (20) 中取最小的可行β_{kj}，恰好得到$\mathcal{D}$ 与$\alpha + \mu^\top z = 1$。因此，只需进一步证明强对偶，即可得到所述对偶等式。

为证明强对偶，先消去所有满足$z_j = 0$ 的变量w_{kj} 及对应的选择约束，因为这些变量必为零。消去后的凸问题在下列点处严格可行：

$$u = 0, \qquad a_i = 2, \qquad \lambda_k = 1, \qquad w_{kj} = z_j/2 \quad (z_j > 0).$$

事实上，损失约束与上界约束均严格成立，并且

$$\sum_{k} \rho_k w_{kj} = \frac{z_j}{2}(\rho_0 + \rho_1) < z_j(4 + \rho_0 + \rho_1) = z_j J \quad (z_j > 0).$$

由Slater 定理，消去后的问题满足强对偶，且对偶最优值可以取得。对消去的坐标补回$\mu_j = \max_k C_{kj}(\Pi)/\rho_k$ 与$\beta_{kj} = 0$，不改变目标值和归一化条件。因此，完整对偶也取得$F(z)$，立方体边界上的点同样如此。

常数可行点$(a, u, \lambda, w) = (\mathbf{1}, 0, 0, 0)$ 的目标为2。在下水平集$J \le 2$ 上，a, λ, w 有界，损失约束还从两侧界住u，论证与附录 A 相同。因此，原问题最小值存在。若最小值为零，则必有$a = \lambda = w = 0$，从而

$$2 = 2\ell(0) \le \ell(-u_r) + \ell(u_r) \le 0,$$

矛盾。由此证明式 (15)。

(ii) 集合$\mathcal{D}$ 为锥，且对$\tau \ge 0$，有$H(\tau\Pi) = \tau H(\Pi) \ge 0$。对任意可行三元组，令$b = \alpha + \mu^\top z$。若$b > 0$，由归一化与(i) 得$H(\Pi)/b \le F(z)$，故

$$2\sqrt{H(\Pi)} - b = \frac{H(\Pi)}{b} - \left(\sqrt{\frac{H(\Pi)}{b}} - \sqrt{b}\right)^2 \le F(z). \tag{21}$$

若$b = 0$，则$\alpha = 0$、$\Pi = 0$，仿射目标为零。对于归一化最优解，有$H(\bar{\Pi}) = F(z)$ 与$\bar{\alpha} + \bar{\mu}^\top z = 1$。将其乘以$F(z)$ 得到

$$H(F(z)\bar{\Pi}) = F(z)^2, \qquad 2\sqrt{H(F(z)\bar{\Pi})} - F(z)(\bar{\alpha} + \bar{\mu}^\top z) = F(z).$$

因此，该上界能够取得，即得式 (16) 与式 (17)。

(iii) 由于$\mathcal{D}$ 不依赖于z，式 (16) 将F 表示为一族仿射函数的最大值，故其为凸函数。可行三元组对所有z 给出下界，在z^t 处的最优三元组则在该点取得等式。因此，

$$c_t(z) = c_t(z^t) - (\mu^t)^\top(z - z^t) = F(z^t) - (\mu^t)^\top(z - z^t) \le F(z). \qquad \square$$

参考文献

[1] Dimitris Bertsimas, Ryan Cory-Wright, and Jean Pauphilet. A unified approach to mixed-integer optimization problems with logical constraints. *SIAM Journal on Optimization*, 31(3):2340–2367, 2021.

[2] Rui Gao, Liyan Xie, Yao Xie, and Huan Xu. Robust hypothesis testing using Wasserstein uncertainty sets. In *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.

[3] Liyan Xie, Rui Gao, and Yao Xie. Robust hypothesis testing with Wasserstein uncertainty sets. arXiv:2105.14348, 2021.