Wasserstein 鲁棒假设检验中的变量选择

摘要

本文从Wasserstein 鲁棒检验的有限维最不利分布表示出发，推导带坐标选择的凸模型。利用统一的风险上界引入选择变量，保持二元点处的最优值不变。所得凸值函数具有仿射对偶割，可用于在变量选集上优化。

1 问题表述

本文研究鲁棒假设检验中的变量选择问题。令$[D]=\{1,\dots,D\}$，以正整数d 表示允许选择的变量数。给定检测函数$f:\mathbb{R}^D\to\mathbb{R}$，遵循文献[2] 的约定，将最坏情形风险定义为

$$R(f)=\sup_{\mathbb{P}_0\in\mathcal{P}_0,\mathbb{P}_1\in\mathcal{P}_1}\left\{\mathbb{E}_{\mathbb{P}_0}\ell(-f(X))+\mathbb{E}_{\mathbb{P}_1}\ell(f(X))\right\},\tag{1}$$

其中，$\mathcal{P}_k,k=0,1$ 为基于Wasserstein 距离构造的分布不确定集；生成函数$\ell(\cdot)$ 非负、非减且为凸函数，并满足$\ell(0)=1,\lim_{t\to-\infty}\ell(t)=0$。对于$k=0,1$，假设第$k$ 类中有n_k 个观测，记为$\{x_i^{(k)}\}_{i=1}^{n_k}$。将相应的经验分布记为$\widehat{\mathbb{P}}_k=\frac{1}{n_k}\sum_{i=1}^{n_k}\delta_{x_i^{(k)}}$，构造Wasserstein 不确定集

$$\mathcal{P}_k=\left\{\mathbb{P}_k:\ \mathcal{W}_1(\widehat{\mathbb{P}}_k,\mathbb{P}_k)\le\rho_k\right\}.$$

这里，$\mathcal{W}_1(\cdot,\cdot)$ 表示以ℓ_1 范数为运输成本的1-Wasserstein 距离。

对于$S\subseteq[D]$，定义仅依赖于S 中坐标的检测函数类：

$$\mathcal{F}_S=\left\{f:\ \mathbb{R}^D\to\mathbb{R},f(x)=g(x[S])，\text{其中}g:\ \mathbb{R}^{|S|}\to\mathbb{R}\text{ 为某个可测函数}\right\}.$$

对于向量$x\in\mathbb{R}^D$，以$x[i]$ 表示其第i 个坐标，以$x[S]$ 表示下标属于S 的坐标组成的向量。所研究的变量选择问题可写成如下组合优化问题：

$$\min_{S\subseteq[D],|S|\le d}\ \min_{f\in\mathcal{F}_S}\ R(f).\tag{2}$$

2 有限维等价表示

假设$n_0,n_1\ge1$、$\rho_0,\rho_1>0$，且ℓ 在$\mathbb{R}$ 上有限。所有分布的一阶矩均有限。固定$S\subseteq[D]$，记

$$V(S)=\min_{f\in\mathcal{F}_S}R(f),\qquad\mathcal{X}=\{x_i^{(0)}:i\in[n_0]\}\cup\{x_j^{(1)}:j\in[n_1]\}.$$

源观测保留其类别下标，以$y\in\mathcal{X}$ 表示目标点。投影到S 不会增加运输成本。反过来，保持各源观测的未选坐标不变，即可将投影后观测的任意运输提升到原空间，且成本不变。因此，投影后的Wasserstein 球恰好描述了与检测函数$g(x[S])$ 有关的不确定性。

遵循文献[2]，定义

$$\psi(p)=\inf_{v\in\mathbb{R}}\{p\ell(v)+(1-p)\ell(-v)\},\qquad0\le p\le1.$$

将文献[2, 命题 1 及定理 3，式 (6)] 的有限维最不利分布表示用于投影后的观测，并保留原类别下标，得到以下结果。总质量为零时，相应求和项定义为零。

命题2.1 (有限维最不利分布表示)**.** 固定选集的风险为

$$
\begin{aligned}
V(S) = \max_{p,\gamma\ge 0} \quad & \sum_{y\in\mathcal{X}} (p_0(y)+p_1(y))\psi\left(\frac{p_0(y)}{p_0(y)+p_1(y)}\right) \\
\text{约束为} \quad & \sum_{y\in\mathcal{X}} \gamma_{i,y}^{(k)} = \frac{1}{n_k}, && i\in[n_k],\ k=0,1, \\
& p_k(y) = \sum_{i=1}^{n_k} \gamma_{i,y}^{(k)}, && y\in\mathcal{X},\ k=0,1, \\
& \sum_{i=1}^{n_k}\sum_{y\in\mathcal{X}} \gamma_{i,y}^{(k)} \|x_i^{(k)}[S]-y[S]\|_1 \le \rho_k, && k=0,1.
\end{aligned}
\tag{3}
$$

其中，$\gamma_{i,y}^{(k)}$ 是从$x_i^{(k)}[S]$ 运到$y[S]$ 的质量，$p_k(y)$ 为运输后相应目标点的质量。保留全部目标点，包括源观测自身。若投影后的目标点重合，则合并其质量。目标函数的凹性和正齐次性保证合并不会使其减小；反过来，对两类采用相同比例拆分合并后的质量，不会改变目标值。因此，固定的目标标签$y\in\mathcal{X}$ 不影响该值。

以g_y 表示赋给$y[S]$ 的评分。令$v=-g_y$ 并代入目标质量，得到

$$
\sum_{y\in\mathcal{X}} (p_0(y)+p_1(y))\psi\left(\frac{p_0(y)}{p_0(y)+p_1(y)}\right) = \inf_{g}\left\{\sum_{i,y}\gamma_{i,y}^{(0)}\ell(-g_y) + \sum_{j,y}\gamma_{j,y}^{(1)}\ell(g_y)\right\}.
$$

运输可行集为紧凸集，花括号内的表达式关于有限维评分向量g 为凸函数，关于γ 为线性函数。因此，由有限维极小极大定理，得到

$$
V(S) = \inf_{g}\left\{\max_{\gamma^{(0)}}\sum_{i,y}\gamma_{i,y}^{(0)}\ell(-g_y) + \max_{\gamma^{(1)}}\sum_{j,y}\gamma_{j,y}^{(1)}\ell(g_y)\right\},
$$

其中，各最大化问题满足式 (3) 中相应的源质量和运输预算约束。

固定g 时，第0 类的最大化问题是运输线性规划。为源质量守恒约束分配自由乘子$a_i^{(0)}$，为运输预算分配非负乘子λ_0。其拉格朗日函数为

$$
\begin{aligned}
\mathcal{L}_0 &= \sum_{i,y}\gamma_{i,y}^{(0)}\ell(-g_y) + \sum_i a_i^{(0)}\left(\frac{1}{n_0} - \sum_y \gamma_{i,y}^{(0)}\right) \\
&\quad + \lambda_0\left(\rho_0 - \sum_{i,y}\gamma_{i,y}^{(0)}\|x_i^{(0)}[S]-y[S]\|_1\right) \\
&= \frac{1}{n_0}\sum_i a_i^{(0)} + \rho_0\lambda_0 \\
&\quad + \sum_{i,y}\gamma_{i,y}^{(0)}\left[\ell(-g_y) - a_i^{(0)} - \lambda_0\|x_i^{(0)}[S]-y[S]\|_1\right].
\end{aligned}
\tag{4}
$$

对$\gamma^{(0)}\ge 0$ 取上确界时，其值有限当且仅当每个方括号中的系数均非正。对两类分别应用线性规划对偶性，再对g 最小化，得到

$$
\begin{aligned}
V(S) = \min_{g,a,\lambda} \quad & \frac{1}{n_0}\sum_i a_i^{(0)} + \frac{1}{n_1}\sum_j a_j^{(1)} + \rho_0\lambda_0 + \rho_1\lambda_1 \\
\text{约束为} \quad & \ell(-g_y) \le a_i^{(0)} + \lambda_0\|x_i^{(0)}[S]-y[S]\|_1, && i\in[n_0],\ y\in\mathcal{X}, \\
& \ell(g_y) \le a_j^{(1)} + \lambda_1\|x_j^{(1)}[S]-y[S]\|_1, && j\in[n_1],\ y\in\mathcal{X}, \\
& g\in\mathbb{R}^{\mathcal{X}},\quad a^{(k)}\in\mathbb{R}^{n_k},\quad \lambda_k\ge 0, && k=0,1.
\end{aligned}
\tag{5}
$$

将该目标函数记为$J(a,\lambda)$。投影重合的目标点对应相同的约束列，因此可以令其评分相等。附录 A 将这些有限个评分延拓为第 1 节中的可测检测函数g，并证明最小值可以取得。

零检测函数的风险为2。在约束中取$y = x_i^{(k)}$，得到$a_i^{(k)} \ge 0$，因此最优解满足

$$\rho_0\lambda_0 + \rho_1\lambda_1 \le J(a,\lambda) = V(S) \le 2. \tag{6}$$

利用这一上界可以引入坐标选择，并保持二元点处的最优值不变。

3 选择变量与对偶

令$z = \mathbf{1}_S$，并记$\mathcal{Z}_d = \{z \in \{0,1\}^D : \mathbf{1}^\top z \le d\}$。运输成本可以直接按坐标分解：

$$\|x_i^{(k)}[S] - y[S]\|_1 = \sum_{m=1}^{D} z_m |x_i^{(k)}[m] - y[m]|.$$

引入w_{km} 以替代$\lambda_k z_m$。条件$0 \le w_{km} \le \lambda_k$ 和$\rho_0 w_{0m} + \rho_1 w_{1m} \le 2z_m$ 使未选坐标的两类权重均为零。对于已选坐标，由式 (6)，在最优解处可以取$w_{km} = \lambda_k$。对于$z \in [0,1]^D$，定义

$$\begin{aligned} F(z) = \min_{g,a,\lambda,w} \quad & J(a,\lambda) \\ \text{约束为} \quad & \ell(-g_y) \le a_i^{(0)} + \sum_m w_{0m}|x_i^{(0)}[m] - y[m]|, && i \in [n_0],\ y \in \mathcal{X}, \\ & \ell(g_y) \le a_j^{(1)} + \sum_m w_{1m}|x_j^{(1)}[m] - y[m]|, && j \in [n_1],\ y \in \mathcal{X}, \\ & 0 \le w_{km} \le \lambda_k, && k = 0,1,\ m \in [D], \\ & \rho_0 w_{0m} + \rho_1 w_{1m} \le 2z_m, && m \in [D], \\ & g \in \mathbb{R}^{\mathcal{X}}, \quad a^{(k)} \in \mathbb{R}^{n_k}, \quad \lambda_k \ge 0, && k = 0,1. \end{aligned} \tag{7}$$

该模型具有文献[1] 中问题 (2.1)–(2.2) 的逻辑结构：外层问题选择坐标，每个坐标激活凸内层问题中的一个变量对(w_{0m}, w_{1m})。

命题3.1 (选择变量表示)**.** 式 (7) 的最小值可以取得。函数F 在$[0,1]^D$ 上为凸函数，且

$$F(\mathbf{1}_S) = V(S), \qquad \min_{|S| \le d} V(S) = \min_{z \in \mathcal{Z}_d} F(z). \tag{8}$$

证明. 式 (5) 的最优解可以扩展为式 (7) 的可行解：在$z = \mathbf{1}_S$ 处令$w_{km} = \lambda_k z_m$，可行性由式 (6) 保证。反过来，该二元选集处的可行点在S 之外满足$w_{km} = 0$，故

$$\sum_m w_{km}|x_i^{(k)}[m] - y[m]| \le \lambda_k \sum_{m \in S} |x_i^{(k)}[m] - y[m]| = \lambda_k \|x_i^{(k)}[S] - y[S]\|_1.$$

因此，该点对式 (5) 可行，目标值不变，从而二元点处的最优值相等。对于任意z，可行解$g = 0$、$a = \mathbf{1}$、$\lambda = w = 0$ 的目标值为2。由附录 A 中的界及$0 \le w_{km} \le \lambda_k$，子水平集$J \le 2$ 紧致。所有约束关于包括z 在内的变量联合凸。对可行解取凸组合，得到

$$F(tz + (1-t)z') \le tF(z) + (1-t)F(z'), \qquad 0 \le t \le 1.$$

□

3.1 对偶表示

为式 (7) 中两组损失约束分别分配乘子$\gamma_{i,y}^{(0)} \ge 0$ 和$\gamma_{j,y}^{(1)} \ge 0$，为每个坐标容量约束分配乘子$\mu_m \ge 0$。对自由源变量a 最小化，恢复源质量等式$\sum_y \gamma_{i,y}^{(k)} = 1/n_k$。因此，同一运输记号通过对偶性重新出现。沿用式 (3) 中的$p_k(y) = \sum_{i=1}^{n_k} \gamma_{i,y}^{(k)}$，令

$$\begin{aligned} H(\gamma) &= \sum_{y \in \mathcal{X}} \inf_{v \in \mathbb{R}} \{p_0(y)\ell(-v) + p_1(y)\ell(v)\} \\ &= \sum_{y \in \mathcal{X}} (p_0(y) + p_1(y))\psi\left(\frac{p_0(y)}{p_0(y) + p_1(y)}\right). \end{aligned} \tag{9}$$

这正是最不利分布问题的目标，由对目标点评分最小化得到。其余对偶约束定义集合

$$\mathcal{D} = \left\{ \begin{array}{ll} \displaystyle\sum_{y\in\mathcal{X}} \gamma_{i,y}^{(k)} = 1/n_k, & i \in [n_k],\ k = 0,1, \\ (\gamma,\mu) \geq 0 : & \displaystyle\sum_{m=1}^{D} \left(\sum_{i=1}^{n_k} \sum_{y\in\mathcal{X}} \gamma_{i,y}^{(k)} |x_i^{(k)}[m] - y[m]| - \rho_k \mu_m \right)_+ \leq \rho_k, \quad k = 0,1 \end{array} \right\}, \tag{10}$$

其中$(v)_+ = \max\{v, 0\}$。附录 B 通过对λ, w 最小化推导第二行。特别地，$\mathcal{D}$ 不依赖于z。

命题3.2 (对偶表示)**.** 对于每个$z \in [0,1]^D$，以下最大值可以取得：

$$F(z) = \max_{(\gamma,\mu)\in\mathcal{D}} \{H(\gamma) - 2\mu^\top z\}. \tag{11}$$

z^t 处的最优解(γ^t, μ^t) 给出支撑函数

$$c_t(z) = H(\gamma^t) - 2(\mu^t)^\top z = F(z^t) - 2(\mu^t)^\top (z - z^t) \leq F(z), \tag{12}$$

并满足$c_t(z^t) = F(z^t)$。

函数H 是线性函数族的下确界，因而为凹函数，而$\mathcal{D}$ 为凸集。因此，固定z 时，对偶为凸优化问题。它关于z 的仿射形式给出了文献[1] 中定理 2.5 和算法 3.1 所依据的切平面构造。

4 切平面算法

记$\mathrm{OPT} = \min_{z\in\mathcal{Z}_d} F(z)$。评估$z^1, \ldots, z^t$ 并取得相应的对偶最优解后，令$U_t = \min_{s\leq t} F(z^s)$，并求解

$$\begin{aligned} (z^{t+1}, L_t) \in \ & \operatorname*{arg\,min}_{z\in\mathcal{Z}_d,\, \eta\geq 0} \quad \eta \\ & \text{约束为} \quad \eta \geq F(z^s) - 2(\mu^s)^\top (z - z^s), \qquad s = 1, \ldots, t. \end{aligned} \tag{13}$$

每条保留的割均为全局下界，并在生成该割的已评估选集处取等号。因此，

$$L_t \leq \mathrm{OPT} \leq U_t. \tag{14}$$

从任意$z^1 \in \mathcal{Z}_d$ 出发，交替求解凸子问题(7)–(11) 与二元线性主问题 (13)。当$U_t - L_t \leq \varepsilon$ 时停止，并返回最好的已评估选集。附录 A 恢复其检测函数，风险为U_t，与最优风险的差距至多为ε。若内层求解非精确，使用实际可行对偶表达式$H(\gamma^t) - 2(\mu^t)^\top z$ 作为割，以原始可行解的目标值作为上界；主问题必须提供全局下界。该表示在二元点处精确，但其连续松弛可能较弱。

A 检测函数的恢复

对于式 (5) 的任意可行解(g, a, λ)，令投影重合的目标点评分相等。这保持可行性与目标值不变。下面构造满足以下条件的可测延拓：

$$\begin{aligned} \ell(-g(\xi)) \leq E_0(\xi), & \qquad \ell(g(\xi)) \leq E_1(\xi), \\ E_k(\xi) = \min_{i\in[n_k]} \{a_i^{(k)} + \lambda_k \|x_i^{(k)}[S] - \xi\|_1\}, & \qquad k = 0,1. \end{aligned} \tag{15}$$

证明. 在观测投影处令$g(y[S]) = g_y$；式 (5) 的约束保证式 (15) 在此处成立。在其他位置，分别选择达到$E_0(\xi), E_1(\xi)$ 的最小下标i, j，并令

$$r_0 = \|x_i^{(0)}[S] - \xi\|_1, \qquad r_1 = \|x_j^{(1)}[S] - \xi\|_1, \qquad b = \|x_i^{(0)}[S] - x_j^{(1)}[S]\|_1.$$

当$b > 0$ 时，令$\tau = \min\{1, r_0/b\}$，并定义

$$g(\xi) = (1 - \tau) g_{x_i^{(0)}} + \tau g_{x_j^{(1)}}. \tag{16}$$

三角不等式给出$\tau b \le r_0$ 和$(1-\tau)b \le r_1$。由凸性及式 (5)，得到

$$\ell(-g(\xi)) \le (1-\tau)\ell(-g_{x_i^{(0)}}) + \tau\ell(-g_{x_j^{(1)}}) \le a_i^{(0)} + \lambda_0 \tau b \le E_0(\xi),$$
$$\ell(g(\xi)) \le (1-\tau)\ell(g_{x_i^{(0)}}) + \tau\ell(g_{x_j^{(1)}}) \le a_j^{(1)} + \lambda_1 (1-\tau) b \le E_1(\xi).$$

当$b = 0$ 时，取$g(\xi) = g_{x_i^{(0)}}$，由式 (5) 得到相同上界。有限个下标中的确定性择取规则保证g为Borel 可测函数，且$|g| \le \max_{y\in\mathcal{X}} |g_y|$。对于任意$\mathbb{P}_k \in \mathcal{P}_k$，对从经验分布到$\mathbb{P}_k$ 的最优耦合积分式 (15)，并利用投影不增加成本，得到

$$\mathbb{E}_{\mathbb{P}_0}\ell(-g(X[S])) \le \frac{1}{n_0}\sum_i a_i^{(0)} + \rho_0\lambda_0,$$
$$\mathbb{E}_{\mathbb{P}_1}\ell(g(X[S])) \le \frac{1}{n_1}\sum_j a_j^{(1)} + \rho_1\lambda_1.$$

因此，$f(x) = g(x[S])$ 满足$R(f) \le J(a,\lambda)$。在非空子水平集$J \le 2$ 上，有$0 \le a_i^{(k)} \le 2n_k$ 和$0 \le \lambda_k \le 2/\rho_k$。每个$g_y$ 的两类损失均由相应类别的约束控制。由于当$t \to \infty$ 时有$\ell(t) \to \infty$，所有评分均有界。该子水平集紧致，故式 (5) 取得最小值；最优解的延拓具有风险$V(S)$。 □

B 对偶表示的证明

命题 *3.2* 的证明. 除γ, μ 外，为$w_{km} \le \lambda_k$ 分配乘子$\beta_{km} \ge 0$。保留g, a 为自由变量、$\lambda, w \ge 0$，最小化问题的拉格朗日函数为

$$\begin{aligned}\mathcal{L} = J(a,\lambda) &+ \sum_{i,y}\gamma_{i,y}^{(0)}\left[\ell(-g_y) - a_i^{(0)} - \sum_m w_{0m}|x_i^{(0)}[m] - y[m]|\right] \\ &+ \sum_{j,y}\gamma_{j,y}^{(1)}\left[\ell(g_y) - a_j^{(1)} - \sum_m w_{1m}|x_j^{(1)}[m] - y[m]|\right] \\ &+ \sum_{k,m}\beta_{km}(w_{km} - \lambda_k) + \sum_m \mu_m(\rho_0 w_{0m} + \rho_1 w_{1m} - 2z_m).\end{aligned} \tag{17}$$

对a 取下确界时，其值有限当且仅当$\sum_y \gamma_{i,y}^{(k)} = 1/n_k$。与$g$ 有关的项为$\sum_y [p_0(y)\ell(-g_y) + p_1(y)\ell(g_y)]$，其下确界为$H(\gamma)$。$\lambda, w \ge 0$ 的系数必须非负：

$$\rho_k - \sum_m \beta_{km} \ge 0, \qquad \beta_{km} + \rho_k\mu_m - \sum_{i,y}\gamma_{i,y}^{(k)}|x_i^{(k)}[m] - y[m]| \ge 0.$$

与$\beta \ge 0$ 合并后，这些条件等价于

$$\sum_m \left(\sum_{i,y}\gamma_{i,y}^{(k)}|x_i^{(k)}[m] - y[m]| - \rho_k\mu_m\right)_+ \le \rho_k.$$

因此，消去β 后得到可行域$\mathcal{D}$ 和目标函数$H(\gamma) - 2\mu^\top z$。

对于每个固定的$z \in [0,1]^D$，点$g = 0$、$a = 2\mathbf{1}$、$\lambda = \mathbf{1}$、$w = 0$ 严格满足所有损失不等式，并满足全部仿射约束。将非负性视为仿射约束后，允许仿射约束取等号的Slater 条件给出强对偶及对偶最优值的可达性，也涵盖边界选集。最后，任意对偶可行点均给出全局下界。(γ^t, μ^t) 在z^t 处的最优性给出

$$F(z) \ge H(\gamma^t) - 2(\mu^t)^\top z = F(z^t) - 2(\mu^t)^\top(z - z^t),$$

这就证明了式 (12)。 □

参考文献

[1] Dimitris Bertsimas, Ryan Cory-Wright, and Jean Pauphilet. A unified approach to mixed-integer optimization problems with logical constraints. *SIAM Journal on Optimization*, 31(3):2340–2367, 2021.

[2] Rui Gao, Liyan Xie, Yao Xie, and Huan Xu. Robust hypothesis testing using Wasserstein uncertainty sets. In *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.