鲁棒变量选择：实验怎么做

2026年10月18日　设计稿，尚未运行实验

先明确要验证什么

一条记录可能有几十个测量值，但实际只能保留其中几个。我们要检验：算法能否找出少量有用变量，让两类数据仍然容易区分；为此付出的搜索时间是否值得。

我们的方法用带类别标签的样本选择变量。预测犯错会产生损失；算法尽量降低训练分布在一定范围内变化后的最大损失，称为 Wasserstein 鲁棒选择，这个训练目标称鲁棒风险。各方法选出同样数量的变量，再用完全相同的预测规则评价，避免把预测规则的差异误当成变量选择的优势。

全文只有三个大实验。消融指每次只改一个设置，用来判断该设置的作用；这里只对半径和初始化做小规模检查。

实验	目的与比较	主要指标
E1 选择效果	在同一套合成和公开数据上，比较少量变量能保留多少分类信息	测试错误率；合成数据的信号恢复率
E2 分布变化	训练结果固定，只改变测试分布，比较表现如何下降	错误率随变化强度的曲线
E3 搜索代价	比较当前算法与逐步加变量的方法，检查多花时间能换来多少改进	训练风险；离最优还差多少；时间和求解次数

先生成一张带标签的数字表

合成数据的每一行是一条记录，每一列是一个数值变量，另有类别标签 $k = 0,1$。总列数记为 D，其中真正携带类别信息的列数为 s；每类训练行数为 n。算法只能选 d 列，d 是观测预算，不等于真实信号数 s。

每次重复按下面的步骤生成数据：

1. 分别为两个类别独立生成 n 条训练记录。每条先按下一页的规则抽取 s 个信号值。
2. 在每条记录后补 $D - s$ 个独立标准正态数，即均值零、标准差一的噪声。这些数的分布不随类别变化，也不依赖信号。
3. 使用同一生成规则，另行抽取每类二十条验证记录、一万条测试记录。训练、验证、测试互不复制。
4. 抽取一次列的随机排列，统一应用于本次重复的训练、验证、测试；所有方法共享这些数据。下一次重复重新抽样和排列。

例如 $D = 50, n = 20, s = 4$：训练表有四十行、五十列，每类二十行；每行含四个信号数和四十六个噪声数。验证表也有四十行、五十列，测试表有两万行、五十列。标签始终随记录保存，不作为候选变量。

训练集用于选变量和拟合检验，验证集用于选参数，测试集用于最后评价。因此 $n = 20$ 之外还用了每类二十个验证标签。不同预算复用同套数据，只改变允许选择的列数。

一条记录的信号值怎样抽取

以下 $Z_1, \ldots, Z_s$ 都是独立标准正态数，每条记录重新抽取。类别标签为 k。参数由后面的统一难度条件确定。

- 均值不同：对每个信号坐标取 $X_j = (2k-1)a + Z_j$。类别零将噪声减去 a，类别一加上 a。
- 波动不同：类别零直接取 $X_j = Z_j$，类别一取 $X_j = rZ_j$。两类中心相同，后者的波动放大 r 倍。
- 相关不同：每对信号独立生成。先抽两个噪声数，取 $X_{2h-1} = Z_{2h-1}$、$X_{2h} = c_k Z_{2h-1} + \sqrt{1-\rho^2} Z_{2h}$，其中 $c_k = (1-2k)\rho$。两类相关系数分别为正、负，单列分布相同。
- 混合不同：每条记录独立抽符号 $B = \pm 1$，各以一半概率出现，取 $X_{1:s} = Ba\, v_k + Z$。v_0 的各项均为一；v_1 前半为一、后半为负一。这里 s 取偶数，$Z = (Z_1, \ldots, Z_s)$。单列分布相同，组合关系不同。

四组模型都先校准到同一总体难度：知道真实分布、观察全部 s 个信号的理想分类器，其两类平均错误率为 20%。参数在运行方法前求解并保存，不根据结果调整。下面给出近似值；生成时保存完整精度。两列 a 分属不同模型。

s	均值 a	波动 r	相关 ρ	混合 a
2	0.595116	2.538656	0.809017	1.212285
4	0.420811	1.871151	0.600000	0.857215
8	0.297558	1.540038	0.425719	0.606142

例如四信号均值模型，类别零的前四列分别从均值约 -0.421、标准差一的正态分布抽取；类别一的均值约为 0.421。其余列照常补独立噪声。不同 s 都重新校准，不能把四信号的相关系数直接沿用。

与原论文怎样对应

原论文第5.1节的两类生成式为 $X = 0.4Be + Z$ 与 $X = 0.4Bf + Z$：e 是一百个一，f 前五十项为一、后五十项为负一，Z 是一百维标准正态噪声。每类训练十条、测试一千条，重复五百次。它没有变量选择，也没有唯一的四列真支持。

保留这组原设置作为单列数据锚点，评价全变量检验错误率，不计变量恢复率；验证集仍按本文规则另采每类二十条，预测也用本文规则，不与原文表格直接对数值。它不并入统一 20% 难度网格。上面的混合模型是其稀疏改造，其余三类是补充的选择检查。

规模和预算怎样变化

先固定 $s=4$，三档规模都比较预算 $d=2,4,8$，观察预算不足、刚好和宽松时的表现。这里候选数和训练数一起改变，档位差异不单独归因于其中某一个因素。

规模	候选变量 D	每类训练数 n	信号数 s	预算 d
小	20	10	4	$2,4,8$
中	50	20	4	$2,4,8$
大	100	50	4	$2,4,8$

在中档固定 $D=50, n=20$。将信号数改为 $s=2$ 时，预算取 $d=1,2,4$；改为 $s=8$ 时，取 $d=4,8,16$。连同已有的四信号条件，三种信号数都比较一半、相等和两倍的预算。共享条件只算一次，不把所有因素全部交叉。

四种模型每个数据配置做三十次独立重复。共五个数据配置、四种模型，即六百套独立数据；每套比较三个预算，共 1,800 个数据－预算任务。所有方法共享每套数据和预算。原论文锚点另计五百次。

公开数据怎样安排

公开数据选取以下四组。前三组是小样本表格分类，最后一组增加到数百个特征，并检查能否推广到训练中没出现的人。

数据	全库规模	本实验任务与用途
WDBC	569 条，30 变量	根据细胞测量区分良性与恶性
Ionosphere	351 条，34 变量	根据雷达测量区分好坏回波
Sonar	208 条，60 变量	根据声呐频段区分岩石与金属
UCI HAR	10,299 窗口，561 特征，30 人	只保留坐与站；用未见受试者测试

表格数据按类别分别划分：60% 为训练池，20% 验证，其余测试，样本数取整时训练和验证向下取整。每次从训练池抽取每类 $10,20,40$ 个样本；同一划分内小样本集包含在大样本集中。每个数据集做十个共享划分，ID 和目标字段不作为变量。

HAR 按人划分，避免同一个人的相近窗口同时进入训练和测试。使用官方二十一人训练、九人测试的划分；每次从训练侧留六人验证，其余十五人中尽量均匀地抽取每类四十个窗口。做十次重复，预算为 $8,16,32$。同人同活动连续区段隔一个保留一个窗口，以减少重叠；验证和测试使用对应受试者的全部保留窗口，按人而非窗口汇总误差。

每个变量只用训练集计算均值和标准差，做减均值、除标准差的标准化；验证与测试沿用同一变换。删除训练中不变化的列，并记录保留变量数。各类在训练目标和评价中等权。

和谁比较，为什么要有这些方法

各方法都选出 d 个变量。两层对照分别回答：选变量的依据好不好，以及优化同一个目标时怎样搜索更有效。

同目标搜索包括四种方法。穷举把所有大小为 d 的选集逐个拟合，给出小问题的最优真值；全局搜索、前向选择、前向加交换则比较如何更省计算地逼近这个值。四者共享数据、半径、损失和固定选集求解器。

全局搜索是当前算法：不断评估选集，并利用已得到的信息排除不可能更好的选择，直到达到目标精度或时间限制。它用逐变量 MMD 的前 d 项初始化。

前向选择从空集开始，每次加入使鲁棒训练风险最低的一个变量。前向加交换在此基础上，再尝试用一个未选变量替换一个已选变量，每轮保留最好的改进。这两种方法与全局搜索优化同一个目标，区别是搜索范围；它们用于判断全局搜索是否值得额外时间。交换最多接受十次，没有改进时提前停止。

其他选择方法分别代表以下思路：

- 逐变量 MMD：分别比较每个变量在两类中的分布，按差异从大到小选取。MMD（最大均值差异）把同类样本相似度与异类样本相似度比较，差异越大，分数越高。
- L1 逻辑回归：训练一个线性分类器，用惩罚让不重要的系数变小，再选绝对系数最大的变量。它代表常用的稀疏线性选择。
- mRMR：每次优先选择与类别有关、又不重复已选变量信息的变量。用互信息衡量这种依赖；小样本下先按训练三分位点分成三档，重合切点合并，避免估计过细。
- 联合 MMD：把选中的多个变量作为整体比较两类分布，用前向选择加单次交换寻找较大的 MMD。它能利用单个变量看不见的相关关系，提供与鲁棒目标不同的联合选择对照。
- 均匀随机：用保存的随机种子抽取一个大小为 d 的选集。

两种 MMD 都采用高斯相似度 $\exp(-\|x-y\|_2^2/(2h^2))$；$h$ 是当前变量子集上的训练样本正距离中位数。分数为两类各自的平均类内相似度之和，减去两倍平均类间相似度；类内平均不含样本自身。联合 MMD 直接最大化这个分数，交换规则与前向加交换相同。

另列真实信号的全部 s 列和全部 D 列作为解释参照，分别说明知道信号位置、放宽观测预算时的表现，不参与同预算排序。

选完以后，怎样保持比较公平

所有选集都重新训练同一种鲁棒评分。它输出 $[-1,1]$ 内的数，正值偏向类别 0；训练使用损失 $\ell(t)=\frac{1}{2}\max(0,1+t)$，使每个固定选集的拟合成为线性规划，即目标和约束都是线性的优化问题。按理论笔记给出的函数构造，用新点与两类训练点在所选坐标上的距离计算评分。

鲁棒半径控制允许分布偏离训练样本多远：较小半径更相信训练数据，较大半径防备更大变化。标准化后，用每类训练样本的两两 ℓ_1 距离中位数除以 D，记为 b_k，作为单坐标尺度；候选半径为 $\theta_k=\rho_0 b_k$，$\rho_0\in\{1/8,1/4,1/2,1,2\}$。实际运输成本仍是所选坐标绝对变化之和。

在参考预算四（HAR 为十六）下，用逐变量 MMD、mRMR、联合 MMD 的三个选集，比较各候选半径的平均验证错误率，选择一对共同半径。随后所有方法、所有预算都固定使用它。L1 逻辑回归的参数 C 越小，惩罚越强；在 $\{0.01,0.1,1,10,100\}$ 中用同一验证评价选择。平局取较大半径、较强惩罚；变量平局取较小索引。测试数据不参与这些选择。

E1：少量变量能保留多少判别信息

主比较使用前述四种模型、三档规模和三种预算，中档另比较信号数 $s = 2, 4, 8$。错误率和恢复率都画成预算曲线，而非只列 $d = 4$。两信号的相关与混合模型在预算一时没有单列判别信息，应展示这一限制。

前三个公开数据集先固定预算四，比较每类训练样本 $10, 20, 40$；再固定每类二十个训练样本，比较预算 $1, 2, 4, 8$。中心条件只运行一次，每个数据集六个条件、十个划分，共 180 个实例。HAR 比较预算 $8, 16, 32$，共三十个实例。

主要预测指标是两类等权的错误率。把评分 $f(x)$ 换成接受类别 0 的概率 $p_0(x) = (1+f(x))/2$。类别 0 的错误概率为 $1 - p_0(x)$，类别 1 为 $p_0(x)$。在各类测试样本内取平均，再将两类平均：

$$\mathrm{BER}_{\mathrm{prob}} = \frac{1}{2}\big(\mathrm{mean}_{Y=0}(1 - p_0(X)) + \mathrm{mean}_{Y=1}\, p_0(X)\big).$$

直接计算概率，不额外掷硬币。错误率 0.5 对应没有类别信息的恒定预测。训练风险是两类损失之和，尺度为相应平衡错误率的两倍；优化差距按这个和计算。另报非负分判为类零、负分判为类一的错误率，同样对两类等权；两类各自的错误率也保留，避免一类改善掩盖另一类恶化。

合成数据另外检查信号恢复。若选中 h 个真实信号，则精确率为 h/d，召回率为 h/s。恢复统计先还原打乱的索引。混合模型可能只凭跨两个半区的一对变量就能判别，完整恢复并非预测正确的必要条件。公开数据只报告选中变量及频率。

三档规模用结果表比较；中档预算变化用错误率、信号召回率两张图；公开数据按数据集和样本量汇总。合成结果报告三十次重复的均值和标准差；每次先算方法差值，再对三十次差值做二千次有放回抽样，给出 95% 区间。表格数据报告十个划分的配对差值和标准差。HAR 先在每人内平均训练重复，再等权汇总九个人，并按人重采样。

E2：测试分布变化后，选择是否仍然有用

复用四种模型中档 $s = d = 4$ 的训练结果，各三十次，不重新选择变量或调参。对测试集做两种变化：共同平移四个信号坐标；在四个坐标上加入独立正态测量噪声。各方法看到完全相同的变化样本。

变化强度用平均半径 $\bar{\theta} = (\theta_0 + \theta_1)/2$ 作参照，位移量取 $\delta/\bar{\theta} = 0, 1/2, 1, 2$。平移向量为 $\delta(1, 1, 1, 1)/4$；噪声标准差取 $\delta/(4\sqrt{2/\pi})$，使两种变化的期望绝对位移之和都等于 δ。这些操作均在保存的标准化坐标中进行。

每种信号各画一幅图，每种方法一条错误率曲线，同时列出从无变化到最大变化的增量。它回答指定变化下谁退化更快；训练优化区间只约束所设 Wasserstein 集合内的损失，不自动保证任意测试变化下的错误率。

半径消融只增加二十个均值与混合中档 $s = d = 4$ 实例，各十次。对全局搜索和前向加交换，固定数据并比较选中半径的 $1/2, 1, 2$ 倍，共 120 次方法运行。三档体现保护更弱、原设置和保护更强，检查错误曲线及是否出现恒定预测，不按测试结果反选半径。

E3：全局搜索是否值得计算成本

先在小问题上同时比较穷举、全局、前向、前向加交换。设 $D = 10, s = 4, d = 3$，固定半径 $\theta_k = b_k/4$，每类训练样本为五或十，四种模型各做五次重复，共四十个实例。穷举全部 120 个大小为三的选集，得到共同求解器下的最优真值；再用独立固定选集线性规划复核。报告各方法高出穷举最优值多少，以及耗时和拟合次数。

算法中的“割”是对所有选集都有效的风险下界公式。另检查割在全部 176 个大小至多为三的选集上均不超过真实值，返回区间包含枚举最优值。数值核查容差为 10^{-8}，外层区间宽度至多 10^{-6}；完整穷举与核查必须完成。

大规模成本比较全局、前向、前向加交换。穷举在 $D = 50, d = 4$ 时已有 230,300 个选集，不要求它完成大规模任务；限时穷举不能标为最优真值。采用四信号均值与混合模型，中心为 $D = 50, n = 20, d = 4$，每次只改变一个因素：

$$D \in \{20, 50, 100, 200\}, \qquad n \in \{10, 20, 50, 100\}, \qquad d \in \{2, 4, 8, 12\}.$$

共享中心只算一次，每种模型十个条件、各十次重复，共 200 个实例。使用共同半径 $\theta_k = b_k/4$，将参数选择开销与搜索成本分开。固定同一硬件、一个求解器线程，每次搜索限时三百秒。全部实例计时一次，仅二十个中心实例重复三次，报告其中位数和范围。

全局搜索需要同时报告找到的解和仍可能改进多少。算法用 $0/1$ 变量表示每列是否选择，交给整数求解器搜索。已找到的可行解给出的风险上界记为 U，求解器证明的全局下界记为 L；$U - L$ 是还未排除的改进空间。不要用搜索中当前可行解的目标值代替下界。

画出 U, L 随时间的变化，并记录首次达到最终最好解的时间、达到目标差距的时间、固定选集拟合次数及选择下一组选集所用的搜索时间。比较三百秒内谁找到更低风险，以及全局搜索在 $10, 60, 300$ 秒时有多少实例完成证明。贪心方法报告可行风险和时间，不给它们附加不存在的全局证书。

只保留必要的运行约定

统计实验中，每个候选配置的变量选择限时三百秒，HAR 为六百秒；单次固定选集拟合最多六十秒，且不超过剩余搜索时间。全局目标绝对差距为 10^{-3}，固定选集的风险上下界差不超过 10^{-4}，交换也以此作为最小改进量。将各约束按自身尺度统一后的违反量控制在 10^{-7} 内。这些数值控制求解精度，不作为提高预测效果的调参项。

所有方法都计入初始化、候选交换和最终拟合，公共半径选择时间单列并给出总时间。超时保留已核查的最好可行结果和差距；无法得到可核查检验时返回恒定零评分并标为失败，仍进入预测汇总。预算未填满时按剩余逐变量 MMD 排序补足，并保留未完成标记。

初始化消融复用半径消融中的二十个实例：在原选中半径下，将全局搜索的 MMD 初始化改为一次随机大小为 d 的选集，只增加二十次运行。比较解质量、求解次数、时间和最终差距。

最终保留数据版本、划分、种子、模型参数、标准化规则、选集、验证选择、错误率、求解状态和时间轨迹。先用不进入最终统计的十个开发实例检查实现；规则确定后再运行上述比较。整份笔记中的数字都是计划设置，没有预填结果或方法排名。