鲁棒变量选择：实验思路与运行记录

数据截至 2026-10-18T21:48+08:00；运行进度与已有结果见文末

1　先从一个具体问题讲起

假设一条细胞检查记录有三十个测量值，但以后每条记录只能保留四个。问题是：选哪四个，仍能尽量区分良性与恶性？这里的“变量选择”就是选整列，而不是从一条记录里挑几个较大的数。选出的四列确定后，所有新记录都只观察这四列。

我们的方法还考虑测量条件改变。训练样本中的区分规律，可能在新样本上变弱；因此选变量时，不只看训练样本本身，也考虑其附近一些分布中较差的情况。下文把这种选择依据称为**鲁棒风险**。它是训练时优化的量，是否真的有助于新数据，仍要用独立测试样本检查。

整套实验围绕三个问题展开，先说明各自的目的，再决定用什么数据和指标。

实验	想回答的问题	怎样回答
E1 选择效果	少量变量能否保留类别信息？	在相同数据、相同变量数下比较方法；看新样本错多少、真信号找到多少
E2 分布变化	测量条件变化后，原来选出的变量和检验是否还有效？	训练结果固定，只改变测试数据，观察错误增加多少
E3 搜索代价	为了把训练目标找得更低，全局搜索多花的计算是否值得？	小问题与穷举对答案；较大问题比较解质量、时间和还可能改进多少

把一次实验想成三张表

下面用一组实际计划设置贯穿解释。每条记录有五十个变量，其中四个真正与类别有关；每类给二十条训练记录。记候选变量数为 $D = 50$、真实信号数为 $s = 4$、每类训练数为 $n = 20$。允许选择的列数叫**观测预算**，记为 d；例如 $d = 4$。s 是数据的性质，d 是给方法的限制，两者不必相等。

训练表共有四十行、五十列。各方法用它选出四列，并确定预测规则，这一步称为拟合。另有四十行验证表，负责选参数；最后用两万行测试表计算错误率。三张表分别抽样，测试表在选变量、选参数时都不使用。同一次抽样中，全部方法共享这三张表；改变预算时也复用它们。

所以一次完整比较是：准备三张表，确定共同参数，各方法选列并拟合，最后在同一批新记录上评价。独立重复这套过程，才能判断差别是否稳定，而不是只展示一组碰巧有利的数据。

2　合成数据：先规定每一行怎样产生

合成数据的好处是我们知道哪些列确实携带类别信息，因而能检查有没有选对。类别记为 $k = 0, 1$。每一行先按下面一种规则生成 s 个信号值，再补上 $D - s$ 个独立标准正态噪声。标准正态数指均值零、标准差一的随机数；以下每个 Z_j 都独立重抽，噪声列也与类别和信号独立。

均值不同。 类别零的信号整体偏小，类别一整体偏大：

$$X_j = (2k - 1)a + Z_j, \qquad j = 1, \ldots, s.$$

例如 $a = 0.421$，就是给类别零的每个信号数减去约0.421，给类别一加上约0.421。单独看一列就可能发现差别。

波动不同。 两类中心相同，但类别一更分散。类别零取 $X_j = Z_j$，类别一取 $X_j = rZ_j$，其中 $r > 1$ 是标准差放大的倍数。这一组检查方法能否发现均值以外的差别。

相关关系不同。 信号每两列一组。先抽两个独立正态数，再令

$$X_{2h-1} = Z_{2h-1}, \qquad X_{2h} = (1 - 2k)\rho Z_{2h-1} + \sqrt{1 - \rho^2}\, Z_{2h}.$$

不同的二列组独立生成。两类每一列的均值都是零、方差都是一；区别是同一对变量在类别零中同向变化，在类别一中反向变化。因此逐列排序缺少线索，必须利用列的组合。

混合方向不同。 每行先抽一个整行共用的正负号 $B = \pm 1$，各占一半，再生成

$$X_{1:s} = Ba\, v_k + Z.$$

Z 是 s 个独立标准正态数组成的向量。v_0 全为一；v_1 前半为一、后半为负一。例如 $s = 4$ 时，两类的中心分别沿 $(1, 1, 1, 1)$ 和 $(1, 1, -1, -1)$ 两个方向正负移动。这里单列分布也相同，区别藏在变量之间的关系中。

这些系数为什么这样定

四组先统一到同一个先天难度：知道真实分布、能观察全部 s 个信号的理想分类器，最小两类平均错误率为20%。这让模型间的比较不至于只是“一组本来就容易”。它不是要求我们的少样本方法达到20%。参数在运行方法前求出，下面是保存值的近似数，不按测试效果调整。

信号数 s	均值 a	波动 r	相关 ρ	混合 a
2	0.595116	2.538656	0.809017	1.212285
4	0.420811	1.871151	0.600000	0.857215
8	0.297558	1.540038	0.425719	0.606142

生成整张表后，随机打乱一次列位置，并把同一排列用于训练、验证和测试。各方法共享该排列，下一次重复重新抽样。这样算法不能靠“前四列总是信号”选对变量。

3　在哪些规模和真实数据上比较

合成数据同时改变规模、信号数和预算

每种信号模型都使用下表五个配置。前面三行固定四个信号，比较小、中、大三档；后两行在中档改变信号数。每行都比较信号数一半、相等、两倍的预算，以检查“只能观察一部分”“刚好够用”“有多余名额”三种情况。

配置	候选数 D	每类训练数 n	信号数 s	预算 d
小档	20	10	4	2,4,8
中档	50	20	4	2,4,8
大档	100	50	4	2,4,8
较少信号	50	20	2	1,2,4
较多信号	50	20	8	4,8,16

每个模型、每行配置独立重复三十次。四模型乘五配置乘三十次，共六百套独立数据；每套三个预算，共一千八百个数据与预算任务。每次另抽每类二十条验证记录、一万条测试记录。三档同时改变了候选数和训练数，所以档位差别不单独归因于某一个因素；E3会另做一次只改一个因素的比较。

公开数据检验结论能否用于真实测量

合成数据的无关列是刻意独立的，真实数据却常有相关变量、测量噪声和冗余。公开数据因此承担第二层检查，但不能据它们计算“真信号恢复率”，因为我们不知道唯一正确的变量集合。

数据	全库规模	本次区分的类别
WDBC	569条，30变量	细胞测量的良性与恶性；去掉ID与类别字段
Ionosphere	351条，34变量	雷达好、坏回波；训练中的常量列会删除，通常保留33列
Sonar	208条，60变量	声呐测量中的岩石与金属
UCI HAR	10,299窗口，561特征	这里只用坐、站两类；全库30人，10,299不是筛选后的实际样本数

前三组按类别分别随机划分：60%进入训练池，20%验证，其余测试；前两项向下取整。每个数据集做十次划分，每次从训练池取每类10、20、40条，小训练集包含于大训练集。在 $n = 10,40$ 时只比较 $d = 4$；在 $n = 20$ 时比较 $d = 1,2,4,8$。因此可以分别看增加训练数据、增加测量变量的作用。

HAR按人划分，避免同一个人的相邻窗口同时出现在训练和测试。保留官方21人训练、9人测试；每次从训练侧留6人验证，余下15人尽量均匀地提供每类40个训练窗口。重复十次，预算为8、16、32。先在原始同人同活动连续区段隔一个保留一个窗口，再筛坐与站，以减少相邻重叠。评价时每名测试者等权，不能把很多窗口说成很多独立受试者。

另保留原论文的一百维混合数据

两类分别生成 $X = 0.4Be + Z$ 与 $X = 0.4Bf + Z$，e 是一百个一，f 前五十项为一、后五十项为负一，Z 为一百维标准正态噪声，B 仍是每行独立的等概率正负号。每类训练10条、验证20条、测试1000条，重复500次，保留全部100变量。它只检查当前预测规则在相似生成机制下的表现，不做变量选择，也不并入20%难度网格。验证与预测规则和原文不完全相同，因此不把它称为原论文算法的完整复现。

4　和谁比较：先分清选列依据与搜索办法

一种方法选出四列后，还需要用这四列预测类别：先把记录变成偏向某一类的数值，称为评分，再据此判类。为了把区别尽量归到“选了哪些列”，所有比较方法最终都重新拟合同一种鲁棒评分。比如L1逻辑回归在这里负责选列，测试时并不直接使用它原来的逻辑分类概率。

同一个目标，比较怎样搜索

全局搜索是当前算法。它从按单列分布差异排出的一组选集开始，计算这组变量的风险，再利用已有结果寻找可能更好的组合。它既记录已经找到的最好方案，也记录还可能改进多少；这两种量的计算含义在E3中说明。

前向选择从空集开始。每轮把每个尚未选的变量分别试加一次，计算鲁棒风险，留下最低的那一列，直到选满 d 列。**前向加交换**选满后，再逐一试“删一列、加一列”，每轮接受最好的替换，改善至少0.0001才继续，最多接受十次。这检查便宜的局部搜索是否已经够用。

穷举把所有同预算选集逐一算完，只用于十列选三列的小问题，共120种。它提供可核对的最优值。大规模不把限时枚举到的一部分误称为真实最优值。

不同的选列依据，比较信息是否选得更好

先解释**MMD（最大均值差异）**。它用样本之间的相似度衡量两类分布是否不同：同类较相似、跨类不相似时，差异分数通常更大。其样本分数为

$$\widehat{\mathrm{MMD}}^2 = \text{类零内部平均相似度} + \text{类一内部平均相似度} - 2\,\text{两类之间平均相似度}.$$

相似度取 $\exp(-\|x-y\|_2^2/(2h^2))$，其中 $\|x-y\|_2$ 是各列差的平方和再开方。相同样本得一，距离增大时下降；h 决定下降快慢：计算当前所用列上全部训练点对的距离，去掉零距离后取中位数。类内平均不含样本与自身的比较。这个有限样本分数可能为负，仍保留原值，不截成零。名字中的“均值”是变换后的相似度均值，所以它不只检查原始变量的均值差。

逐变量MMD每次只看一列，算两类分布差异，取分数最高的 d 列。它可发现均值或波动差异，但看不到“单列相同、组合不同”的信息。全局搜索也用这一排序作初始选集。

联合MMD把当前多列作为一个向量计算差异，前向加列后再做最好的一换一。每个候选选集重算 h，最多接受十次、每次至少改善0.0001。它能利用列间关系，但这里只做局部搜索，不宣称找到了MMD的全局最优选集。

L1逻辑回归先给各列乘系数再相加，拟合一个线性分类器；对系数绝对值之和加惩罚，再选绝对系数最大的 d 列。它检查常见的稀疏线性选择是否已经足够。比较 $C = 0.01, 0.1, 1, 10, 100$，$C$ 越小惩罚越强；每个选集都拟合共同鲁棒评分，以验证错误率选 C，平局取较小 C。

mRMR（最大相关、最小冗余）优先选与类别有关、又少重复已选信息的列。互信息衡量“知道一个量后，另一个量的不确定性减少多少”。为便于用小样本估计，每列按合并训练数值从小到大大致等分三份，分成低、中、高三档，重复分界合并；每轮用与类别的互信息，减去与已选各列互信息的平均值。首轮没有重复项。

均匀随机不放回抽取 d 列，提供没有选列依据的参照，随机种子保存。以上并列候选按较小列索引决定。全部真信号、全部变量也另做参考，但列数可能不同，不参加相同预算的排名。

5　一次公平比较怎样完成

先处理量纲，再把测试集留到最后

距离会受单位影响：数值范围大的列可能主导距离，而不一定更重要。因此每列先减去合并训练样本的均值，再除以训练样本标准差。验证和测试沿用这组数值，不各自重新标准化。训练中完全不变化的列删除，保留原列索引；不能按测试集是否变化决定保留什么。

训练表负责选变量和拟合。验证表负责选择参数。测试表最后才用于报告结果。因此合成实验的 $n = 20$ 表示每类二十个拟合标签，除此之外还有每类二十个验证标签，不把额外标签隐藏在“小样本”说法里。

鲁棒半径是什么，为什么要共同选择

把某一类训练样本看成各带相同权重的概率质量。允许把这些质量搬到附近位置，平均搬动距离不超过一个数，这个数就是该类的**Wasserstein半径**。距离用所选坐标绝对差之和，称为 ℓ_1 距离。半径越大，训练目标要防备的变化越广，通常也更保守；但“更保守”是否更准确，要由验证和测试来判断。

先用训练数据确定尺度。对每一类，计算所有训练点对的 ℓ_1 距离，取中位数，再除以保留列数，得到 b_k，其中 k 是类别。比较五种候选半径

$$\theta_k = c\, b_k, \qquad c \in \{1/8, 1/4, 1/2, 1, 2\}.$$

同一个倍数 c 同时用于两类，但两类的尺度 b_k 可以不同。这里除以列数只是把训练距离换成每列的典型尺度，避免候选变量多时半径仅因维数而机械变大。

在参考预算四（HAR为十六）下，先用逐变量MMD、mRMR、联合MMD分别选列。对每个候选半径拟合这三组检验，平均它们的验证错误率，取最小者，平局取较大半径。这样不是用我们自己的方法单独决定所有人的参数。选定后，同一套数据中的全部方法、全部预算都固定这对半径，不随测试表现重选。E3只比较搜索时，半径固定为 $b_k/4$，不混入验证调参的耗时。

列选完之后，所有方法怎样预测

固定选集后，用相同鲁棒模型求训练点的评分、各点基准代价和每类距离权重。预测新记录时，只取选中列；在每一类中，找“基准代价加上加权距离”最小的参考训练行，称为锚点。记两个锚点评分为 u_0, u_1，新点到类别零锚点的距离为 r_0，两锚点距离为 q，则

$$t = \min\{1, r_0/q\}, \qquad f(x) = (1-t)u_0 + tu_1.$$

距离仍是所选列的绝对差之和；$q = 0$ 时规定 $t = 0$。评分 $f(x) \in [-1, 1]$，正值偏向类别零，负值偏向类别一。锚点是已有训练行，不是额外数据。

这套评分构造也是实验要检验的一环。把训练目标求得很低，并不自动说明独立新样本能预测得好；文末的一百维实验正好展示了两者的区别。

6　指标怎样算，每个数字回答什么

预测：两类分别算错，再等权平均

两类测试样本数可能不同，直接算总错分比例会更偏向人数多的一类。我们先算各类错误，再各占一半，这叫**平衡错误率（BER）**。越低越好，同时保留每一类的错误，防止平均值掩盖单类失败。

阈值错误率把 $f(x) \geq 0$ 判为类别零，否则判为类别一。分别统计两类错分比例 e_0, e_1，取 $(e_0+e_1)/2$。计算示例：两类各十条记录，分别错两条、四条，平衡错误率就是 $(20\%+40\%)/2 = 30\%$。这个示例只说明算法，不是实测结果。

主指标还保留评分的不确定性。把评分转换成**判为类别零的决策概率**

$$p_0(x) = \frac{1+f(x)}{2}.$$

例如 $f = 0.6$ 时，以0.8的概率判零、0.2的概率判一。它是规定的随机判决规则，不等于已校准的真实类别概率。对真实类别零，预期判错概率是 $1-p_0$；对真实类别一，则是 p_0。因此**概率错误率**为

$$\mathrm{BER}_{\mathrm{prob}} = \frac{1}{2}\left[\mathrm{mean}_{Y=0}(1-p_0(X)) + \mathrm{mean}_{Y=1}\, p_0(X)\right].$$

计算示例：两类的平均 p_0 分别为0.8和0.3，概率错误率为 $(0.2+0.3)/2 = 25\%$。实际直接计算这些概率的平均，不再抽随机标签，以免额外加入抽签噪声。阈值错误率检查最后的硬判类，概率错误率检查整个评分；二者可以不同。

恒定判同一类或不看记录等概率猜测，平衡错误率都是50%。这是参照水平；其他规则也可能得到50%，不能仅凭该数字说数据没有类别信息。

训练鲁棒风险把两类的预期错误分别在允许的分布范围内取最大，再相加。因此它除以二后才与平衡错误率同尺度，且只约束所设定的分布范围，不是独立测试错误的无条件保证。

选列：既看找回多少，也看是否浪费名额

只有合成数据知道真信号。若共有 s 个信号，方法选了 d 列，其中命中 h 列，则精确率为 h/d，召回率为 h/s。示例：四个信号中选中两个，同时总共选三列，精确率 $2/3$、召回率 $2/4$。若把预算放得很大，召回容易上升，所以两个指标一起看。

恢复率也不完全等同于分类能力。混合模型可能凭跨两个半区的一对变量就获得信息，未选全四个信号不等于无用；反过来，选中了信号也仍需检查评分是否把信息用好。

重复实验：平均值、波动和方法差值

合成数据通常报告三十次独立重复的均值与样本标准差，表中的“$\pm$”表示不同数据重复之间的波动，不是均值误差。比较方法时，先在同一套数据内作差；需要区间时，从这些成对差值中有放回重抽同样数量，重复2000次，取平均差的2.5%和97.5%分位作为95%区间。

公开表格的十次划分反复使用同一数据集，只描述划分敏感性，不当成十个独立人群。HAR先对每名测试者平均十次训练结果，再对九人等权；区间也按人重抽，不把窗口或训练重复当成新受试者。

7 E1与E2：怎样验证选择与稳健性

E1：相同预算下，选择依据是否有用

E1使用前面的六百套合成数据和四组公开数据，比较全局、前向、前向加交换、五种其他选列依据。全部方法共享训练、验证、测试和预算，再拟合共同评分。因此逻辑回归等基线的作用是比较选集，不是比较不同分类器的最终能力。

先在合成中档 $D = 50, n = 20, s = 4$ 看预算2、4、8的错误率和恢复率；再检查另外两档与信号数2、8的结果。均值、波动组中单列就有信息；相关、混合组中必须组合变量。因此可以区分方法只是擅长逐列打分，还是也能利用联合信息。两信号的相关或混合组在预算一时，单列没有类别信息，这种限制不能靠更好的搜索消除。

公开表格在每类二十训练样本下看预算曲线，在预算四下看每类10、20、40个训练样本；HAR看预算8、16、32在未见过的人上是否有效。全部变量与全部真信号只辅助解释是否损失信息；它们与小预算不直接排名。每个条件分别报告，不把四种模型或不同预算混成一个总冠军。

E2：固定训练结果，只改变新数据

E2复用E1中档四信号、预算四的训练结果：四模型各三十次，共120套。变量、标准化变换、半径和评分全部固定，不重新训练。只对原测试记录的四个信号坐标加变化；各方法看到同一批变化后的记录。

变化强度记为 δ，取平均训练半径 $\bar{\theta} = (\theta_0 + \theta_1)/2$ 的0、0.5、1、2倍。不是随意给每组选择不同尺度，而是以该次已选半径作共同标尺。使用两种变化：

- **整体平移：** 每个信号坐标都加 $\delta/4$，所以一条记录四列的总绝对移动量为 δ。两类都一样移动，模拟测量零点改变。
- **增加噪声：** 每个信号坐标加独立零均值正态噪声，标准差为 $\delta/(4\sqrt{2/\pi})$。这个取法使每条记录的平均总绝对移动量也是 δ，便于和整体平移比较。

这里的操作都在训练变换后的坐标中进行，不对变化后的数据重新标准化。曲线画各强度的绝对错误率，表格报告最高强度相对零强度的增量。若同一强度下某方法错误增加较少，才是针对这类变化的稳健性证据。

这两种变化是明确可重复的压力测试，并不是已经求出了最坏分布。加噪声还可能使类别本身更难区分，错误增加不能全部解释成算法不稳健。真实分布也未必位于所选半径内，所以训练风险低不等于测试错误一定低。

8　E3与小消融：多花计算是否值得

先说清“找到好解”和“证明好解”

固定一组选列后，鲁棒模型仍需拟合评分。把这个连续优化算一次，记作一次固定选集拟合。搜索时间包含初始化、试加变量、交换和最终拟合；另列共同半径选择耗时，并给出含它的总耗时。

全局搜索返回两个量：U 是已找到可行方案的风险上界，L 是所有选集最优风险的下界。因此 $U-L$ 是还未排除的改善空间。例如 $U=0.84, L=0.80$，仍可能降低最多0.04的训练风险，不是测试错误还差四个百分点。训练风险是两类最坏损失之和，除二才和概率错误率同尺度；这种最坏错误约束只针对设定的分布范围。

小问题还能知道独立最优值 $R^{\star}$，于是记录**超额风险** $U-R^{\star}$，表示当前解比真正最优高多少。贪心没有全局下界，不能给它编造最优性证书。时间、拟合次数、超额风险与 $U-L$ 一起看，才能区分“很快找到好解”与“花很久证明没有更好解”。

小问题核查与单因素规模比较

小问题固定 $D=10, s=4, d=3$，每类训练5或10条；四模型各五次，共40套。全部120个三列选集都算完，另用独立运输线性规划计算大小至多三的全部176个选集。线性规划是目标和约束对变量均为线性的优化问题；这套独立写法用运输质量计算同一个风险，核对结果而非只让原程序检查自己。

全局搜索还用到“割”，即从已算选集得到、应对所有选集成立的风险下界公式。对这176个选集逐条检查割是否超过独立风险，也核对 $[L,U]$ 是否包含最优值。独立值比较允许的数值误差为 10^{-8}，小问题的目标区间宽度为 10^{-6}。

规模实验只用均值、混合两模型，固定 $s=4$，以 $D=50, n=20, d=4$ 为中心，每次只改一个因素：

改变什么	比较值	另外两项
候选变量数	$D=20,50,100,200$	$n=20, d=4$
每类训练数	$n=10,20,50,100$	$D=50, d=4$
预算	$d=2,4,8,12$	$D=50, n=20$

共享中心只算一次，故每模型十个条件、各十次，共200套独立数据。二十套中心各计时三次，其余一次；先在每套内取计时中位数，再汇总独立数据。另记首次找到最终最好解、达到目标间隔的时间，以及10、60、300秒时的上下界与达标比例。

只做两项小消融

另生成二十套中档数据：均值、混合各十套，$D=50, n=20, s=d=4$。**半径消融**只把原选中半径乘0.5、1、2，用全局与前向加交换比较，共120次，检查更保守是否也更好。**初始化消融**复用这二十套与原半径，把全局的MMD起点换成一次随机选集，只增加二十次；这改变的是搜索起点，不是改用随机方法作最终选择。

一般每个候选配置的搜索限300秒，HAR为600秒；一次固定选集拟合最多60秒并受剩余总时间约束。L1的五个 C 各自限时，合计全部时间。通常外层间隔 10^{-3}、固定选集间隔 10^{-4}；约束在程序统一数值尺度后允许的误差为 10^{-7}。这些控制计算精度，不按测试成绩调整。超时保留最好可行解与剩余间隔；无法得到可核查评分时，用明确标记的零评分替代，错误率仍计入结果。

9　已完成结果：小问题的搜索是否算对

本节已记录 40/40 套小问题。前面解释了比较依据，现在看数据回答哪一部分问题。

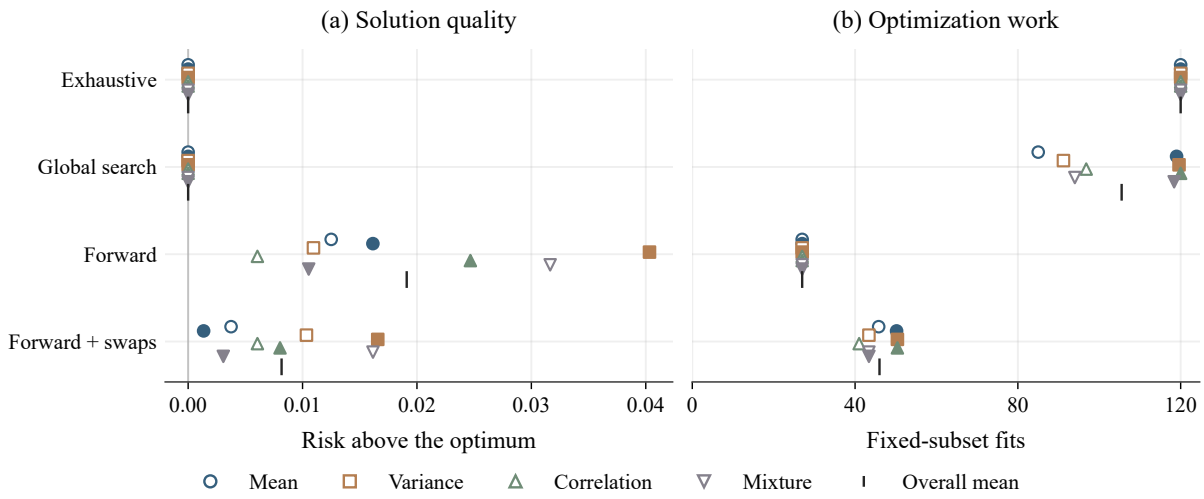


图 1. 左侧每点是一个模型、训练样本量条件下五次重复的平均超额风险，每种方法八个条件点；零表示与独立最优风险一致。右侧为同样条件下的平均拟合次数。颜色和点形区分四模型，空心、实心分别表示每类训练5、10条；黑色短线是40套数据的总体均值。

方法	高出最优	时间 / 秒	拟合次数
穷举	0.0000 ± 0.0000	1.06 ± 0.31	120.0 ± 0.0
全局搜索	0.0000 ± 0.0000	5.14 ± 1.17	105.5 ± 16.4
前向选择	0.0191 ± 0.0224	0.25 ± 0.08	27.0 ± 0.0
前向加交换	0.0082 ± 0.0146	0.43 ± 0.19	46.0 ± 7.9

四种模型、两种训练样本量，每格按四十套独立数据汇总；风险的尺度是两类损失之和，不是错误率百分比。

这张图和表怎样读

先看左侧：穷举与全局的点都在零附近，表示它们在这批小问题上找到了独立最优解。前向的部分点偏离零，加交换后降低，说明只加不换确实会遗漏一些更好的组合。表中风险和时间的“±”都反映40套数据之间的波动，不能把它误读为误差已经小到可忽略。

再看右侧：全局平均评估的选集仍接近穷举的120个，当前小问题还没有体现明显搜索节省。虽然全局训练目标求得更低，但这不是测试错误率图，不能据此得出分类更准的结论。两种结论由E3和E1分别回答。 交换将平均超额风险从 0.0191 降至 0.0082；全局平均拟合 105.5 次，穷举120次。并发计时不能作为独占硬件的速度结论。

为什么40个最优解，只有38个证明达标

独立计算已核查7040个固定选集、约210万条割不等式，没有发现违反；40个全局区间都包含独立最优值。找到的可行风险也都与最优值在既定核查容差内一致。但停止证明还要求 $U - L \le 10^{-6}$，两例略超这一阈值，所以保留精度限制状态。找到的解正确、最终间隔是否达标，是两个分别记录的事实。

这批计时是在并行数据任务下观测到的，表里如实列出实际秒数。要评价单独占用计算资源时的速度，仍要等后续串行的规模实验，而不能把本轮数值包装成全局搜索的加速优势。 最大最终间隔 1.0011e-06，略超0.000001目标的 2 例保留精度限制状态。

10　已完成结果：训练风险低，预测是否也好

这里看第3节的一百维混合数据，全部变量都保留，因此失败不能解释为“丢掉了某几个信号”。这一检查针对当前鲁棒评分本身。图中训练鲁棒风险除二，是设定分布范围内的最坏概率错误率上界；测试错误率则来自独立新样本。二者不是同一个数。

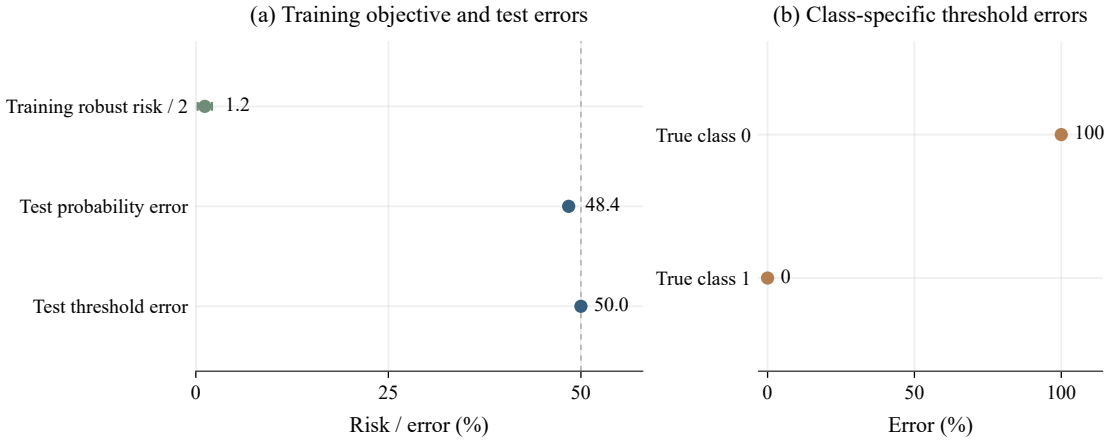


图 2. 左侧比较训练风险和两种测试错误率，点与误差线表示500次重复的均值与标准差；右侧分别看两类的阈值错误。一类全错、另一类全对，意味着检验总是偏向同一个类别，平均50%掩盖了这种偏置。

全变量检验	概率错误率	阈值错误率	有效重复
100 维混合模型	48.4 ± 0.5	50.0 ± 0.0	500

与原文相同的生成机制；本文另设验证样本并使用当前评分构造，因此不与原文表格直接对数值。

500次重复中，一百万个测试点的阈值预测全部为类别一，两类错误率为100%和0%。概率错误率为48.41%，比50%低 1.59 个百分点；但训练鲁棒风险的一半仅为 1.16%。

当前评分在两个训练锚点之间按距离插值。新点到类别零锚点的距离，通常接近两个锚点之间的距离；两类插值权重的中位数分别为 0.925 和 0.969，使评分偏向类别一。独立重算完整复现全部已存指标。本轮保留原规则，没有在看过测试结果后修改预测。

概率错误率比50%略低，说明评分仍保留少量区分；硬阈值却没有把这种区分转成有效判类。它揭示了当前评分构造的问题，不能把小规模优化正确性当作预测有效性的证明。

E1结果：不同规模与信号数

每行固定一种数据条件，只比较预算等于信号数时的概率错误率。这里突出全局、前向加交换和联合MMD三种联合选择办法；其他方法和预算保留在配套数值表。未满三十次的条件只能作为当前观测，不能作总体优劣结论。

条件	全局错误率	前向加交换	联合 MMD
均值 D=20, n=10, s=d=4；重复6/30	47.1 ± 2.3	45.5 ± 2.8	44.1 ± 0.9

数值为测试概率错误率（%）的均值 ± 标准差；每行单独汇总并列出有效重复数。其他方法和预算见配套数据。

表中已有 1/20 个预定条件，其中 0 个条件的三种方法均记录完整。每行固定数据模型、候选维度、每类训练数及信号数；只比较预算等于信号数的结果。其余预算保留在完整数值表中，缺失观测不填零。

运行进度：哪些结论仍需后续数据

部分	已记录 / 计划	当前范围
E1 合成	6 / 600	合成选择主比较；未完成前不排总体名次
全变量检查	500 / 500	保留全变量，检查评分的样本外行为
E1 公开数据	0 / 100	真实测量与未见测试者上的选择效果
E2 分布变化	0 / 120	复用E1，检验指定测试变化
E3 小问题	40 / 40	与独立最优值核对的搜索结果
E3 规模	0 / 200	单因素规模与串行计时代价
小消融	0 / 20	半径和初始化的局部影响

记录完成表示计划方法都已尝试，不表示每次搜索均已证明最优；超时与失败照实保留。E2复用E1，公开数据也反复划分同一数据集，表中各行不能直接相加说成独立人群数。未完成部分保留计划，不以零错误或推测结果补齐。 本轮使用AMD Ryzen 9 7945HX、16 GB内存，SciPy 1.18.1中的HiGHS求解器，每个求解器用一个线程。小问题并发运行；规模计时另在没有其他实验任务时串行进行。

本轮结果来自10月18日冻结的实现。理论稿后来补充了变量对风险的影响与搜索次数上界的分析；本轮未专门测量该上界，暂不声称已验证它。